

基于多时空图卷积网络的交通流预测*

戴俊明^a, 曹 阳^{a,b}, 沈琴琴^b, 施 隼^{a,b†}

(南通大学 a. 信息科学技术学院; b. 交通与土木工程学院, 江苏 南通 226019)

摘要: 交通流预测在交通管理和城市规划的应用中具有重要意义,然而现有的预测方法无法充分挖掘其潜在的复杂时空相关性,为进一步挖掘路网道路网络数据的时空特性以提高预测精度,提出一种多时空图卷积网络(multi-spatial-temporal graph convolutional network, MST-GCN)模型。首先,利用切比雪夫图卷积(ChebNet)结合门控循环单元(GRU)构建时空组件以深度挖掘节点的时空相关性;其次,分别提取周相关、日相关、邻近时间的序列数据,输入三个时空组件以深度挖掘不同时间窗口间的时间相关性;最后,将时空组件与编码器—解码器网络结构(encoder-decoder)融合组建 MST-GCN 模型。利用加利福尼亚州交通局(Caltrans)性能评估系统中高速公路数据集 PEMS04 和 PEMS08 进行实验,结果表明新模型的性能明显优于门控循环单元模型和最近提出的扩散卷积循环神经网络(DCRNN)、时间图卷积网络(T-GCN)、基于注意力机制的时空图卷积神经网络(ASTGCN)和时空同步图卷积网络(STSGCN)模型。

关键词: 交通流预测; 时空相关性; 编码器—解码器; 切比雪夫多项式; 图卷积网络

中图分类号: TP18;U491.1

文献标志码: A

文章编号: 1001-3695(2022)03-023-0780-05

doi:10.19734/j.issn.1001-3695.2021.08.0361

Traffic flow prediction based on multi-spatial-temporal graph convolutional network

Dai Junming^a, Cao Yang^{a,b}, Shen Qinqin^b, Shi Quan^{a,b†}

(a. College of Information Science & Technology, b. College of Transportation & Civil Engineering, Nantong University, Nantong Jiangsu 226019, China)

Abstract: Traffic flow forecasting is of great significance in the application of traffic management and urban planning. However, the existing forecasting methods cannot fully exploit the potential complex spatio-temporal correlations. In order to further explore the temporal and spatial characteristics of road network data to improve the prediction accuracy, this paper proposed a multi-spatial-temporal graph convolutional network (MST-GCN) model. Firstly, by using Chebyshev graph convolution (ChebNet) combined with gated recurrent unit (GRU) to construct spatio-temporal components to deeply mine the spatio-temporal correlation of nodes. Secondly, it extracted weekly, daily, and recent time sequence data separately, and entered three spatio-temporal components to deeply explore the time correlation between different time windows. Finally, it combined the spatio-temporal component and the encoder-decoder network structure to form the MST-GCN model. Experiments were conducted using the highway datasets PEMS04 and PEMS08 in the California Department of Transportation (Caltrans) performance evaluation system. The results show that the new model has significantly better performance than the gated recurrent unit model and the recently proposed diffusion convolutional recurrent neural network (DCRNN), temporal graph convolutional network (T-GCN), attention based spatial-temporal graph convolutional networks (ASTGCN) and spatial-temporal synchronous graph convolutional network (STSGCN) models.

Key words: traffic flow prediction; spatio-temporal correlation; encoder-decoder; Chebyshev polynomial; graph convolutional network (GCN)

0 引言

随着智能交通系统的快速发展,越来越多的学者关注交通流预测。交通流预测问题是根据城市路网或高速公路的道路交通现状进行建模,以预测未来一段时间内的交通状况,准确有效的预测能够帮助交通管理部门更合理地引导车辆,达到缓解交通拥堵,提高道路通行效率的目的^[1]。

现有的交通流预测方法主要分为模型驱动和数据驱动两类方法。模型驱动方法又称为参数方法,主要的代表模型有差

分自回归移动平均模型^[2]、卡尔曼滤波模型^[3]、灰色预测模型^[4]等,这类模型通常具有严格的假设条件和固定的算法结构,然而交通流容易受到随机干扰因素(如交通事故、天气、出行者行为等)的影响,不确定性较强,参数方法无法挖掘交通流的非线性特征,导致预测精确度普遍较低。数据驱动方法又分为传统机器学习方法和深度学习方法。前者的典型代表有支持向量机^[5]、K近邻^[6]、贝叶斯网络^[7]等。后者主要为人工神经网络及其各类变种^[8],这类模型具有较强的非线性映射能力,对数据的要求没有模型驱动方法严格,因此能够较好地

收稿日期: 2021-08-30; **修回日期:** 2021-10-26 **基金项目:** 国家自然科学基金资助项目(61771265);江苏高校“青蓝工程”项目;南通市科技计划项目(MS22021034,JC2021198);南通市“226”科研项目(131320633045);南通大学信息科学技术学院研究生科研与实践创新计划项目(NTUSISTPR21-007)

作者简介: 戴俊明(1998-),男,江苏扬州人,硕士研究生,主要研究方向为智能信息处理;曹阳(1986-),男,江苏如皋人,教授,博导,博士,主要研究方向为科学计算、智能信息处理;沈琴琴(1984-),女,江苏如皋人,高级实验师,博士,主要研究方向为智能交通;施隼(1973-),男(通信作者),江苏海门人,教授,博导,博士,主要研究方向为智能信息处理(sq@ntu.edu.cn)。

适应交通流的不确定性,有效地提高预测效果。

近年来,为了全面挖掘交通流特征,混合神经网络逐渐成为主流网络结构。大多数研究基于循环神经网络的变种(long short-term memory, LSTM^[9]和 gated recurrent unit, GRU^[10])与其他模型组合进行预测,取得了较好的预测性能。谷远利等人^[11]引入基于熵的灰色关联分析方法来捕获路段间的空间特征,提出一种新的深度学习模型,对车道级的交通速度进行预测;Lin 等人^[12]结合自注意力机制和卷积长短期记忆网络,提出一种新的自注意力记忆网络来捕捉空间和时间域方面的特征;包银鑫等人^[13]结合时空残差模型和卷积神经网络,对交通栅格数据进行相关性分析,并融合 LSTM 捕获周期性和邻近性的长期时间特征。

尽管当前交通流量预测已存在较多有效的方法,然而捕捉交通流的时空相关性,提高模型的预测性能仍然是一个具有挑战性的问题。现有的预测方法无法充分挖掘时空相关性主要存在以下两个原因:

a) 观察点的位置分布一般为不规则图状拓扑结构,普通方法难以充分利用数据内部有效的空间信息,无法完全捕获道路之间高阶邻居的微弱信息扰动。

b) 不同时期的历史数据对未来不同时间的交通流量有不同的影响,在时间维度上表现出很强的动态性。

由于观察点的空间结构是非结构化的,无法利用常规的卷积神经网络提取相邻观察点间的空间特征。因此,图卷积网络(GCN)^[14~16]受到了广泛的关注。Li 等人^[17]为捕获交通数据的时空依赖性,对 GRU 的门控进行改进,提出扩散卷积门控循环单元(DCGRU),结合编码器—解码器提出 seq2seq 的 DCRNN 模型;Zhao 等人^[18]在 DCRNN 模型的基础上,提出一种基于 GCN 和 GRU 的时间图卷积网络模型(T-GCN),与 DCGRU 相比,DCGRU 对输入和隐藏记忆单元进行图卷积,T-GCN 仅对输入进行图卷积。针对时间依赖,Guo 等人^[19]使用三个不同的时空组件提取历史数据的信息,综合交通网络的图结构和交通数据的动态时空模式表征邻居节点与预测节点间的时空相关性,提出一种基于注意力机制的时空图卷积神经网络(ASTGCN);Song 等人^[20]利用三个连续时间片构建局部时空图,同时使用滑动窗口分割出不同的时间周期,堆叠多个图卷积层组成时空同步图卷积网络(STSGCN)提取长期时空相关性。

由于 T-GCN 使用两层图卷积网络聚合一阶和二阶邻居的空间信息,未深度挖掘高阶相邻节点间的空间相关性,所以利用能覆盖 k 阶邻居节点的 k 阶切比雪夫图卷积完成空间卷积操作,提取高阶邻居的空间相关性;此外,T-GCN 使用单一时间窗口的时间序列进行预测,未从不同时间窗口的角度挖掘时间依赖,因此本文分别提取周相关、日相关、相邻时间相关序列数据,并通过对时间序列进行语义编码和解码,以捕获时间相关性。

综上,本文提出多时空图卷积模型(multi-spatial-temporal graph convolutional network, MST-GCN),旨在从交通数据中获取复杂的时空特征,并应用到高速公路的交通流预测上。

1 相关工作

1.1 问题定义

本文主要针对路网交通流的单步预测问题,利用无向图 $G(V, E)$ 描述路网的拓扑结构,其中 V 为路网节点集合,节点之间的连接情况表示为边, E 为边的集合。

假设当前时刻为 t ,则 $t+1$ 时刻交通流的函数形式可以表示为

$$X_{t+1} = f(G; X_{t-T}, \dots, X_{t-1}, X_t) \quad (1)$$

其中: T 代表输入历史时间序列的长度; $X_t \in \mathbb{R}^{N \times M}$ 代表各个传感器在 t 时刻的交通信息, M 为交通信息的种类个数。

1.2 时间图卷积 T-GCN

T-GCN 模型由图卷积网络和门控循环单元组成,其前向传播过程如图 1 所示:a) 利用两层图卷积网络聚合一阶和二阶邻居的空间信息,捕捉交通流的空间相关性;b) 结合门控循环单元模型,通过单元之间的信息传递捕捉时间相关性;c) 通过全连接层得到预测结果。

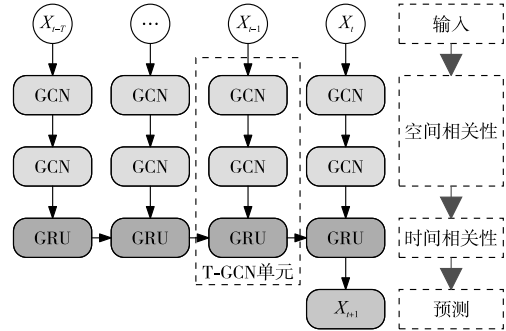


图1 T-GCN 前向传播过程

Fig. 1 T-GCN forward propagation process

T-GCN 单元的计算过程如图 2 所示,具体流程如下:

a) T-GCN 利用两层 GCN 捕捉交通流的空间相关性。

图卷积操作计算^[15]如下:

$$\text{gcn}(X) = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} X \theta \quad (2)$$

其中: $\tilde{A} = A + I$ 为添加自连接的邻接矩阵, $A, I \in \mathbb{R}^{N \times N}$; I 为单位矩阵; \tilde{D} 为 \tilde{A} 的度矩阵; X 代表模型输入的时空矩阵; θ 代表卷积核。




图2 T-GCN 单元

Fig. 2 T-GCN cell

T-GCN 对 t 时刻的输入 X_t 进行两次图卷积运算:

$$\text{gcn}_2(X_t) = \sigma(\text{gcn}(\text{relu}(\text{gcn}(X_t)))) \quad (3)$$

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (4)$$

$$\text{relu}(x) = \max(0, x) \quad (5)$$

其中: σ 为 sigmoid 函数; relu 为 ReLU 函数。两者都是非线性激活函数。

b) 结合门控循环单元模型,通过记忆单元之间的信息传递捕捉时间相关性。

$$u_t = \sigma(W_u [\text{gcn}_2(X_t), h_{t-1}] + b_u) \quad (6)$$

$$r_t = \sigma(W_r [\text{gcn}_2(X_t), h_{t-1}] + b_r) \quad (7)$$

$$c_t = \tanh(W_c [\text{gcn}_2(X_t), r_t * h_{t-1}] + b_c) \quad (8)$$

$$h_t = u_t * h_{t-1} + (1 - u_t) * c_t \quad (9)$$

其中: h_{t-1} 和 h_t 为 $t-1$ 时刻和 t 时刻隐藏层的输出; u_t 为 t 时刻的更新门; r_t 为 t 时刻的重置门; c_t 为 t 时刻的记忆单元; W 和 b 为训练过程中的参数; \tanh 为非线性激活函数。

GCN 是切比雪夫图卷积^[16]的一阶简化,忽略了一阶以上邻居节点间有效的空间信息。T-GCN 使用两次图卷积进行叠加,仅仅聚合了一阶和二阶邻居的空间信息,未深度挖掘高阶相邻节点间的空间相关性。因此本文利用 k 阶切比雪夫图卷积改进 T-GCN 单元的两层图卷积操作。

2 多时空图卷积 MST-GCN

2.1 空间相关性

GCN 是切比雪夫图卷积在 $k=1, \lambda_{\max}=2$ 时的推导结果, 由于切比雪夫图卷积的 k 阶卷积算子能覆盖 k 阶邻居节点, 所以 $k=1$ 表示 GCN 仅能够提取一阶邻居间的空间相关性, 忽略了一阶以上邻居节点间有效的空间信息。本文利用 k 阶切比雪夫图卷积改进 T-GCN 单元的两层图卷积操作, k 阶切比雪夫多项式函数形式为

$$\text{chebnet}(X) = \sigma\left(\sum_{k=0}^{k-1} \beta_k T_k(\tilde{L}) X\right) \quad (10)$$

$$T_k(\tilde{L}) = 2\tilde{L}T_{k-1}(\tilde{L}) - T_{k-2}(\tilde{L}) \quad (11)$$

$$\tilde{L} = \frac{2L}{\lambda_{\max}} - I_N \quad (12)$$

$$L = I - D^{-1/2} A D^{-1/2} \quad (13)$$

$$T_0(\tilde{L}) = I, T_1(\tilde{L}) = \tilde{L} \quad (14)$$

其中: L 为对称规范化的拉普拉斯矩阵, 由不添加自连接的邻接矩阵 A 和度矩阵 D 构成; λ_{\max} 为 L 的最大特征值; T_k 为 k 阶的切比雪夫多项式; β_k 是训练的权重参数, 与 T_k 构成卷积核。由于切比雪夫多项式的定义域在 $[-1, 1]$, 所以将 L 归一化为 \tilde{L} 。

切比雪夫图卷积的 k 阶卷积算子能够覆盖 k 阶邻居节点的特征, 通过调整 k 值, 改变卷积感受野范围, 能够确定有效的空间特征影响范围, 提高模型空间相关性挖掘的能力。

2.2 时间相关性

为捕获交通的时间动态相关性, 本文使用三个不同的时空组件提取交通历史数据特征。按照不同时间片类型划分输入数据, 选取最近 T_w 周、最近 T_d 日的相似时间间隔的时空数据 X_w 和 X_d , 与最近 T_m 个邻近时间间隔的时空数据 X_m 作为多源同构数据。

Y 为图 3 中黑色部分 (见电子版), 表示预测时段的交通流量值。

X_w 为周序列, 由最近 T_w 周中与预测时段相同的时间段组成, 它们具有与预测周期相同的周属性和时间间隔, 如图 3 蓝色部分所示 (见电子版)。通常, 在交通状况的变化趋势和峰值上, 工作日的交通流量与上一周工作日的交通流量具有一定的相似性, 并区别于非工作日。因此, 加入周相关数据以捕获工作日与非工作日的周期特征。

X_d 为日序列, 由最近 T_d 天中与预测时段相同的时间段组成, 如图 3 红色部分所示 (见电子版)。由于出行者的活动轨迹具有一定的规律性, 交通流呈现出周期性的波动, 例如工作日的早高峰和晚高峰可能具有相似的交通流量。因此, 加入日相关数据提取时空动态相关性。

X_m 为邻近序列, 是预测时段近期的一段历史时间序列, 时间步长为 T_m , 如图 3 绿色部分所示 (见电子版)。从宏观角度分析, 交通拥堵的形成和扩散是循序渐进的, 因此, 加入邻近时间的交通流以捕获交通流的变化趋势。




图 3 时间序列的输入与输出
Fig. 3 Input and output of time series

使用三个时空组件分别挖掘周相关、日相关、邻近时间的序列数据的时空相关性。如图 4 所示, 时空组件由一个切比雪夫图卷积模块、一个门控循环单元模块组成。首先, 利用切比雪夫图卷积对在空间维度上交通时空数据进行 k 次卷积操作, 并将卷积结果聚合, 得到 k 阶扩散后的节点信息; 其次, 使用门控循环单元在时间维度上挖掘交通流的周期性, 动态挖掘时间相关

性; 最后利用全连接对门控循环单元的输出规整化到预测维度。




图 4 时空组件

Fig. 4 Spatio-temporal component

2.3 多时空融合

本文采用三个时空组件与编码器—解码器网络结构融合构建多时空图卷积网络 (MST-GCN) 模型, 如图 5 所示。将周序列、日序列的两个时空组件作为周编码器和日编码器, 其输出 C_w 和 C_d 作为解码器记忆单元的初始值, 解码器以邻近序列作为输入, 输出为交通流量的预测值。




图 5 多时空图卷积模型

Fig. 5 Multi-spatial-temporal graph convolutional network

本文提出的 MST-GCN 模型分别提取周相关、日相关、邻近时间的交通流数据, 使用三个时空组件与编码器—解码器网络结构融合来深度挖掘不同时间窗口之间的周期性。其中, 为深度挖掘节点的时空相关性, 时空组件结合了切比雪夫图卷积和门控循环单元来获取更大的感受野。

3 实验

3.1 数据集

为评估模型性能, 利用 Caltrans 性能评估系统 (PeMS, <https://pems.dot.ca.gov>) 中高速公路数据集 PEMS04 和 PEMS08 进行分析。

PEMS04 为采集自旧金山湾的交通数据, 其中包含 29 条道路上的 3 848 个传感器, 选择其中 307 个传感器的数据进行预测。该数据集的时间跨度为 2018 年 1 月 1 日到 2 月 28 日, 共 59 天的数据。

PEMS08 为 2016 年 7 月 1 日至 8 月 31 日共 62 天圣贝纳迪诺的交通数据, 其中包含 8 条道路上的 1 979 个传感器, 选择其中 170 个传感器的数据进行预测。

3.2 预处理

PEMS04 和 PEMS08 均为每 5 min 聚合一次流量数据, 每个传感器每天包含 288 条数据记录, 每一条记录包含三个特征, 分别是该时间段响应传感器的交通流量、平均车辆速度和占有率。

以 6:2:2 的比例将时空数据划分为训练集、验证集和测试集。同时对每一个特征进行极差归一化, 将数据保持在 $[0, 1]$, 具体计算公式如下:

$$x^* = \frac{x - \min}{\max - \min} \quad (15)$$

通过利用传感器之间的距离, 使用阈值高斯核^[21]建立图的邻接矩阵 A , 阈值高斯核的计算过程如下:

$$W_{ij} = \begin{cases} e^{-\frac{\text{dist}(v_i, v_j)^2}{\sigma^2}} & \text{dist}(v_i, v_j) < s \\ 0 & \text{dist}(v_i, v_j) \geq s \end{cases} \quad (16)$$

其中: W_{ij} 代表传感器 v_i 到传感器 v_j 之间边的权重; $\text{dist}(v_i, v_j)$ 表示传感器 v_i 与 v_j 之间的距离; σ^2 是距离的方差; s 是阈值。由于数据集中没有超过 1 000 m 的传感器,所以阈值 s 取 1 000。

3.3 评估指标

本文使用三个度量函数来评估 MST-GCN 模型的预测效果,分别是平均绝对误差(mean absolute error, MAE)、均方根误差(root mean square error, RMSE)和平均绝对百分比误差(mean absolute percentage error, MAPE):

$$MAE = \frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N |y_j^i - \hat{y}_j^i| \quad (17)$$

$$RMSE = \sqrt{\frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N (y_j^i - \hat{y}_j^i)^2} \quad (18)$$

$$MAPE = \frac{1}{M} \sum_{i=1}^M \sum_{j=1}^N \left| \frac{y_j^i - \hat{y}_j^i}{y_j^i} \right| \quad (19)$$

其中: y_j^i 和 \hat{y}_j^i 代表第 i 个样本中第 j 条道路的实际交通流和预测交通流; M 代表样本数; N 代表道路数; \bar{y} 是样本集的平均值。

3.4 实验参数设置

为验证模型的有效性,将本文提出的 MST-GCN 模型和经典的 GRU 模型、近期提出的 DCRNN、T-GCN、ASTGCN、STSGCN 模型进行对比。

表 1 为各个模型的超参数设置。其中, layers 表示隐藏层数, units 代表每个隐藏层的计算单元个数, 实验中所有模型隐藏层使用相同个数的计算单元, k 表示时空组件中图卷积的阶数, T_w 和 T_d 为周序列和日序列长度, T_m 为邻近序列长度, 也可以看做时间序列模型的时间步长。

表 1 不同模型超参数设置

Tab. 1 Hyperparameter settings for different models

model	layers	units	k	T_w	T_d	T_m
GRU	3	500	×	×	×	8
DCRNN	2	64	3	×	×	8
TGCN	3	64	2	×	×	8
ASTGCN	2	64	3	24	12	24
STSGCN	4	64	3	×	×	12
MST-GCN	3	64	3	2	6	8

3.5 实验结果

实验结果如表 2 所示。在 PEMS08 数据集中, MST-GCN 模型在精度上始终优于其他基准模型。在 PEMS04 数据集中, MST-GCN 有最小的 MAE 和 MAPE, RMSE 略大于 STSGCN。以 MAPE 为评价指标, MST-GCN 相比 GRU 平均提升 23.48%, 相比 DCRNN 提升 13.61%, 相比 T-GCN 提升 21.29%, 相比 ASTGCN 提升 24.39%, 相比 STSGCN 提升 5.06%。

表 2 不同模型交通流量预测的性能比较

Tab. 2 Performance comparison of different models of traffic flow prediction

model	PEMS04			PEMS08		
	MAE	RMSE	MAPE/%	MAE	RMSE	MAPE/%
GRU	24.38	40.51	16.29	19.07	35.83	13.09
DCRNN	24.48	38.43	15.33	19.46	31.70	11.80
T-GCN	25.79	43.15	16.94	24.22	35.84	12.19
ASTGCN	22.93	35.22	16.56	18.61	28.16	13.08
STSGCN	22.56	33.58	14.11	17.13	26.80	10.96
MST-GCN	22.19	33.90	14.05	15.74	23.67	9.99

图 6 和 7 分别展示两个数据集使用不同模型的预测结果。GRU 仅考虑时间相关性,未利用路网的空间相关性,因此 GRU 的精度不及利用时空相关性的方法;DCRNN 和 T-GCN 模型分别对空间相关性和时间相关性进行建模,然而它们仅利用单一时间窗口来提取长时依赖,忽略了不同时间窗口的周期性;ASTGCN 和 STSGCN 均使用不同的时空组件对时间窗口提取

时空相关性,然而它们忽略了不同时间窗口之间的有序性,因此捕捉时空长时依赖的性能就会相对降低。本文的 MST-GCN 方法考虑了不同时间窗口之间的有序性,利用编码器—解码器结构对时空组件进行融合,来捕获不同时间窗口之间的时空长时依赖。因此,本文模型在预测精度上均优于现有模型,取得了较好的预测效果。




图 6 PEMS04 数据集使用不同模型的预测效果

Fig. 6 Prediction effect of PEMS04 dataset using different models




图 7 PEMS08 数据集使用不同模型的预测效果

Fig. 7 Prediction effect of PEMS08 dataset using different models

此外,实验还比较 MST-GCN 随着超参数变化的性能变化情况,包括图卷积的阶数 k 、周序列长度 T_w 、日序列长度 T_d 及邻近序列长度 T_m (即时间步长)。实验结果如图 8 所示,图卷积的阶数和邻近序列长度对预测结果影响较大,而周序列长度 T_w 和日序列长度 T_d 影响相对较小。因此,选定 $k=3$, $T_w=2$, $T_d=6$, $T_m=8$ 为最佳参数配置。

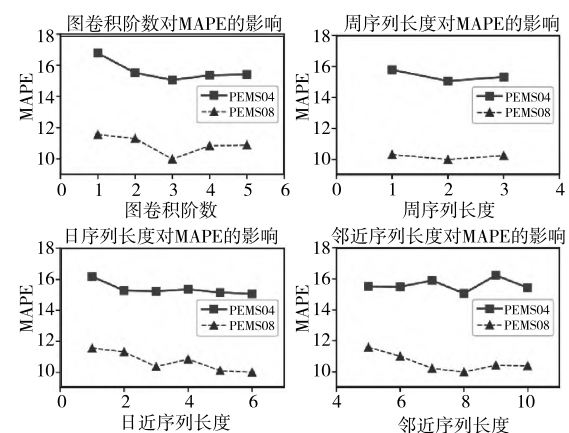


图 8 不同超参数在 PEMS04 和 PEMS08 数据集上的预测效果

Fig. 8 Prediction effect of different hyperparameters on the PEMS04 and PEMS08 datasets

4 结束语

针对使用时空数据进行交通流预测建模的问题,本文提出

一种多时空图卷积网络模型(MST-GCN)来捕获时空依赖关系。首先,为深度挖掘节点的时空相关性,结合切比雪夫图卷积和门控循环单元获取更大的感受野;其次,分别提取周相关、日相关、邻近时间的序列数据,使用三个时空组件来深度挖掘不同时间窗口的周期性;最后,将多个时空组件与编码器—解码器网络结构融合组建 MST-GCN 模型。利用 Caltrans 性能评估系统中的高速公路数据集 PEMS04 和 PEMS08 进行实验,结果表明新模型的性能明显优于其他模型,可以应用于实际路网提高交通路网的通行效率。下一步研究将收集城市路网的数据集,探索模型在复杂城市路网下的适应能力。

参考文献:

- [1] Vlahogianni E I, Karlaftis M G, Golias J C. Short-term traffic forecasting: where we are and where we're going[J]. *Transportation Research, Part C: Emerging Technologies*, 2014, 43: 3-19.
- [2] 韩超,宋苏,王成红. 基于 ARIMA 模型的短时交通流实时自适应预测[J]. *系统仿真学报*, 2004, 16(7): 1530-1532, 1535. (Han Chao, Song Su, Wang Chenghong. Real-time adaptive prediction of short-term traffic flow based on ARIMA model[J]. *Journal of System Simulation*, 2004, 16(7): 1530-1532, 1535.)
- [3] Kumar S V. Traffic flow prediction using Kalman filtering technique[J]. *Procedia Engineering*, 2017, 187: 582-587.
- [4] 沈琴琴,王玥,黄悦,等. 改进初值的灰色 Verhulst-Markov 模型及其应用[J]. *统计与决策*, 2020, 36(7): 30-33. (Shen Qinqin, Wang Yue, Huang Yue, et al. Grey Verhulst-Markov model with improved initial value and its application[J]. *Statistics and Decision*, 2020, 36(7): 30-33.)
- [5] Feng Xinxin, Ling Xianhao, Zheng Haifeng, et al. Adaptive multi-kernel SVM with spatial-temporal correlation for short-term traffic flow prediction[J]. *IEEE Trans on Intelligent Transportation Systems*, 2018, 20(6): 2001-2013.
- [6] 张涛,陈先,谢美萍,等. 基于 K 近邻非参数回归的短时交通流预测方法[J]. *系统工程理论与实践*, 2010, 30(2): 376-384. (Zhang Tao, Chen Xian, Xie Meiping, et al. Short-term traffic flow prediction method based on nonparametric regression of K-nearest neighbors[J]. *Systems Engineering Theory and Practice*, 2010, 30(2): 376-384.)
- [7] 王建,邓卫,赵金宝. 基于贝叶斯网络多方法组合的短时交通流预测[J]. *交通运输系统工程与信息*, 2011, 11(4): 147-153. (Wang Jian, Deng Wei, Zhao Jinbao. Short-term traffic flow forecast based on Bayesian network multi-method combination[J]. *Transportation Systems Engineering and Information*, 2011, 11(4): 147-153.)
- [8] Do L N N, Taherifar N, Vu H L. Survey of neural network-based models for short-term traffic state prediction[J]. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 2019, 9(1): e1285.
- [9] Ma Xiaolei, Tao Zhimin, Wang Yin Hai, et al. Long short-term memory neural network for traffic speed prediction using remote microwave sensor data[J]. *Transportation Research, Part C: Emerging Technologies*, 2015, 54: 187-197.
- [10] Fu Rui, Zhang Zuo, Li Li. Using LSTM and GRU neural network methods for traffic flow prediction[C]//Proc of the 31st Youth Academic Annual Conference of Chinese Association of Automation. 2016: 324-328.
- [11] 谷远利,陆文琦,李萌,等. 基于组合深度学习的快速路车道级速度预测研究[J]. *交通运输系统工程与信息*, 2019, 19(4): 79-86. (Gu Yuanli, Lu Wenqi, Li Meng, et al. Research on expressway lane-level speed prediction based on combined deep learning[J]. *Transportation Systems Engineering and Information*, 2019, 19(4): 79-86.)
- [12] Lin Zhihui, Li Maomao, Zheng Zhuobin, et al. Self-attention ConvLSTM for spatio-temporal prediction[C]//Proc of the 34th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2020: 11531-11538.
- [13] 包银鑫,曹阳,施俊. 基于改进时空残差卷积神经网络的城市路网短时交通流预测[J]. *计算机应用*, 2022, 42(1): 258-264. (Bao Yinxin, Cao Yang, Shi Quan. Urban road network short-term traffic flow prediction based on improved spatio-temporal residual convolutional neural network[J]. *Journal of Computer Applications*, 2022, 42(1): 258-264.)
- [14] Bruna J, Zaremba W, Szlam A, et al. Spectral networks and locally connected networks on graphs[C]//Proc of the 2nd International Conference on Learning Representations. 2014.
- [15] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[C]//Proc of the 5th International Conference on Learning Representations. 2017.
- [16] Defferrard M, Bresson X, Vandergheynst P. Convolutional neural networks on graphs with fast localized spectral filtering[C]//Advances in Neural Information Processing Systems. 2016: 3844-3852.
- [17] Li Yaguang, Yu Rose, Cyrus S, et al. Diffusion convolutional recurrent neural network: data-driven traffic forecasting[C]//Proc of the 6th International Conference on Learning Representations. 2018.
- [18] Zhao Ling, Song Yujiao, Zhang Chao, et al. T-GCN: a temporal graph convolutional network for traffic prediction[J]. *IEEE Trans on Intelligent Transportation Systems*, 2019, 21(9): 3848-3858.
- [19] Guo Shengnan, Lin Youfang, Feng Ning, et al. Attention based spatial-temporal graph convolutional networks for traffic flow forecasting[C]//Proc of the 33rd AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2019: 922-929.
- [20] Song Chao, Lin Youfang, Guo Shengnan, et al. Spatial-temporal synchronous graph convolutional networks: a new framework for spatial-temporal network data forecasting[C]//Proc of the 34th AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2020: 914-921.
- [21] Shuman D I, Narang S K, Frossard P, et al. The emerging field of signal processing on graphs: extending high-dimensional data analysis to networks and other irregular domains[J]. *IEEE Signal Processing Magazine*, 2013, 30(3): 83-98.

下期要目

- ◆ 基于机器学习的 SDN 流量工程研究综述
- ◆ 航空制造知识图谱构建研究综述
- ◆ 基于机器学习的时尚穿搭推荐研究综述
- ◆ 一种基于区块链和密文属性加密的访问控制方案
- ◆ 基于链上数据的区块链欺诈账户检测研究
- ◆ 基于 LASSO-MIDAS 模型的混频时间序列预测研究
- ◆ 于特征点界标过滤的时间序列模式匹配方法
- ◆ 基于时间加权改进的 LDTW 算法
- ◆ 基于可区分度的连续空间属性约简算法研究

- ◆ 类中心极大的多视角极大熵聚类算法
- ◆ 基于动态二分网络表示学习的推荐方法
- ◆ 基于双向映射学习的多标签分类算法
- ◆ 基于结构性质保持和相关性学习的多标记分类算法
- ◆ NEMTF: 一种基于多维度文本特征的新闻网页信息提取方法
- ◆ MASGC: 融合特定屏蔽机制的简单图卷积情感分析模型
- ◆ 考虑群组结构的在线社交网络竞争性舆情信息传播模型研究
- ◆ 融合高低层语义信息的自然语言句子匹配方法
- ◆ 句子级状态下 LSTM 对谣言鉴别的研究
- ◆ 基于自编码神经网络的半监督联邦学习模型