

文章编号:1671-1637(2023)03-0044-24

## 基于机器学习的交通流预测方法综述

姚俊峰<sup>1,2</sup>, 何 瑞<sup>3</sup>, 史童童<sup>3</sup>, 王 萍<sup>4</sup>, 赵祥模<sup>1,5</sup>

(1. 长安大学 信息工程学院, 陕西 西安 710064; 2. 中国交通信息科技集团有限公司, 北京 101399;  
3. 长安大学 电子与控制工程学院, 陕西 西安 710064; 4. 中山大学 智能工程学院,  
广东 深圳 518107; 5. 西安工业大学 电子信息工程学院, 陕西 西安 710021)

**摘要:**通过文献梳理、专家访谈和试验场景构建等方法,分析了道路指定断面和区域路网宏观交通流预测的国内外研究现状和发展趋势,归纳了局部断面交通流预测方法,包括传统机器学习、递归神经网络和混合模型,分析了卷积神经网络、图神经网络和融合多因素网络的特点,阐述了方法的原理、优势、局限性和应用场景,总结了现有场景交通数据集类别,从采样周期与采集方式角度归纳了国内外主流交通数据集。分析结果表明:递归神经网络可以有效获取交通数据的历史规律,但存在梯度爆炸、计算复杂度高、长时预测准确度不佳等问题;图神经网络针对路网拓扑连接关系引入了图结构,在考虑路网和交通流数据的时空相关性上具有明显优势;融合多因素网络充分考虑天气、道路、事故等内外部因素的影响,有效提升了交通流预测的实时性和鲁棒性;由于交通数据采集困难、外部因素影响难以量化、机器学习方法可解释性差等原因,交通流预测方法的改进受到了限制;未来应从交通信息有效挖掘和图卷积方法完善两方面入手,拓宽图结构在交通领域的应用和考虑非常态交通场景,进一步揭示交通数据的内在规律,开发更准确、高效的交通流预测方法,推动交通流预测在工业界的落地应用。

**关键词:**智能交通系统;交通流预测;机器学习;图卷积网络;混合模型;交通数据集

**中图分类号:**U495 **文献标志码:**A **DOI:**10.19818/j.cnki.1671-1637.2023.03.003

## Review on machine learning-based traffic flow prediction methods

YAO Jun-feng<sup>1,2</sup>, HE Rui<sup>3</sup>, SHI Tong-tong<sup>3</sup>, WANG Ping<sup>4</sup>, ZHAO Xiang-mo<sup>1,5</sup>

(1. School of Information Engineering, Chang'an University, Xi'an 710064, Shaanxi, China; 2. China Communications Information Technology Group Co., Ltd., Beijing 101399, China; 3. School of Electronics and Control Engineering, Chang'an University, Xi'an 710064, Shaanxi, China; 4. School of Intelligent Systems Engineering, Sun Yat-Sen University, Shenzhen 518107, Guangdong, China; 5. School of Electronic Information Engineering, Xi'an Technological University, Xi'an 710021, Shaanxi, China)

**Abstract:** The research status and development trend of macro traffic flow prediction of designated road sections and regional road network at home and abroad were analyzed by literature review, expert interview, and experimental scenario construction. Local section traffic flow prediction methods were summarized, including traditional machine learning, recurrent neural networks,

收稿日期:2022-12-15

基金项目:国家重点研发计划(2021YFC3001003);广东省科技计划项目(2017B030314076)

作者简介:姚俊峰(1978-),男,山西晋城人,中国交通信息科技集团有限公司高级工程师,长安大学工学博士研究生,从事交通信息工程及控制研究。

导师简介:赵祥模(1966-),男,重庆人,长安大学教授,工学博士。

通讯作者:王 萍(1982-),女,山东泰安人,中山大学副教授,工学博士。

引用格式:姚俊峰,何 瑞,史童童,等. 基于机器学习的交通流预测方法综述[J]. 交通运输工程学报, 2023, 23(3): 44-67.

Citation: YAO Jun-feng, HE Rui, SHI Tong-tong, et al. Review on machine learning-based traffic flow prediction methods[J]. Journal of Traffic and Transportation Engineering, 2023, 23(3): 44-67.

and hybrid models. The characteristics of convolutional neural networks, graph neural networks, and fusion multi-factor networks were discussed. The principles, advantages, limitations, and application scenarios of the methods were explained. The types of existing scenario traffic datasets and the mainstream traffic datasets at home and abroad were summarized from the perspectives of sampling periods and collecting methods. Analysis results show that recurrent neural networks can effectively obtain the historical laws of traffic data, but there are some problems such as gradient explosion, high computational complexity, and poor accuracy of long-time prediction. Graph neural networks introduce graph structures for road network topological connection relationships, which has obvious advantage in considering the spatiotemporal correlation of road network and traffic flow data. Fusion multi-factor methods fully consider the influence of internal and external factors such as weather, roads, and accidents, effectively improving the real-time performance and robustness of traffic flow prediction. The improvements of traffic flow prediction methods have limitations due to the difficult traffic data collection and external factor influence quantification, as well as the poor interpretability of machine learning methods. The future research should start from two aspects of starting the efficient mining of traffic information and the perfection of graph convolution methods, broaden the application of graph structures in the traffic field, and consider non-constant traffic scenarios. So as to further reveal the inherent laws of traffic data, develop more accurate and efficient traffic flow prediction methods, and promote the application of traffic flow prediction in industry. 4 tabs, 18 figs, 108 refs.

**Key words:** intelligent transportation system; traffic flow predication; machine learning; graph convolutional network; hybrid model; traffic dataset

**Author resumes:** YAO Jun-feng(1978-), male, senior engineer, doctoral student, jtbyaojf@126.com; ZHAO Xiang-mo(1966-), male, professor, PhD, xmzhao@chd.edu.cn; WANG Ping(1982-), female, associate professor, PhD, wangp358@mail.sysu.edu.cn.

**Foundation items:** National Key Research and Development Program of China(2021YFC3001003); Science and Technology Plan Project of Guangdong Province(2017B030314076)

## 0 引言

随着城市化进程的加快以及人均车辆保有率的不断提升,交通堵塞和交通事故已成为全球性问题,无论是发达国家还是发展中国家,现有交通系统都不可避免地存在着交通拥堵频繁、交通事故严重、交通环境污染等问题。为了应对这些挑战,许多城市致力于研究更高效的交通管理策略、更合理的交通资源分配和更优质的交通服务,特别是更精细的交通控制与诱导系统是智能交通系统(Intelligent Transportation System, ITS)研究的关键环节。其中,实时准确的交通状态感知和预测是实现智能交通系统的重要环节,提前预测未来交通状态可以为交通系统管理和规划提供科学依据<sup>[1]</sup>,交通管理部门以此制定更加灵活的交通控制策略,提前部署交通资源和引导交通流量,从而减少大规模交通拥堵现象<sup>[2]</sup>;交通规划部门可以有科学根据地进行道路改

造与匝道设计,合理地部署红绿灯、交通监控、交通标志标牌等交通设施<sup>[3]</sup>;出行者基于准确的交通状态预测信息可进行最优出行路径和出行方案的制定。

快速发展的机器学习技术在智能交通系统中的出色表现受到了研究人员的广泛关注<sup>[4]</sup>。在交通流预测中,传统方法主要基于数理统计分析交通状况演化的周期性来处理交通流预测问题。然而,由于数据时间序列分布的随机干扰波动,限制了非线性交通流的高度可表达性,无法直接建模时间序列中交通数据的各种依赖关系。基于机器学习的交通流预测方法可以有效处理流量数据的复杂非线性问题,并且综合考虑交通流量数据的历史规律性和路网的空间相关性,具有较好的预测性能。目前,基于机器学习的交通流预测已经成为该领域的研究热点。

本文综述了机器学习在交通流预测领域的研究进展与未来发展方向。以预测空间范围为依据对目前的交通流预测方法进行分类,重点分析了单一道

路断面和区域路网交通流预测的国内外研究现状,从原理、优势、局限性、应用场景和后续应用多个角度进行了阐述;从采样周期与采集方式角度归纳了国内外主流交通数据集,对自建数据集,按照异常数据处理、缺失数据处理、数据标准化顺序对数据处理的主流方法进行了概括;针对当前相关论文同质化现象进行了解释,讨论了交通数据应用领域存在的困难和挑战,展望了未来交通流预测的主流发展方向。

## 1 交通流预测方法

交通流预测是利用历史和实时交通数据信息来预测未来一段时间内指定道路或区域的交通状况,预测内容一般包括交通流量、速度、密度(或占有率)、行程时间等反映交通状态的变量。其中,单位时间内通过某断面交通流量的统计和计算最为常用。根据交通流预测的实际场景,可以分为高峰期预测、正常期预测和异常情况下的预测;根据预测的周期,交通流预测可分为短时、中时、长时预测<sup>[5]</sup>,时间间隔定义在 5~15 min 内为短时预测,15~45 min 内为中时预测,45 min 以上则为长时预测。其中,短时交通流预测研究历史较长,成果显著。近些年,研究人员已不局限于短时预测,正致力于尽可能延长预测时长并保持其准确率。

交通流预测是一个不确定、时变、非线性的复杂系统问题,易受偶发事件、节假日和天气等因素的影响,且预测误差也会随着预测时长的增加而逐渐变大。此外,如果只考虑目标监测点的交通状况,而忽略上下游若干时刻的交通状况和相邻路段间的影响,预测结果与现实交通状况往往具有较大偏差<sup>[6]</sup>。目前,考虑空间关系的区域交通流预测方法,捕获固定图结构的空间依赖性,即构建空间信息的邻接矩阵,一般是基于距离特征或监测点间关联性,且假设实体之间的底层关系是预先确定的。然而,固定图结构(关系)难以完全反映真实空间时变特征,并且实测数据的完整性难以保证,导致真实的关系缺失,无法精确地捕捉数据中隐藏的空间依赖性<sup>[7]</sup>。同时,天气、道路环境、能见度等变化以及交通事故、自然灾害等一些无法控制的外部因素同样给交通流的研究带来了极大挑战。

交通流预测问题的划分也体现了交通流预测方法对异常情况下的实时性、准确性和可靠性的要求<sup>[8]</sup>。与其他时间序列预测问题不同,交通流预测的主要挑战在于复杂的耦合关系,包括路网结构的拓扑连接及其不断变化的时空特征;在时间上,交通

数据具有较强的时变性和周期性,如早高峰晚高峰、周中周末等;在空间上,路网中相邻节点之间具有很强的相关性,直接相互影响,非相邻节点也具有基于交通流模式的起点-终点(Origin-Destination, OD)的隐式空间相关性。基于机器学习的交通流预测问题可以分为 2 类,分别是断面交通流预测和区域交通流预测,断面交通流预测包含了传统机器学习方法、递归神经网络和混合方法,区域交通流预测包含了卷积神经网络、图卷积神经网络和融合多因素方法。

### 1.1 断面交通流预测方法

20 世纪 80 年代初,短时交通流预测开始出现,此后一直是交通领域研究的热点之一。起初,交通流预测一直局限于单一道路断面短时交通流预测,即预测当前检测点未来一段时间的交通数据,如图 1 所示,展示了陕西省西安市某指定断面的交通流量情况。本文将主流的研究方法分为 3 类,分别是基于传统机器学习、递归神经网络和混合模型的交通流预测。



图 1 陕西省西安市某指定断面交通流

Fig. 1 Traffic flow at a designated section in Xi'an Shaanxi Province

#### 1.1.1 基于传统机器学习的交通流预测方法

为了应对交通流预测任务的非线性问题,机器学习方法受到关注。它适合不确定性、非线性的动态系统,无需参数,可移植,预测精度高,且误差分布情况良好,适用于不需先验知识、只需足够的历史数据的情况,能够对非线性的交通数据进行建模,并提取更复杂的相关性。

传统的机器学习方法在交通预测领域的应用可分为 3 类:基于特征提取方法、基于高斯过程回归方法和基于状态空间方法。其中基于特征提取的机器学习方法常被用于交通流预测问题<sup>[9]</sup>,核心是训练使用统计学知识和交通特征建立的回归方法,局限



性在于需要人工建立回归方程,方法的性能很大程度上取决于回归分析的准确度;高斯过程回归<sup>[10]</sup>包含对交通特征时空特性的处理,但需要大量计算负荷,难以训练大量数据;状态空间方法<sup>[11]</sup>利用马尔可夫隐含状态模拟了系统的不确定性,但在建模复杂系统和模拟动态流量时作用有限。

基于传统机器学习的交通流预测问题的经典方法有K-最近邻(K-Nearest Neighbor, K-NN)方法<sup>[12]</sup>、支持向量机(Support Vector Machine, SVM)<sup>[13]</sup>和贝叶斯网络<sup>[14]</sup>等。

K-NN方法是一种有监督的机器学习方法,可以识别行为与当前交通状况相似的数据簇,尤其适用于交通拥堵的情况。基于K-NN方法的交通流预测方法可以分为3个基本组成部分,即历史观测数据库、邻域搜索程序和预测函数,其内部的数据流传递关系如图2所示<sup>[15]</sup>。




图2 K-NN方法内部数据流传递关系

Fig. 2 Transfer relationship of internal data flow in K-NN method

基于K-NN的预测方法可以从历史数据库中定位大量观测值(也称为最近邻),然后基于该最近邻集预测未来的数据。Gong等<sup>[15]</sup>针对交通研究了基于自关联分析和关联分析的有效交通状态向量选择方法,提出基于K-NN方法在北京市某高速公路数据集中取得了不错的预测精度。K-NN方法由于其无需参数估计和预先训练的特点,在简单场景下有着较好的预测效果,然而K值(最近邻居的数量)的选取并不固定,不能应对差异度较大的交通场景,并且K-NN方法的预测结果受观测值的影响较大,当观测数据库中出现噪声数据和训练样本划分不当时预测效果较差。在实际应用中,由于K-NN方法的非稀疏性,需要对所有样本进行计算,有着较大的内存消耗和计算复杂度,并不适用于基于大数据的实时交通场景。

相较于非稀疏性的K-NN方法,SVM是一种具有稀疏非线性核的学习方法,其优点在于具有良好的泛化能力,避免了过度拟合带来的一些问题,能够准确预测城市短期交通流量。基于SVM的交通流预测方法可以分为4步,第1步利用非线性映射

函数将输入的交通流训练数据映射到高维特征空间,第2步确定SVM的学习目标,第3步引入拉格朗日乘子得到拉格朗日函数,并将其转化为凸二次规划问题,第4步输出预测数据。SVM方法有着坚实的理论基础,并且由于SVM的最终决策函数只由少数决策向量决定,可以有效避免“维度灾难”,在解决小样本场景和高维特征问题上有着独到优势,但SVM方法需要预先进行训练,在大规模数据集上计算复杂度较高,除此以外,参数设定也直接影响到训练结果。Tong等<sup>[16]</sup>将粒子群优化方法应用于SVM的参数优化,提高了系统的优化性能,因此,在大规模动态交通场景中,如何有效优化参数、降低计算复杂度是SVM方法未来的研究方向。

贝叶斯网络是一种基于因果方法的学习方法,优点在于在统计上充分考虑了随机变量之间的因果关系,因此,可以对上下游路段之间的交通流进行建模和分析,从贝叶斯网络的角度出发,对象节点的值可以由其相邻节点推断。此外,基于贝叶斯网络的消息传递机制,可以在交通数据不完整的情况下进行预测。Sun等<sup>[17]</sup>所提出的基于贝叶斯网络的交通流预测方法可以实现突发事故情况下的交通流预测。贝叶斯方法在小样本交通数据集和突发事故场景中有着极高的应用潜力,然而,贝叶斯方法学习过程中需要求解积分,在面对大数据场景时,难以避免较高的计算复杂度。

基于传统机器学习方法虽然可以处理流量预测中的非线性和不规则性,但在特征提取层面依然执行的是浅层学习,并且需要对交通数据做简单变换。随着城市交通网络的数据量和数据维度呈爆炸式增长,上述技术无法完成需要精细特征表示的复杂交通流预测任务。

### 1.1.2 基于递归神经网络的交通流预测方法

随着ITS的快速发展,对大量交通数据和多源环境数据的收集将得到进一步实现。基于传统机器学习方法的低效训练策略和浅层结构无法应对海量数据,往往会忽略其他影响因素,多源数据融合预测的优势更得不到体现且优化困难。自20世纪90年代以来神经网络方法在交通工程领域被逐渐应用,尤其在短期交通流预测方面得到极大关注<sup>[18]</sup>。神经网络方法被证实适合用于描述交通系统的复杂非线性特征<sup>[19]</sup>。Vythoulkas<sup>[20]</sup>首次提出用系统识别和人工神经网络进行城市道路网络交通状态的预测;Hua等<sup>[21]</sup>评价了神经网络在智能交通领域的应用潜力,提出神经网络是智能交通系统最需要的工

具,在实时交通流预测中,神经网络要比其他方法优越。从此,神经网络被广泛用于解决交通流预测问题,并且被视为交通工程中的一种通用模式。其原理主要为:用一部分数据训练方法,即确定网络结构(包括隐含层数、各层节点数、连接权值、神经元的传递函数),随后用剩余部分数据进行预测。

起初,研究人员利用基于序列预测的递归神经网络(Recurrent Neural Network, RNN)来预测交通流量。RNN 是一种广泛应用于交通流预测的方法,可以发现隐藏在数据中的特征,以预测时空信息<sup>[22]</sup>。RNN 与前馈神经网络(Feedforward Neural Network, FNN)类似,基本的 RNN 由输入层、隐藏层和输出层构成。RNN 和 FNN 的区别在于隐藏层,在 FNN 中将信息传递给输出层,而在 RNN 中,信息还将传输回自身,形成循环,因此,RNN 中的隐藏层被称为递归隐藏层。RNN 能够记住每一时刻的信息,且每一时刻的隐藏层不仅由该时刻的输入层决定,还由上一时刻的隐藏层决定,这种循环促使了历史信息的保留,使 RNN 能够处理时间序列数

据。RNN 在各个领域都有广泛的应用,其本身也不断被改进,衍生出了多种类别的 RNN 方法,主要分为单隐层、多隐层和双向 RNN 等。图 3<sup>[22]</sup>展示了单隐层 RNN 的折叠和展开结构,其中  $X_t$  为  $t$  时刻的输入数据, $U_t$  为输入层和隐藏层之间的权重, $Y_t$  为  $t$  时刻的输出数据, $W_t$  为隐藏层之间的权重, $V_t$  为隐藏层和输出层之间的权重, $S_t$  为隐藏层的记忆状态。

虽然隐藏状态使 RNN 能够在过去的时间步长中记忆输入信息,但也在序列上引入了矩阵乘法。矩阵乘法中的较小值使梯度在每个时间步长都减小,导致最终消失的现象;相反,较大值会导致梯度爆炸问题。消失或爆炸的梯度阻碍了 RNN 学习数据中长期序列依赖关系的能力。为解决这些问题,研究人员转向了基于 RNN 方法的长短期记忆(Long Short-Term Memory, LSTM)网络和门控递归单元(Gated Recurrent Unit, GRU)方法的研究,这些都是作为短期记忆和梯度问题的良好解决方案,LSTM 和 GRU 方法的网络结构如图 4 所示<sup>[23]</sup>,其中  $H_t$  为  $t$  时刻的隐藏层输出。




图 3 RNN 的折叠和展开结构

Fig. 3 Folding and unfolding structures of RNN

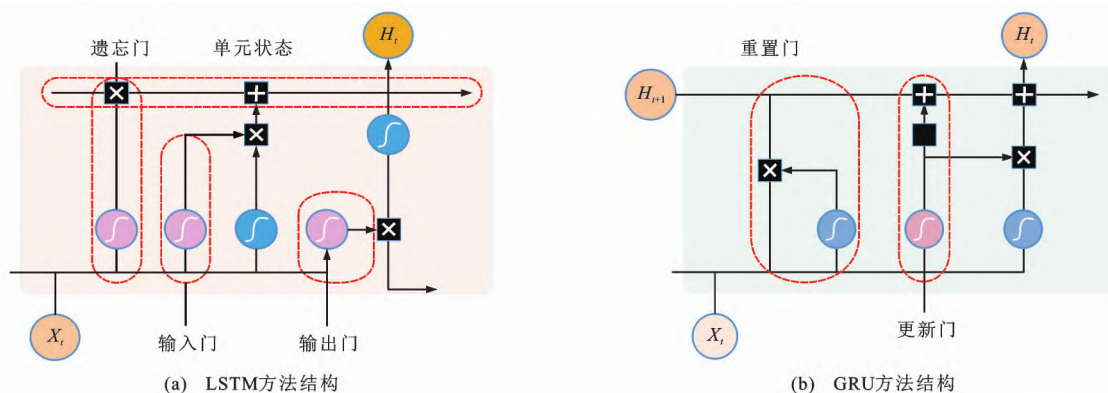


图 4 LSTM 和 GRU 网络结构

Fig. 4 Network structures of LSTM and GRU

相对于 RNN, LSTM 有了改进的结构,由输入门、输出门、遗忘门和存储单元组成,这些门和存储单元使其可以学习输入数据之间长期依赖的关系。LSTM 主要有 2 点改进:设置专门的变量  $H_t$  来存

储  $t$  时刻的单元状态,作为下一时刻的输入,从而使网络具有长期记忆;引入“门运算”,将梯度中的累乘变为累加,解决了梯度消失问题。Ma 等<sup>[24]</sup>肯定了 LSTM 方法在交通流预测领域的有效性,然而,虽

然 LSTM 在避免梯度消失或爆炸方面表现出色,但其结构复杂导致了更多的内存需求和更长的训练时间;Chung 等<sup>[25]</sup>提出了一个简单而强大的 LSTM 变体,即 GRU,其结构更为简单,方法中只有 2 个门:更新门和重置门,更新门是输入门和遗忘门的合并,用于控制前一时刻的状态信息被带入到当前状态中的程度,重置门则控制前一状态有多少信息被写入到当前的候选集上;Fu 等<sup>[26]</sup>使用基本 LSTM 和 GRU 预测交通流,结果表明:在交通流预测方面 GRU 性能要优于 LSTM。

RNN、LSTM 和 GRU 作为常用的深度学习方法,在各个领域应用广泛,尤其在交通流预测领域获得了极大的关注,在提取时序特征方面优势明显,目前仍然是主流方法,后续许多方法均由 RNN 及其变体方法衍生或结合而来,如图 5 所示。Zhao 等<sup>[27]</sup>提出了一种由多个存储单元构成的二维 LSTM 网络,用于从原始目的地相关矩阵中捕获时域和空域的相关性,该 LSTM 变体可以更全面地考虑路网时空特性,取得更好的预测结果。

此后,针对城市路网的突发情况和不确定性,Zhu 等<sup>[28]</sup>利用蒙特卡罗 (Monte Carlo, MC) 丢失法和固有噪声估计,给出了一种为神经网络预测提供不确定性估计的简单方法,并利用 2 层编码器预训练的 LSTM 网络实现城市交通信息预测,试验表明,该方法可以有效预测特殊时期的路网流量。针对路网数据的缺失问题,Tian 等<sup>[29]</sup>提出了考虑缺失数据的长短期记忆 (LSTM-Missing Data, LSTM-M) 网络,通过将缺失的交通模式与掩蔽向量显式结合来推断交通流;Pan 等<sup>[30]</sup>利用 GRU 编码历史流量数据以及基于元学习的递归神经网络 (Meta Learning-RNN, Meta-RNN) 提取节点信息的城市交通流预测网络。在迁移学习领域,Deshpande 等<sup>[31]</sup>建立类似 RNN 的更新操作来适应时序数据的自适应循环单元,不仅在交通流预测数据集中取得了较好的预测效果,也可以拓展到其他领域。近年来,Yang 等<sup>[32]</sup>提出了一种改进的 LSTM 解决方案,通过集成注意力机制来捕获高影响历史数据,以增强特征。



图 5 基于递归神经网络的交通流预测主流方法

Fig. 5 Mainstream methods of traffic flow prediction based on recurrent neural network

基于 RNN 体系的预测方法在短期交通流预测问题上表现较好,可以有效建模交通数据的时间依赖性。但是这些方法受数据的时序影响较大,因此,在处理长时数据时,方法对于多时间步之前的记忆能力会有所下降,故难以实现准确的长时预测。

### 1.1.3 基于混合模型的交通流预测方法

随着单一模型的性能提升逐步放缓和人们对深度学习方法特性的理解愈发深入,混合模型在交通流预测中展现出巨大的潜力。混合模型指综合利用多种方法实现交通流预测,谭满春等<sup>[33]</sup>采用差分整合移动平均自回归 (Autoregressive Integrated Moving Average, ARIMA) 方法和人工神经网络方法进行短期交通流预测,利用 ARIMA 良好的线性拟合能力和人工神经网络强大的非线性映射能力,考虑交通流时间序列由线性自相关结构和非线性结

构组成,使用 ARIMA 方法预测交通流时间序列的线性分量,将人工神经网络方法应用于非线性残差分量预测;Tian 等<sup>[34]</sup>结合堆栈自动编码器 (Stacked Autoencoder, SAE) 和 LSTM 进行交通流预测,其中 SAE 用于获取空间特征,LSTM 则用于提取交通流的时间特征,然后,结合 SAE 和 LSTM 的优势来预测交通流,结果表明:混合方法相比于单一方法均获得了更优的预测效果。目前,融合多个方法,充分利用各个方法的优缺点已经成为交通流预测领域重要的发展方向。

断面交通流预测的 3 种方法对比如表 1 所示。传统机器学习方法虽然有着较少的训练成本,但其属于浅层学习,无法有效应对大数据场景,适用于数据量不大的简单场景;递归神经网络可以有效获取交通数据的历史规律性,但由于其结构的连续性,在



表 1 三种断面交通流预测方法对比

Table 1 Comparison of three section traffic flow prediction methods

方法	原理	局限性	适用场景
传统机器学习	训练使用统计学知识和交通特征建立的回归方法	体系结构较浅,适用范围极其有限,必须手动选取特征	预测时间短、精度需求低、数据量小的单一场景
递归神经网络	借助记忆单元学习历史数据对当前的影响	长时依赖性获取不足,训练成本高	精度需求高与数据量大的单一场景
混合模型	衔接几种方法或并行计算多个方法	未充分考虑路网的空间特性,计算复杂度高	预测精度和时间要求高的复杂场景

处理具有长时依赖性数据时表现不佳,并且梯度爆炸问题仍然没有较好的解决方案;混合模型可以根据流量预测的需要融合选用多种方法,可以有效针对某一场景,但容易产生较大的训练成本,提升了计算复杂度。上述方法均实现了指定道路断面的交通流预测,但只考虑了该位置的时间信息和历史交通信息的影响。虽有部分方法采取多个路段的交通数据进行研究,但只限于个别路段(一般为预测点相邻的上下游路段),并未充分考虑交通信息的空间特征,因此,实用性仍有较大不足。

## 1.2 区域交通流预测方法

道路网多个断面间的交通数据具有时空演化规律,研究路段交通数据的时空相关性、批量预测路段交通状态,可提高大规模路网众多路段交通信息的预测速度和效率,有效掌握整个区域的交通状况,陕西省某区域交通流量如图 6 所示。之前绝大多数方法都致力于捕捉交通数据中的时间相关性,例如断面交通流预测中 RNN 及其变体 LSTM、GRU 等,但对于区域交通流预测任务而言,交通数据的变化受路网结构的制约,仅考虑时间特性的预测方法无




图 6 陕西省某区域交通流

Fig. 6 Traffic flow in a certain area of Shaanxi Province

法准确预测道路上的交通状态,因此,充分利用时空相关性是解决交通流预测问题的关键。随着智能交通体系框架的不断完善和交通需求的日益增加,融合路网时空特性的区域预测成为交通流预测任务的主流研究方向。

时空网络数据预测是时空数据挖掘中的基础研究问题,然而道路网络错综复杂,交通数据在空间上呈现出非定向的不规则结构,同时受不同道路线条的影响,表现出空间上的节点强关联性,且伴随时间的变化呈现明显的波动和周期特征。为了解决这些问题,卷积与图卷积网络被广泛用于交通流预测任务。

### 1.2.1 基于卷积神经网络的交通流预测方法

研究人员已经逐渐认识到空间依赖性的重要性,并通过引入卷积神经网络(Convolutional Neural Network, CNN)来提取路网的空间信息<sup>[35]</sup>。卷积神经网络是一类包含卷积计算并且含有深层次结构的深度前馈神经网络,是深度学习的代表方法之一。优点在于可自动提取目标特征,发现样本集中特征规律,解决了手动提取特征效率低下、分类准确率低等问题。由于其从图像中提取关键特征的独特方法,CNN 在图像理解方面表现出了显著的学习能力,基于此优点,部分研究尝试通过将交通路网结构转化为图的形式,并且使用标准化网格对其进行划分,每个网格代表某一区域的交通路网。这样,CNN 就可以通过提取不同区域的交通特征实现对路网空间信息的获取。

如图 7 所示<sup>[36]</sup>,真实路网结构被划分为多个标准网格,并且每个网格都和其邻域直接相连。对于




图 7 交通场景下 CNN 的深度学习架构

Fig. 7 Deep learning architecture of CNN in traffic scenarios

3×3的区域而言,每个中心网格的邻域就是环绕其的8个网格,这8个网格可根据其位置组成特定的序列,对于整体区域可以应用3×3的过滤器实现对指定区域及其邻域的加权平均,并且由于这些领域的顺序是特定的,CNN的训练权重可实现参数共享。

Ma等<sup>[36]</sup>将CNN在图像上的应用迁移到了交通预测领域,将交通环境下的方法结构划分为四部分,分别是方法输入、交通特征提取、预测和方法输出,其中交通特征的提取采用CNN网络框架,用2个连续的卷积层和池化层提取路网空间信息,再通过全连接层实现交通预测。在路网信息的提取中,Ma等<sup>[36]</sup>构建了横轴为时间维度、纵轴为空间维度的时空矩阵,

把时空矩阵作为图像的通道输入,将交通路网中的流量信息转换到图像上,如图8所示。另外,对卷积层和池化层超参数的选取以及卷积的深度做了讨论和试验,在北京出租车数据集上取得了较好的预测精度,并且由于CNN权重共享的特点,有着较低的计算复杂度,可以进一步推广到大型的交通网络。该方法指出了交通预测领域应重点考虑路网内交通状态的时空关联特征,为基于融合时空特征的交通预测问题打下了基础。此后Cao等<sup>[37]</sup>使用类似的方法,将交互式网络流量转换为图像,并使用CNN提取交通流量的交互函数,进一步使用GRU提取时间特性,通过充分融合时空特性预测准确度相较于只使用GRU和CNN分别提升了14.3%和13.0%。




图8 交通数据到图像转换

Fig. 8 Conversion of traffic data to image

之后,深度学习理论不断发展,对高维时空数据的建模和对复杂特征的提取越来越受到人们的重视,在此基础上,Guo等<sup>[38]</sup>提出了一种新的端到端深度学习方法,即时空三维网络(Spatio-Temporal 3D Network, ST-3DNet),引入3D卷积避免了二维卷积运算时时间信息的丢失,更有效地捕获空间和时间维度上交通数据的相关性;并且考虑到在整个路网的空间结构中,同一区域的不同道路所携带的特征信息对于预测的贡献度是不同的,不能只考虑时空相关性,因此,提出了“重新校准”(Recalibration, Rc)块来明确和量化每个区域通道特征的贡献程度,如图9所示<sup>[38]</sup>。在完成时空特征的有效提取后,考虑到交通数据的2种时间特性,即局部模式和长期模式,ST-3DNet采用由3D卷积和Rc块组成的2个组件分别对2种模式进行建模,最后在最终预测时用加权的方式将它们聚合后输出,在3个数据集中取得了准确的预测结果。该方法首次将3D卷积引入到交通领域,并且考虑到交通数据的局部特性对预测结果的影响,以及时空相关性对预测贡




图9 重新校准块

Fig. 9 Rc block

献程度的差异。

接下来考虑到随着时间的推移路网中不同位置间的空间依赖性可能是动态的,并且时间的动态变化也不完全是周期性的,Yao等<sup>[39]</sup>提出了基于时空神经网络的时空动态网络(Spatial-Temporal Dynamic Network, STDN),使用局部CNN和LSTM分别处理时空信息。其中带有门控机制的CNN利用区域间的动态相似性对空间依赖建模,并且引入周期



性位移注意力机制学习长期依赖性,在纽约出租车数据集和纽约共享单车数据集中验证了该方法的有效性。该方法的独到之处在于指出了交通状态的时空依赖关系是动态的,尤其是针对交通序列的时间周期性进行了讨论,融合多种方法分别建模路网时空特性,对交通流预测的实时性进行了探索。

RNN 和 CNN 的体系结构过去在提取时空依赖关系方面很流行。例如, Wu 等<sup>[40]</sup>融合 CNN 和 LSTM 提出了一种短期交通流预测方法,融合时序和递归卷积网络(Integrating Temporal and Recurrent Convolutional Network, ITRCN),分别使用一维 CNN 和 2 层 LSTM 捕获时空特性。在这些架构中,RNN 或其变体被用来提取交通数据中的时间相关性,CNN 用于捕获基于网格的交通网络中的空间相关性,大量方法也都是基于 CNN 网络框架<sup>[41-53]</sup>。然而,许多交通网络本质上是图结构的,在 CNN 中学习到空间特征对于表示基于图的交通网络并不是最优的。由于 CNN 是为欧几里得空间设计的,可以有效地提取数据的局部模式,但只能应用于标准网格数据,在具有非欧几里得拓扑的运输网络中具有局限性,无法从本质上描述交通数据的空间依赖性。

### 1.2.2 基于图神经网络的交通流预测方法

为了从非欧结构的交通路网中提取空间特征,部分研究者引入数学中图论的观点,将路网描述为图的形式,图的结构可以很好地描述交通节点的连接关系,并且为卷积的引入提供了新的思路。近年来,常使用图神经网络来建模交通网络中的空间依赖性,再利用卷积从根本上提高图分析效率,并从频域和空间域进行网络构建,即图卷积网络(Graph Convolutional Network, GCN)。图卷积将传统的卷积推广到图结构的数据中,如图 10 所示。图卷积网络及其变体被广泛应用于这些时空网络数据预测任务,并取得了准确的预测结果。下面介绍基于图卷积网络交通流预测方法的一些基本要素。




图 10 从 CNN 迁移到 GCN

Fig. 10 Migrating from CNN to GCN

路网结构图构建是图卷积网络的关键环节,可以将路网表示为  $G=(V,E,W)$ 。其中  $V=\{v_1, v_2, \dots, v_n\}$  表示  $n$  个节点的集合,可以理解为路网节点,例如收费站、路口等; $E$  表示连接节点的边集,可以根据边是否具有方向性将图结构分为有向图和无向图; $W \in \mathbf{R}^{n \times n}$  表示带权连接矩阵,描述了不同节点间的连接权重属性。需要指出的是,对于不同的交通预测问题,节点和边可能由于其所处的图卷积结构不同代表着不同的意义,例如在交通流预测中,可以选取每个节点的交通流量作为其特征,交通路网的图结构如图 11 所示,其中  $M$  为在时间  $t$  基础上减少的时间步长,  $H$  为增加的时间步长,随着时间步长的变化每个节点的交通流量也随之变化。

接下来,如何从路网结构图中提取空间信息成为研究的重点,目前,主流研究方向包括基于谱域(频域)和空域的图卷积。其中谱域方法是通过谱分析考虑卷积的局部性,从而将 CNN 模拟构建到谱域,如谱图卷积(Spectral Graph Convolution, SGC),该方法主要集中于对谱图理论核心公式的不断推导和改善,从优化参数的角度降低方法的运算量。空域方法直接在图的节点及其邻域上执行卷积滤波器,如扩散图卷积(Diffusion Graph Convolution, DGC)。

#### (1) 基于谱域的图卷积网络

由于图平移不变性的缺失给在节点域定义卷积神经网络带来困难,谱域方法利用卷积定理从谱域定义图卷积。谱域图卷积网络基于图信号处理,将




图 11 交通路网的图结构

Fig. 11 Graph structures of traffic road network

图神经网络的卷积层定义为一个滤波器,即通过滤波器去除噪声信号从而得到输入信号。谱域图卷积的处理过程可以简单理解为:空域的图信号变换到谱域,在谱域进行卷积操作,最后将卷积后的信息再变换回空域,这样就可以实现在非欧式结构的路网中进行空间特征提取。Defferrard 等<sup>[54]</sup>提出了基于切比雪夫多项式的切比雪夫网络(Chebyshev Network, ChebNet),通过限制卷积核的大小实现局部信息的提取和计算复杂度的降低,将计算复杂度由  $O(n^2)$  降为  $O(n)$ ,将图卷积从理论推广到实际应用。此后,Kipf 等<sup>[55]</sup>为了使 ChebNet 有更好的局部连接特性,使用一阶切比雪夫多项式并通过限制参数来简化谱图卷积;Xu 等<sup>[56]</sup>提出图小波神经网络(Graph Wavelet Neural Network, GWNN),使用小波变换替代谱域图卷积中的傅里叶变换,分别计算特征变换和卷积,有效降低了计算的复杂度,并且利用小波变换的特点实现局部特征的提取。

## (2) 基于空间域的图卷积网络

Niepert 等<sup>[57]</sup>首先提出了基于空间的图卷积网络,不同于从信号处理理论出发的谱域图卷积神经网络,空间域图卷积神经网络是从图中的节点出发,设计聚集邻居节点特征的聚合函数,采用消息传播机制,思考怎样准确高效地利用中心节点的邻居节点特征来更新表示中心节点特征。CNN 的本质是加权求和,空间域的图卷积神经网络正是从 CNN 的基本构造过程出发,从求和的角度来完成图神经网络(Graph Neural Network, GNN)聚合邻居节点的目的。由于图中的节点无序且邻居节点个数不确定,所以空间域的图卷积神经网络的工作步骤是:①固定邻居节点个数;②给邻居节点排序。如果完成了上述2个工作,非欧氏结构数据就变成了普通的欧氏结构数据,传统的方法也就可以完全迁移到图上来。其中,步骤①也是便于将 GNN 应用于节点数量巨大的图上。但是该方法需要整张图所有节点

均参与训练,运算复杂度高,实时性较差,并且只适用于固定图结构。Hamilton 等<sup>[58]</sup>从信息聚合的角度出发提出了图采样与聚合(Graph Sample and Aggregated, GraphSAGE)方法,其核心思想是通过聚合相邻节点的信息以更新中心节点。每个聚合函数可以学习单个节点的不同搜索深度或跳数的信息聚合,通过训练好的聚合函数来对新增节点进行特征提取。随后 Velickovic 等<sup>[59]</sup>通过引入注意力机制,根据每个节点在其邻域节点的注意力程度对该节点进行更新,提出了图注意力网络(Graph Attention Network, GAT)方法。由于每个节点的权重不同,GAT 有着更好的表达能力,相较于 GraphSAGE,GAT 可以访问所有邻居节点,并且无需对其进行排序,运行更加高效。此外 Monti 等<sup>[60]</sup>提出了混合模型网络(Mixture Model Network, MoNet),通过定义多个核函数衡量目标节点与其他节点的相似度,并且将核函数的权重作为卷积核的参数,该方法也作为空域图卷积的经典方法而广泛应用。近年来,Xu 等<sup>[61]</sup>提出的深度层次图卷积神经网络(Hierarchical Graph Convolutional Network, H-GCN)引入图池机制,将结构上相似的节点聚合为超节点,将粗化的图细化为原始图,从而增大感受野,有效地捕获全局信息。

目前,GCN 已成为交通流预测研究的基础方法以及试验的基准方法。空域图卷积网络与频域图卷积网络虽然均不是针对交通流预测问题而提出的,但由于交通数据的天然图结构属性,令 GCN 在交通流预测领域展现出优于传统方法的高效率与高准确率。此外,交通数据本身为时序数据,如何挖掘时序特征且与空间特征融合预测成为用于交通流预测的神经网络方法的改进重点。图注意力机制同样被用于交通流预测方法且能显著提升性能。同时,当前研究已不满足静态图,更多新颖的框架不断被提出,如图 12 所示介绍了基于图卷积网络的交通流预



图 12 基于图卷积的交通流预测方法

Fig. 12 Typical methods of traffic forecasting based on GCN



测方法发展情况。

起初 Seo 等<sup>[62]</sup>尝试从 CNN 推广到任意图结构,引入了图卷积递归网络(Graph Convolutional Recurrent Network, GCRN)来识别结构化数据序列的联合空间结构和动态变化,通过基于谱域图卷积的 ChebNet 结构识别空间信息,再结合 RNN 及其变体,例如 LSTM、GRU 等学习时间变化。文献[62]提出的 2 种 GCRN 架构在动态修订版国家标准与技术研究所数据库中实现了很好的预测效果,虽然并未应用于交通流预测领域,但为基于图卷积的交通流预测提供了很好的思路和研究方向。

Li 等<sup>[63]</sup>从利用扩散卷积运算提取空间相关性出发,提出了扩散卷积递归神经网络(Diffusion Convolutional Recurrent Neural Network, DCRNN),考虑到交通动力学的随机特性,建立道路传感器网络的带权有向图,使用图上的随机游走捕获了空间依赖性,在对时间依赖性建模时,将 GRU 中的矩阵乘法变为扩散卷积,得到了扩散卷积门控循环单元。此后, Wu 等<sup>[64]</sup>所提出的图波网络(Graph WaveNet, GWN)方法在采用扩散卷积思想提取路网的空间特征的基础上,加入了一种新型的自适应连接矩阵,弥补了固定拓扑结构提取空间特征的不足。

为了获取不规则路网的空间信息,并且避免 RNN 体系多次迭代引起的误差积累, Yu 等<sup>[65]</sup>提出了时空图卷积网络(Spatio-Temporal Graph Convolutional Network, STGCN),主体由 2 个时空卷积块堆叠组成,每个时空卷积块通过 2 个门控时间卷积和一个空间图卷积构成“三明治”结构,其中空间卷积层通过谱域图卷积提取空间信息,时间卷积层采用 GRU 实现的一维因果卷积学习时间依赖性。在城市交通系统运行时,早晚高峰会引起强烈的交通流数据波动,而循环神经网络体系由于依赖上一步记忆的信息而无法捕捉到这种剧烈的数据变化。STGCN 方法采用门控卷积层实时提取交通流时间轴上的动态行为,不受之前时间点预测数据的限制,并且由于时序和空间提取层都采用了卷积的结构,可以通过堆叠的方式并行训练,取得了更短的训练时间。STGCN 方法首次使用纯卷积层同时提取时间和空间信息,并且由于纯卷积操作相较于 RNN 结构大幅提升了训练速度,可以有效应用于大尺度的数据集。

对于如何有效获取空间节点间的动态相关性, Guo 等<sup>[66]</sup>提出了基于注意力的时空图卷积网络(Attentional Spatio-Temporal Graph Convolutional Network, ASTGCN)方法来解决交通流量预测问

题。在时间维度上,由 3 个具有相同结构的独立组件组成,分别对交通流的 3 个时间属性进行建模,即最近、每日和每周的依存关系;在空间维度上,使用注意力机制以自适应地捕捉空间维度中节点之间的动态相关性。利用空间维度上交通网络中的信号相关性,采用谱域方法将图转换为代数形式来分析图的拓扑属性,使用图卷积捕获空间模式。

通过引入注意力机制来调整不同时间点的重要性并组合全局时间和空间信息以提高预测准确性。Zheng 等<sup>[67]</sup>提出了基于图多注意力网络(Graph Multi-Attention Network, GMAN)的交通流预测方法,该方法将注意力机制引入到空间的动态相关性和时间的非线性相关性上,并且为了减轻误差传递问题,在编码器和解码器间加入了变换注意力层,使得历史和预测的交通特征实现转换; Wang 等<sup>[68]</sup>指出此前利用注意力机制捕获动态空间依赖性时未考虑到全局的时间依赖,提出了一种具有位置注意力机制的图神经网络层,从而更好地聚合邻近节点的空间信息; Chen 等<sup>[69]</sup>发现此前的图卷积结构往往忽视了路网边的相互影响,因此,提出了多级注意力双分量图卷积网络(Multi-Range Attentive Bicomponent Graph Convolutional Network, MRA-BGCN),采用双组分图卷积对路网中边和节点的相关性都进行建模,并且引入了多级注意力机制,从而捕获多邻域范围的信息,通过叠加多个双分量图卷积门控递归单元层,用序列到序列结构进行多步交通预测,对图卷积结构和注意力机制都进行了一定的改进。

使用 GNN 和 RNN 相结合的交通流预测方法容易产生梯度弥散和爆炸,并且由于卷积的非线性运算,对输入端线性变化不敏感。为了解决这个问题, Chen 等<sup>[70]</sup>提出了一种基于多重残差循环图神经网络(Multiple Residual Recurrent Graph Neural Network, MRes-RGNN)的交通流预测框架,该网络方法由于使用了递归残差结构,可以准确提取交通网络的时空结构且对模型的突发变化更为敏感,同时解决了梯度问题。

现有的交通图构建常依赖于指定区域节点间的空间邻近关系,而忽略了不同节点在时间上的相似性,例如早高峰时期不同区域的商业区、学校同样会出现交通拥堵问题,但是这些区域因为在空间上的距离较远,往往在交通图的构建中被忽略了。为此,研究者开始探索使用不同方式进行交通图的构建。Li 等<sup>[71]</sup>提出了时空融合图神经网络(Spatial-Temporal Fusion Graph Neural Networks, STFGNN),



使用动态时间规整(Dynamic Time Warping, DTW)的方法计算节点时间序列的相似度,在传统的空间图的基础上,动态地构建时间图,通过融合时间和空间图提取隐藏的时空特性,再使用门控扩散卷积捕获全局和局部的相关性,通过堆叠处理可以更好地学习时空依赖性以及处理长序列的时空相关性。同样是基于图结构的构建,Lyu 等<sup>[72]</sup>所提出的时间多图卷积网络(Temporal Multi-Graph Convolutional Network, T-MGCN)通过加权拓扑图、交通模式图、区域功能图的构建以及使用堆叠 GRU 捕捉时间相关性,融合了时间相关性、空间相关性以及语义相关性,很好地捕获了各种全局特征。

为了减少训练成本,针对短期交通流预测,Zhang 等<sup>[73]</sup>提出的残差图卷积长短期记忆网络(Residual Graph Convolution Long Short-Term Memory, RGC-LSTM)通过多个隐藏层的堆叠和一个全连接层实现

深度架构,计算复杂度低,训练速度快,取得了合理的计算成本。对于大型数据集,Mallick 等<sup>[74]</sup>提出了一种应用于大型公路网交通流预测方法,使用图分区将大型高速公路网络分解为较小的网络,并使用 DCRNN 对其进行独立训练。

近年来,融合多种结构的预测方法逐渐成为主流。例如,Li 等<sup>[75]</sup>提出了一个三通道注意力机制网络,融合图卷积网络、选通递归单元和全连接神经网络,用于提取路网的空间、时间和其他特征;Liu 等<sup>[76]</sup>结合使用数据恢复方法和 GraphSAGE 实现数据缺失情况下的速度预测。

为了对比不同结构的优缺点,本文选取了 10 种典型方法,在基于陕西省 186 个收费站点的交通流量数据集上进行训练,并分别对平均绝对误差、平均绝对离差、均方根误差和训练时间 4 种参数进行了对比,预测步长分别为 15、30、45、60 min,如表 2 所示。

表 2 十种典型方法的试验结果对比  
Table 2 Experimental result comparison of 10 typical methods

方法	平均绝对误差	平均绝对离差	均方根误差	训练时间/min
时序图卷积网络 (Temporal Graph Convolutional Network, T-GCN)	2.915/3.154 3.429/3.680	0.709/0.711 0.723/0.728	8.532/9.019 9.608/10.129	120
STGCN	3.124/3.467 3.826/4.174	0.828/0.862 0.831/0.853	9.199/10.371 11.706/12.923	22
DCRNN	4.130/5.120 6.430/7.526	0.964/1.120 1.428/1.634	9.650/10.620 11.882/12.949	160
时间卷积网络 (Temporal Convolutional Network, TCN)	5.372/9.305 14.575/18.953	3.280/5.859 10.040/13.153	9.664/12.520 19.574/23.829	64
GRU	6.547/10.130 16.570/21.105	3.586/6.847 11.544/15.283	9.981/15.328 25.114/31.941	78
SAE	7.625/11.985 16.980/21.551	3.626/5.897 10.662/13.764	10.136/15.525 25.744/32.743	88
LSTM	7.727/12.232 17.246/21.921	3.370/5.920 10.626/13.894	10.332/16.354 26.288/33.614	96
支持向量回归 (Support Vector Regression, SVR)	6.705/11.406 22.808/20.743	3.923/6.478 15.186/19.792	20.017/34.670 67.055/87.619	130
ARIMA	12.094/22.913 43.934/58.153	7.605/14.742 30.161/40.058	16.961/31.009 57.026/75.063	210
历史平均 (Historical Average, HA)	14.602/26.620 45.830/60.245	3.751/7.000 12.583/16.61	36.309/64.627 108.666/142.22	190

通过图 13 的对比结果可知:在 15 min 的短时预测工作中,这几类方法的误差都较小;随着预测时间的增加,基于统计学方法和传统机器学习方法的收敛效果显著变差,且预测精度和稳定性比较不理想;基于深度学习的方法相比较统计学方法和传统

机器学习方法的长时预测性能较好;融合了时空维度特征基于图卷积方法的长时预测性能和稳定性优于仅考虑时间维度的方法;引入图结构捕获空间特征,对于给定区域的交通流预测也会更加准确、快速。此外,实际道路情况也会受到天气、事故等多种

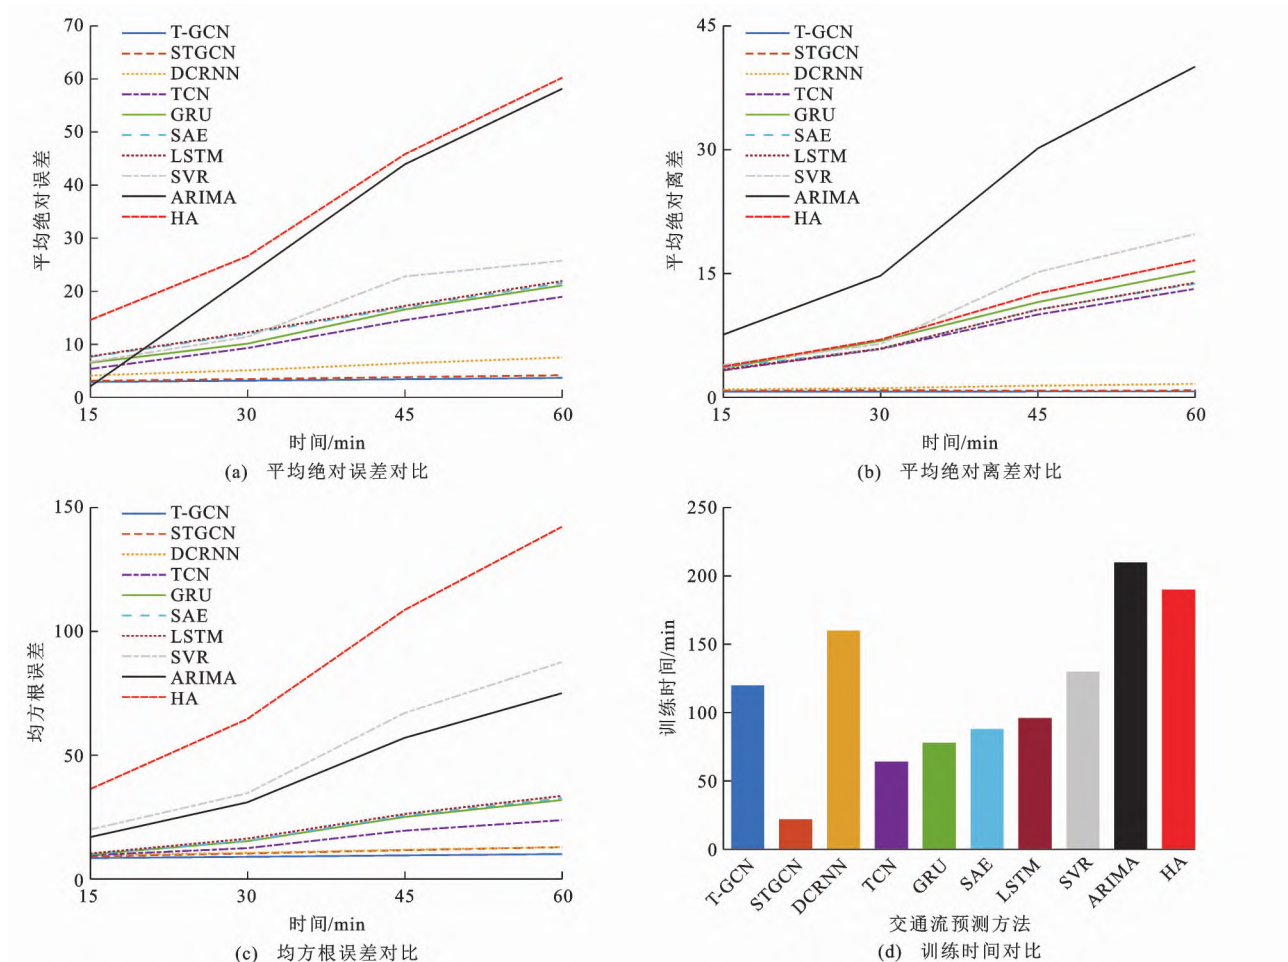


图 13 十种典型方法的试验结果对比

Fig. 13 Experimental result comparison of 10 typical methods

因素的影响,为了更准确地完成预测任务,基于融合多因素的交通流预测方法越来越受到人们的重视。

### 1.2.3 基于融合多因素的交通流预测方法

交通流预测在很大程度上依赖于从各种传感器源收集的历史交通数据。目前,众多方法均在交通流预测方向取得了一定的成果,但在实际应用中由于数据庞大、多源、组织方式不当都对交通流预测的实时性和准确性有很大影响。而且交通流预测任务不仅依赖于历史交通信息和空间关系,还受到天气、环境、道路等外部因素的干扰。仅使用现有的交通信息(如交通量、行驶时间、速度等)用作预测未来道路状况的输入,若环境变量发生了变化(例如,如果有施工或维修工作,或道路结构或天气条件发生了变化),这些方法就不能提供精确的预测<sup>[77]</sup>。人们普遍认为天气、道路等会严重影响交通特性并导致交通拥堵和事故。如果不全面了解外部因素对交通状况的影响,交通管理部门就无法在相关运营政策中考虑相关因素来提高交通效率和安全性。而且固有的交通模式和多重干扰之间复杂的时空依赖关系

尚未得到完全解决,现有的方法也无法充分考虑内部和外部因素的影响。目前,交通领域已经汇聚了监控设备采集的视频、图像,线圈卡口采集的流量、速度、占有率以及车载设备采集的 GPS 等海量多源异构的高维交通数据,同时,恶劣天气、交通事故以及交通管制等辅助数据同样对于交通流预测具有不可忽视的价值。然而,目前无论是神经网络或图神经网络,其关注点均主要在于时空特征的提取。在此基础上,若引入交通流数据之外其他有价值的信息,将会对交通流预测问题有所提升,因此,如何有效地利用多源数据并将外部影响因素整合到方法中以提高和改善交通流预测任务是亟需解决的主要问题之一。

Zheng 等<sup>[78]</sup>提出了一个两阶段的框架来预测整个区域的交通流量。在时空干扰(Spatio-Temporal Disturbances, STD)建模阶段,首先计算每个区域中每个兴趣点(Point of Interest, POI)类别的内在影响,作为内在影响因子(Intrinsic Impact Factor, IIF),其分布可用区域函数表示。从 POI 所在区域

的频率分布、类别密度和分布不平衡程度三方面研究其内在影响。然后,将多个因素对每个 POI 类别的扰动影响建模为扰动影响因子 (Disturbance Influence Factor, DIF),采用 2 个全连接层以提取多个因素对各个 POI 类别的干扰影响。最后通过三维卷积神经网络将 IIF 和 DIF 作为 STD 结合起来,以模拟扰动的时空传播效应。在预测阶段,首先消除了 STD 对历史交通流量的影响, $\bar{X}_t$ 表示  $t$  时刻无干扰的交通流量。残差神经网络(Residual Neural Network, ResNet)<sup>[79]</sup>通过采用残余单元保证了 CNN 结构的加深,最后,将 ResNet 对  $t+1$  时刻的预测输出  $\bar{X}_{t+1}$ 与考虑多个因素影响的 STD 输出  $s_{t+1}$ 相结合,生成最终的交通流量预测结果  $\hat{X}_{t+1}$ ,具体方法框架如图 14 所示。

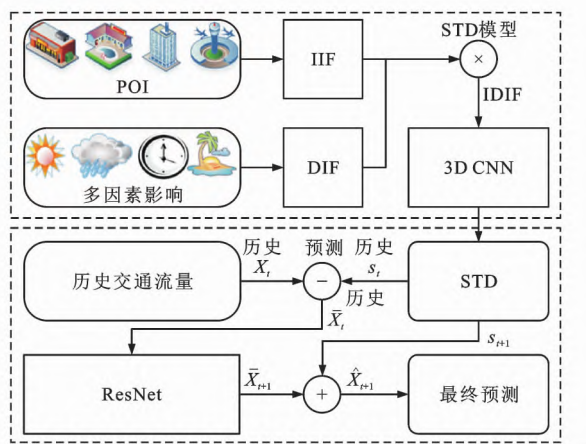


图 14 STD 方法框架

Fig. 14 Framework of STD

此外,Liao 等<sup>[80]</sup>集成了一个基于 LSTM 的编码器来编码外部信息,并将天气数据建模作为序列输入;与之类似,Zhang 等<sup>[81]</sup>基于 GRU,提出添加

了输入特征和天气信息的特征融合方法;为了考虑车辆自身因素对于预测准确度的影响,Wang 等<sup>[82]</sup>通过深层信念-径向基函数网络,将行进速度、交通流量和降雨强度 3 种数据融合,实现了对降雨天特定路段车辆平均行驶速度的精准预测;考虑到降雨等因素会影响交通状态,Zhang 等<sup>[83]</sup>提出了时空残差神经网络(Spatio-Temporal Residual Network, ST-ResNet)对交通拥堵的时间临近性、周期和趋势特性建模,针对每个属性,设计了残差卷积单元的分支,每个残差卷积单元对拥堵流的空间特性进行建模,再利用 ST-ResNet 动态整合 3 个残差神经网络分支的输出,为不同的分支和区域分配不同的权重,将整合结果进一步结合外部因素,如天气和一周中的哪一天,来预测整个地区的流量状况。试验结果均验证了添加天气因素的有效性,交通流预测方法的实用性得到进一步提高。

表 3 展示了区域交通流预测的 3 种方法对比:其中基于卷积神经网络的交通流预测方法原理简单,计算量小,但难以描述非欧结构的路网状况;图神经网络的引入有效解决了这个问题,但对于路网结构外的外部因素考虑不够,对于突发事件的应对能力较弱;融合多因素的交通流预测方法可以充分考虑外部因素对区域路网交通状态的影响,在降雨等突发情况下预测精度较高,但相关性因素的融合仍然不够成熟。随着深度学习的进一步发展,缺乏融入相关性因素的问题可能会得到进一步解决,部分方法已经将外部因素纳入交通状态预测,但是研究数量还较少,暂未形成较为通用的处理方法,因此,在 GCN 的基础上,通过多任务学习等方法融合多源异构交通数据具有广阔的研究前景。

表 3 三种区域交通流预测方法对比

Table 3 Comparison of three regional traffic flow prediction methods

方法	原理	优势	局限性	适用场景	后续应用
卷积神经网络	采用 2 个连续的卷积层和池化层提取路网空间信息	局部连接性,输出神经元只连接到附近的局部输入神经元;池化机制,很大程度上减少了训练 CNN 所需的参数数量,同时保证了最重要的特征被保留;全连接性,应用于最后阶段的全连接层使得输入层的数据维度是可控的	在具有非欧几里得拓扑的运输网络中具有局限性	路网结构较为简单的场景	交通态势评估、通行能力分析 与收费站人力规划
图神经网络	利用图神经网络来建模交通网络中的空间依赖性,再利用卷积从根本上提高图分析效率	空间解释性好;图结构的引入有效地捕获了非欧结构的路网特性	未考虑天气等其他因素对路网的影响	路网结构复杂、外部因素影响弱的场景	交通信号协调控制与地铁车辆调度
融合多因素	利用多源数据并将外部影响因素整合到方法中	实用性高;考虑外部因素对交通状况的影响	相关性因素的融合仍不够成熟	外部因素对交通状况影响较大的场景	交通事故分析



值得指出的是,各种交通流的预测都是为后续研究或者应用服务的,不同角度、不同场景,甚至同一场景下的不同时空尺度,都会产生很大的交通差异。而交通流预测提供了一种预测未来交通态势的方法,对智能交通系统的基础与发展有着关键性的技术支撑,需要完整地实现交通应用,还需要分析具体的交通场景特性,应用不同的交通参数,采取不同的控制方法,才能完整地实现一个场景下的交通分析,因此,如何将交通流预测正确地应用于实际的场景,还需要做大量的工作与研究。

## 2 交通数据集

### 2.1 公开数据集

随着交通设施的不断完善,交通数据量也产生了爆炸式增长,交通流预测恰恰是建立在庞大的交通数据上的。交通数据的来源主要包括道路检测器、车辆 GPS 记录、公交卡、手机信令等。按照交通信息采集的技术和方式的不同可以将其分为固定式交通数据和移动式交通数据 2 种方式。

#### 2.1.1 固定式交通数据

基于安装在固定目标点位的交通信息检测设备对道路上行驶的车辆进行检测,常见的采集方式包括地磁线圈采集技术、超声波采集技术、视频图像采集技术、微波雷达采集技术等。采集的数据包含指定路段或区域路网的车辆通行情况,指定路段信息通常含有车辆 ID、行驶方向、车辆轨迹、总流量、车速等;区域路网信息通常含有车辆坐标、流量、站点通勤情况、位置分布等。这些数据广泛应用于交通流量、速度密度等宏观交通预测。

#### 2.1.2 移动式交通数据

随着交通出行中实时性和动态性的交通信息需求不断提升,传统的固定式交通数据采集技术和信息处理手段虽然相对成熟,但是也存在覆盖率低、维护成本高、可靠性差等问题,因此,移动式交通数据采集技术也受到关注。常见的采集方式包括浮动车采集技术、无人机采集技术和众包采集技术,基于移动车辆配置的 GPS 接收器,经过指定时间间隔记录一次车辆坐标、车辆 ID 等信息,根据 GPS 坐标信息可以推断出车辆轨迹,并结合路网结构进一步推测车辆速度和交通流量,此类数据虽然需要进行数据处理环节,但易于获取,准确性高,也广泛用于交通流量预测。

本文将交通预测的常用公开数据集进行了整理与对比,如表 4 所示。

表 4 交通预测公开数据集

Table 4 Public datasets for traffic prediction

分类	数据集名称	采样周期	采集方式
固定式采集数据集	交通性能测量系统数据集	5 min	车辆检测器
	多尺度时空交通估计与预测数据集	5 min	车辆检测器
	洛杉矶高速公路数据集	5 min	环形检测器
	西雅图城市交通流数据集	5 min	地感线圈
	纽约市自行车共享行程数据集		自行车数据
移动式采集数据集	上海地铁客流数据集、深圳地铁客流数据集	15 min	地铁站点
	马德里城市交通追踪数据集	0.5 s	车辆轨迹采集
	纽约市出租车和豪华轿车委员会行程数据集		出租车记录
	北京市出租车 GPS 轨迹数据集	30 min	GPS 数据
	上海市交通行程时间及车速数据集	10 min	出租车记录
	深圳市浮动车数据集	15 min	出租车轨迹
	北京市出租车 GPS 轨迹数据集		出租车轨迹
	滴滴出行交通流量预测数据集		网约车记录
	科隆市的推特交通信息语料库	1 s	车辆轨迹采集
	弗吉尼亚理工大学自然驾驶研究数据集	1 s	车辆轨迹采集

#### 2.1.3 其他数据

除上述数据集外,源自气象部门的天气数据和包含街景图像、卫星图像、视频监控的多媒体数据也可以作为预测方法的辅助输入或用于验证数据准确性。公共数据集的合理选取是实现准确交通流预测的基础,例如基于机器学习的交通流预测方法将公共数据集划分为训练集、验证集、测试集,从而进行模型的训练、检验和测试,因此,在基于数据驱动的交通流预测中,选择或建立高质量的数据集是实现精准预测的前提。

### 2.2 自建数据集

在设计交通流预测方法时,除了直接使用公开数据集外也可以利用流量推算等方法自建数据集。

本文对比试验采用的数据集就是选取了陕西省 186 个高速公路收费站 4 个月的原始收费数据(2018.12~2019.03),利用 Wang 等<sup>[84]</sup>提出的流量推算方法将高速公路通行费数据转化为指定路段的交通流数据。首先,利用 Dijkstra 最短路径方法得到最短行程路径和总行程距离,同时,结合收费站数据提供的车辆在高速公路上的总行驶时间,可以计算出单车全程行驶在高速公路上的平均速度;其次,在固定时间,根据海量数据分析,同一车型的车辆在固定路段行驶时的行驶速度大致相同,顺流速度和

顺流时间的概念<sup>[85]</sup>可作为不同类型车辆在路段上行驶速度的参考值,因此,可以估计不同车辆在给定

路段上的平均行驶时间;最后,根据之前结果计算出指定路段上的交通流量,如图15所示。




图15 陕西省186个收费站交通流数据

Fig. 15 Traffic flow data of 186 toll stations in Shaanxi Province

## 2.3 数据预处理

交通流数据主要是检测速度、流量、时间等参数,但是数据采集过程中会出现检测设备故障、仪器误差、软件故障、通信干扰、环境噪声等情况,甚至道路突发故障等都会对数据造成巨大影响,导致实时数据可能会缺失或者异常,因此,ITS系统中的数据问题不可避免且无处不在,并且目前大量深度学习方法的数据类型都是基于张量的,尤其是基于Tensorflow架构,训练数据的完整性和准确性将直观地影响到训练结果,数据预处理相当必要且极其重要。数据预处理的整体流程如图16所示。

### 2.3.1 异常数据处理

异常数据的预处理方法可以分为2类:①数据剔除,当交通数据中出现错误数据较少的情况下可以采用数据剔除,剔除个别错误数据不会影响数据的完整性和趋势性,但如果错误数据所占比例较大,就不能采取剔除法,因为过多剔除错误数据会破坏数据的完整性和趋势性;②高峰去噪,由于交通数据具有高度非线性且在高峰时刻的流量数据会非常显著,如图17所示的峰值数据,即高峰时段的噪点震

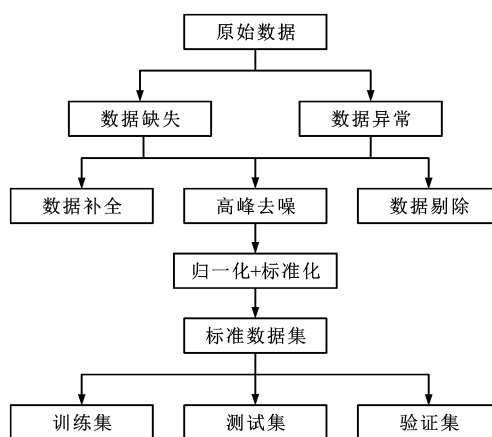


图16 数据预处理流程

Fig. 16 Preprocessing flowchart of data

荡区域,因此,需要高峰去噪处理,常用的方法为经验模式分解<sup>[86]</sup>,即在趋势变化局部震荡部分进行波动分解处理,降低干扰信号引起的扰动误差。

### 2.3.2 缺失数据处理

数据缺失的原因是硬件和软件因素在检测端没有检测到数据,或在数据通信过程中出现数据包丢失。在道路交通中,这可能是由于车辆密度过大和




图 17 典型高峰异常数据

Fig. 17 Abnormal data at typical peaks

交通流检测仪器数据采集不准确、传输中的数据故障和其他许多原因导致收集的数据出现空白,如某一时间点、某一段时间或几个时间段的数据丢失。通常时间序列数据存在如图 18 所示的 2 种经典的缺失模式,图 18(a)表示导出的收费记录在单个收费站处随机丢失了观测值,红色圆圈表示缺失值;图 18(b)表示在多个收费站的记录中有 2 个连续的时间点都无观测值,是更常见的时空交通数据丢失模式,红色方框内的灰色曲线代表缺失值,蓝色曲线代表观测值,这种情况需要对缺失的数据进行关联和处理,然后使用插值和平滑方法对数据进行修复,在此之前要使用初始化运算符对数据进行无量纲化,以考虑到影响因素的特征系列的单位和数量级并不统一的事实。




图 18 交通流数据的缺失模式

Fig. 18 Missing patterns of traffic flow data

考虑到交通数据具有很强的时空关联性,采用矩阵方法表征交通流以补全数据成为研究的主流,其中代表性方法有贝叶斯主成分分析<sup>[87]</sup>、概率主成

分分析<sup>[88]</sup>、贝叶斯概率矩阵分解<sup>[89]</sup>等。之后由于交通数据的维度较高,将矩阵推广到张量。基于张量的数据补偿方法可以分为 2 类,一类是基于 Tucker 张量插值填补法<sup>[90]</sup>、基于 CP 分解法<sup>[91]</sup>和张量同时分解和补全方法<sup>[92]</sup>等;另一类基于迹范数最小化,代表方法有低秩张量补全法<sup>[93]</sup>、截断核范数极小化的低秩张量补全法<sup>[94]</sup>。

### 2.3.3 数据标准化/归一化

一般得到的交通数据较为分散,数据呈现的分布特征曲线较为模糊,无法确定分布,因此,数据不满足正态分布,需要进行标准化,使数据规整,提升数据间的可比较性,方便后续进行方法预测。将数据 Z-分数(Z-score)归一处理使其近似满足正态分布,从而在训练过程中获取较为平均的分配权重。

### 2.3.4 其他处理方法

对交通数据的处理是实现交通流预测的基础,除了上述方法外,Xu 等<sup>[95]</sup>提出了对于动态交通数据异常值的处理方法,其中对异常数据的筛选包含 4 个步骤,分别为组合交通数量、速度、时间占有率的初步筛选,选择合适临界值的阈值筛选,交通流理论筛选和对多个质量特征共同统计的质量控制筛选,对于不同的异常数据提出了相应的数据恢复办法,包括基于时间序列、基于历史数据、基于空间位置和基于时空相关性的数据恢复。此后裴莉莉等<sup>[96]</sup>提出了基于相似系数和相似项之和的异常检测方法以及基于极端梯度提升的多维数据预测修复方法;阮嘉琨等<sup>[97]</sup>利用基于密度的空间聚类方法检测高速公路交通流异常数据。

除了传统方法外,基于机器学习的数据补全方法也取得了很好的效果,例如基于孤立森林的缺失值填补<sup>[98]</sup>、基于改进 K-NN 方法的交通异常数据修复方法<sup>[99]</sup>、基于长短记忆方法的异常判别方法<sup>[100]</sup>等。通过合理的交通数据处理,取得准确、有效的交通数据,将为交通流预测提供可靠的数据支撑。

## 3 交通流预测方法的发展方向

随着深度学习方法的发展和交通数据采集能力的不断提升,基于机器学习的交通流预测方法已成为智能交通领域的研究热点<sup>[101]</sup>,并且已发表了大量论文,经过对比<sup>[102]</sup>可以发现,虽然这些论文采取了不同的研究方法,都取得了较高的预测精度,但出现了大量同质化相似论文,针对这一研究现状本文



做出如下解释。

### 3.1 研究现状分析

#### 3.1.1 交通数据的丰富

随着中国智能交通基础设施的不断普及,城市与高速道路部署了多种感应线圈、视频、微波、超声探测、龙门架等信息感知设备,并且5G、北斗等通讯与定位技术也实现落地应用,交通数据采集的丰富度与信息传输的精确度不断提升,由此产生的交通大数据将对智能交通系统的设计和应用产生深远影响,交通领域迈入信息化、智能化时代。丰富多源的交通数据可以协助实现地铁车辆调度、网络交通控制、交通态势评估、交通事故分析等智能交通应用,迫切的现实需求使得交通流预测成为研究热点,因此,随着中国交通数据的不断丰富,交通流预测领域涌现出大量文献,并且由于交通数据准确度的不断提升,现有方法往往取得了较好的预测精度。

#### 3.1.2 机器学习的发展

交通预测领域的发展不仅依赖于交通数据集的完善,也依靠机器学习方法的更新。优质的交通数据集为数据驱动的交通流预测方法提供了坚实的信息基础。而近年来人工智能领域不断发展,当机器视觉、自然语言处理等热门机器学习领域出现突破性进展时,其相应的深度学习方法也会被迁移至交通流预测领域,研究人员根据实际需求对方法做出针对性的改进与提升,从而取得了很好的预测精度,并且作为底层模型的数学与算法基础类似,因此,出现大量相似论文。

#### 3.1.3 技术问题的存在

由于机器学习方法对数据集要求较高,部分研究人员可能存在数据集预处理过度、将测试集用于训练、方法过拟合等技术问题,因此,虽然在目标数据集上有较好的预测精度,但考虑到交通流预测的现实应用,应保证方法的实时性、泛化性和鲁棒性。

### 3.2 未来的改进方向

虽然近年来交通流预测的方法不断改进,已经取得了较高的准确率,但仍受制于各种条件的限制,未来还需在多个方面有所改进。

#### 3.2.1 交通信息挖掘

当前交通流预测方法对于交通信息更深层次的特征认知仍不完全,后续可考虑挖掘交通信息的进一步特征和其他因素对交通流的影响。交通数据具有复杂的空间依赖性、时间依赖性,绝大多

数基于图卷积网络的方法均考虑到了交通信息的时间和空间依赖性,但仍未有足够深度的研究对多种交通信息(流量、速度和占有率等)的内部联系、时空属性关联性进行详细的剖析,因此,加深对交通信息的特征分析将对智能交通和交通方法提供极大的帮助。

#### 3.2.2 外部因素量化

外部因素对交通状况的影响十分严重,如节假日、时间属性(例如小时、日、周、月、季节、年)、天气(例如降雨、温度、空气质量、能见度等)、特殊事件、交通事件和道路环境等,均在一定程度上影响交通流预测。目前,已有部分交通流预测研究工作逐渐向考虑外部因素的方向靠拢,但该类型数据收集困难,数量较小,随机性强,且难以量化各种因素对交通状态的影响,因此,研究深度还远远不足。将外部因素与其他特征连接起来,并将其输入方法和设计一个单独负责处理外部因素的外部组件与其他组件结合进行输出是当前融合预测的2种常用方法,但该技术仍然相当不成熟,急需更多、更先进的方法来解决这一问题。

#### 3.2.3 图卷积方法完善

在交通流预测领域中GCN已成为中坚方法,但其起步较晚,其理论基础和研究深度还远远不够。目前来看,依然面临着许多亟待解决的问题。

##### (1) 动态图建模

GCN网络处理的图结构绝大部分均为静态图,涉及动态图结构的方法较少。静态图结构是静态不变的,而动态图的顶点和边随机变化,甚至消失,规律难循。

##### (2) 异质图

同质图指节点和边为一种类型,这种数据处理起来较容易。而异质图则是指节点和边的类型不同,同一个节点和不同的节点连接会表现出不同的属性,同一条边和不同的节点连接也会表现出不同的关系,异质图结构处理起来就相对复杂。但异质图却是和实际问题最为贴切的场景。

##### (3) 结构加深

GCN固有优势之一是平滑了图信号,但随着其层数不断加深,其训练结果极易出现过平滑的情况。由于图卷积是特殊形式的拉普拉斯平滑,在图卷积聚合邻居节点特征的过程中,平滑操作使信号在特征层面更加一致,从而使信号失去其多样性,导致相关预测任务的性能急剧下降,该现象在小数据集上更加明显,因此,GCN不能像一般卷积方法那样不

断深入地堆叠,但浅层神经网络又存在感受野和特征提取能力有限的问题。

#### (4)其他分支

图神经网络研究领域还有众多分支,如图对抗网络、图自编码器、递归图神经网络、图强化学习、图迁移学习等均可尝试在交通流预测领域进行研究。

#### 3.2.4 图结构应用拓展

利用图结构来处理交通流预测的工作有很多,且已经取得了最先进的性能。然而,在其他研究方向的研究工作还较少,如控制交通信号<sup>[103-104]</sup>、交通事故检测、车牌检测<sup>[105]</sup>、行人检测、车道检测和交通标志检测等,可尝试引入图结构进行研究。

#### 3.2.5 非常态交通流预测

交通异常状况即发生于交通营运过程之中,或发生于交通体系之外,但影响到交通正常运行的情况与事件,例如人群大规模聚集,在大型活动举行期间如节日庆典、体育活动、文化交流、学校开学等,有限时间和空间内将会迅速聚集大量人流和车流,在活动前后会引起区域交通流激增,导致相关路段交通拥堵,进一步影响邻近区域交通流量。除此以外,突发交通事故,恶劣天气导致的路面结冰、积水等非常态情形也将显著影响交通状况,这类异常交通事件对于公共出行安全具有极大威胁,因此,对非常态交通需求提供预测,优化资源配置,解决交通供需矛盾,有效进行交通疏散,提升出行效率,助力交通管理规划,提升城市运转效率,具有重要社会价值。

## 4 结 语

(1)在断面交通流预测方面,预测当前监测点未来一段时间的交通流量,是交通流预测最初的发展方向。基于机器学习的断面交通流预测主要可分为3类:基于传统机器学习方法计算复杂度低,但预测精度较差;基于递归神经网络的方法可以有效处理时序问题,有较高的预测精度,但对交通数据长时依赖性捕获较差;基于混合模型的方法可以融合各个方法的优点,特定场景下预测结果较好,但计算复杂度高。

(2)在区域交通流预测方面,由于拓展到多个断面,即预测整个区域的交通状况,是交通流预测的主流发展方向。基于机器学习的区域交通流预测方法可分为3类:基于卷积神经网络的方法在规范路网下预测精度高,但难以处理非欧空间的路网信息;基于图卷积方法通过引入图结构,可以有效建模路网的时空依赖性,但未考虑其他外部因素,在特殊情况下预

测精度有所下降;基于融合多因素方法充分考虑了如天气、事故在内的外部环境变量,有着很高的预测精度和实用性,是未来交通流预测发展的方向之一。

(3)在公开数据集方面,基于机器学习的交通流预测方法往往对数据要求较高。本文整理了全球范围内广泛用于交通流预测的公开数据集,总结其采样周期和采集方式,并详细综述了自建数据集和数据预处理的理论和方法。

(4)在应用场景方面,当前对于交通流预测研究大多还只是停留在理论层面,首先设计出方法,然后在公开数据集上进行测试验证,鲜有把现实情况考虑在内。虽然在现实世界上已有一小部分的应用,如交通态势分析<sup>[106]</sup>、事故分析评估<sup>[107]</sup>、收费站人力规划<sup>[108]</sup>等,但还远没有达到大规模应用的程度,任何研究只有真正的在工业界落地,才能发挥它的应用价值,反之也会促进其进一步的研究发展。尽快将交通流预测应用到实际的工业场景中,是一个亟需解决的问题。

#### 参 考 文 献 :

#### References :

- [1] WANG Yi-bing, YU Xiang-hua, ZHANG Si-yu, et al. Freeway traffic control in presence of capacity drop[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(3): 1497-1516.
- [2] 曾筠程,邵敏华,孙立军,等. 基于有向图卷积神经网络的交通预测与拥堵管控[J]. 中国公路学报, 2021, 34(12): 239-248. ZENG Yun-cheng, SHAO Min-hua, SUN Li-jun, et al. Traffic prediction and congestion control based on directed graph convolution neural network[J]. China Journal of Highway and Transport, 2021, 34(12): 239-248. (in Chinese)
- [3] 张伟斌,张 帅,郭海锋,等. 基于交通因子状态网络的城市交叉口交通流预测[J]. 中国公路学报, 2021, 34(12): 217-228. ZHANG Wei-bin, ZHANG Shuai, GUO Hai-feng, et al. Traffic flow prediction of urban intersections based on a traffic factor state network[J]. China Journal of Highway and Transport, 2021, 34(12): 217-228. (in Chinese)
- [4] SHI Xiao-ming, QI Heng, SHEN Yan-ming, et al. A spatial-temporal attention approach for traffic prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(8): 4909-4918.
- [5] 宋国杰,胡 程,谢昆青,等. 面向实时短时交通流预测的过程神经网络建模[J]. 交通运输工程学报, 2009, 9(5): 73-77. SONG Guo-jie, HU Cheng, XIE Kun-qing, et al. Process neural network modeling for real-time short-term traffic flow prediction[J]. Journal of Traffic and Transportation Engineering, 2009, 9(5): 73-77. (in Chinese)
- [6] 马永杰,程时升,马芸婷,等. 卷积神经网络及其在智能交通系统中的应用综述[J]. 交通运输工程学报, 2021, 21(4): 48-71.

- MA Yong-jie, CHENG Shi-sheng, MA Yun-ting, et al. Review of convolutional neural network and its application in intelligent transportation system[J]. Journal of Traffic and Transportation Engineering, 2021, 21(4): 48-71. (in Chinese)
- [7] 《中国公路学报》编辑部. 中国交通工程学术研究综述·2016[J]. 中国公路学报, 2016, 29(6): 1-161.  
Editorial Department of *China Journal of Highway and Transport*. Review on China's Traffic engineering research progress · 2016[J]. China Journal of Highway and Transport, 2016, 29(6): 1-161. (in Chinese)
- [8] 陈俊杰,上官伟,蔡伯根,等. 交通流特征深度认知的车队运行参数优化方法[J]. 中国公路学报, 2020, 33(11): 264-274.  
CHEN Jun-jie, SHANGGUAN Wei, CAI Bai-gen, et al. Platoon operating-parameter optimization method based on deep cognition of traffic-flow features[J]. China Journal of Highway and Transport, 2020, 33(11): 264-274. (in Chinese)
- [9] LI Wen-gen, CAO Jian-nong, GUAN Ji-hong, et al. A general framework for unmet demand prediction in on-demand transport services[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 20(8): 2820-2830.
- [10] LIN Lu, LI Jian-xin, CHEN Feng, et al. Road traffic speed prediction: a probabilistic model fusing multi-source data[J]. IEEE Transactions on Knowledge and Data Engineering, 2018, 30(7): 1310-1323.
- [11] GONG Yong-shun, LI Zhi-bin, ZHANG Jian, et al. Network-wide crowd flow prediction of Sydney trains via customized online non-negative matrix factorization[C]//ACM. Proceedings of the 27th ACM International Conference on Information and Knowledge Management. New York: ACM, 2018: 1243-1252.
- [12] COVER T, HART P. Nearest neighbor pattern classification[J]. IEEE Transactions on Information Theory, 1967, 13(1): 21-27.
- [13] CORTES C, VAPNIK V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273-297.
- [14] PEARL J. Probabilistic reasoning in intelligent systems: networks of plausible inference[J]. Artificial Intelligence, 1991, 48(1): 117-124.
- [15] GONG Xiao-yan, WANG Fei-yue. Three improvements on KNN-NPR for traffic flow forecasting[C]//IEEE. The IEEE 5th International Conference on Intelligent Transportation Systems. New York: IEEE, 2003: 736-740.
- [16] TONG Jian-cheng, GU Xiang, ZHANG Miao, et al. Traffic flow prediction based on improved SVR for VANET[C]//IEEE. 2021 4th International Conference on Advanced Electronic Materials, Computers and Software Engineering (AEMCSE). New York: IEEE, 2021: 402-405.
- [17] SUN Shi-liang, ZHANG Chang-shui, YU Guo-qiang. A bayesian network approach to traffic flow forecasting [J]. IEEE Transactions on Intelligent Transportation Systems, 2006, 7(1): 124-132.
- [18] ALEXANDER TEDJOPURNOMO D, BAO Zhi-feng, ZHENG Bai-hua, et al. A survey on modern deep neural network for traffic prediction: trends, methods and challenges[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(4): 1544-1561.
- [19] DOUGHERTY M. A review of neural networks applied to transport[J]. Transportation Research Part C: Emerging Technologies, 1995, 3(4): 247-260.
- [20] VYTHOULKAS P. Alternative approaches to short term traffic forecasting for use in driver information systems[J]. Transportation and Traffic Theory, 1993, 12: 485-506.
- [21] HUA Jiu-yi, FAGHRI A. Applications of artificial neural networks to intelligent vehicle-highway systems[J]. Transportation Research Record, 1994, 1453: 83-90.
- [22] WU Qing, JIANG Zhe, HONG Ke-wei, et al. Tensor-based recurrent neural network and multi-modal prediction with its applications in traffic network management[J]. IEEE Transactions on Network and Service Management, 2021, 18(1): 780-792.
- [23] DU Yi, CUI Na-xin, LI Hui-Xin, et al. The vehicle's velocity prediction methods based on RNN and LSTM neural network[C]//IEEE. Proceedings of 2020 Chinese Control and Decision Conference (CCDC). New York: IEEE, 2020: 99-102.
- [24] MA Xiao-lei, TAO Zhi-min, WANG Yin-hai, et al. Long short-term memory neural network for traffic speed prediction using remote microwave sensor data[J]. Transportation Research Part C: Emerging Technologies, 2015, 54: 187-197.
- [25] CHUNG J Y, GULCEHRE C, CHO K H, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. ArXiv Preprint, 2014, DOI: arXiv: 1412.3555.
- [26] FU Rui, ZHANG Zuo, LI Li, et al. Using LSTM and GRU neural network methods for traffic flow prediction [C] //IEEE. 31st Youth Academic Annual Conference of Chinese Association of Automation. New York: IEEE, 2016: 324-328.
- [27] ZHAO Zheng, CHEN Wei-hai, WU Xing-ming, et al. LSTM network: a deep learning approach for short-term traffic forecast[J]. IET Intelligent Transport Systems, 2017, 11(2): 68-75.
- [28] ZHU Ling-xue, LAPTEV N. Deep and confident prediction for time series at uber[C]//IEEE. 2017 IEEE International Conference on Data Mining Workshops (ICDMW). New York: IEEE, 2017: 103-110.
- [29] TIAN Yan, ZHANG Kai-li, LI Jian-yuan, et al. LSTM-based traffic flow prediction with missing data[J]. Neurocomputing, 2018, 318: 297-305.
- [30] PAN Zhe-yi, LIANG Yu-xuan, WANG Wei-feng, et al. Urban traffic prediction from spatio-temporal data using deep meta learning[C]//ACM. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2019: 1720-1730.
- [31] DESHPANDE P, SARAWAGI S. Streaming adaptation of deep forecasting models using adaptive recurrent units[C]//ACM. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York:



- ACM, 2019; 1560-1568.
- [32] YANG Bai-lin, SUN Shu-lin, LI Jian-yuan, et al. Traffic flow prediction using LSTM with feature enhancement[J]. Neurocomputing, 2019, 332: 320-327.
- [33] 谭满春,冯萃斌,徐建闽,等. 基于 ARIMA 与神经网络组合模型的交通流预测[J]. 中国公路学报, 2007, 20(4): 118-121. TAN Man-chun, FENG Nao-bin, XU Jian-min, et al. Traffic flow prediction based on hybrid ARIMA and ANN model[J]. China Journal of Highway and Transport, 2007, 20(4): 118-121. (in Chinese)
- [34] TIAN Yin, WEI Chen-chen, XU Dong-wei, et al. Traffic flow prediction based on stack autoencoder and long short-term memory network[C]//IEEE. 2020 IEEE 3rd International Conference on Automation, Electronics and Electrical Engineering (AUTEEE). New York: IEEE, 2020: 385-388.
- [35] LI Ya-guang, SHAHABI C. A brief overview of machine learning methods for short-term traffic forecasting and future directions[J]. SIGSPATIAL Special, 2018, 10(1): 3-9.
- [36] MA Xiao-lei, DAI Zhuang, HE Zheng-bing, et al. Learning traffic as images: a deep convolutional neural network for large-scale transportation network speed prediction[J]. Sensors, 2017, 17(4): 818.
- [37] CAO Xiao-fang, ZHONG Yu-hua, ZHOU Yun, et al. Interactive temporal recurrent convolution network for traffic prediction in data centers[J]. IEEE Access, 2017, 6: 5276-5289.
- [38] GUO Shen-nan, LIN You-fang, LI Shi-jie, et al. Deep spatial-temporal 3D convolutional neural networks for traffic data forecasting[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 20(10): 3913-3926.
- [39] YAO Hua-xiu, TANG Xian-feng, WEI Hua, et al. Revisiting spatial-temporal similarity: a deep learning framework for traffic prediction[C]//AAAI. Proceedings of the 33rd AAAI Conference on Artificial Intelligence. Palo Alto: AAAI, 2019: 5668-5675.
- [40] WU Yuan-kai, TAN Hua-chun. Short-term traffic flow forecasting with spatial-temporal correlation in a hybrid deep learning framework[J]. ArXiv Preprint, 2016, DOI: arXiv: 1612.01022.
- [41] ZHANG Jun-bo, ZHENG Yu, QI De-kang, et al. DNN-based prediction model for spatio-temporal data[C]//ACM. Proceedings of the 24th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. New York: ACM, 2016: 1-4.
- [42] YAO Hua-xin, WU Fei, KE Jin-tao, et al. Deep multi-view spatial-temporal network for taxi demand prediction[C]//AAAI. Proceedings of the 32nd AAAI conference on artificial intelligence. Palo Alto: AAAI, 2018: 2588-2595.
- [43] WANG Dong, ZHANG Jun-bao, CAO Wei, et al. When will you arrive? Estimating travel time based on deep neural networks[C]//AAAI. Proceedings of the 32nd AAAI Conference on Artificial Intelligence. Palo Alto: AAAI, 2018: 2500-2507.
- [44] LIN Zi-qian, FENG Jie, LU Zi-yang, et al. DeepSTN+: context-aware spatial-temporal neural network for crowd flow prediction in metropolis[C]//AAAI. Proceedings of the 33rd AAAI Conference on Artificial Intelligence. Palo Alto: AAAI, 2019: 1020-1027.
- [45] ZHAO Jun-hui, ZHU Tian-qi, ZHAO Rui-dong, et al. Layerwise recurrent autoencoder for real-world traffic flow forecasting[C]//Springer. Proceedings of 9th International Conference on Intelligence Science and Big Data Engineering. Berlin: Springer, 2019: 78-88.
- [46] LYU Zhong-jian, XU Jia-jie, ZHENG Kai, et al. LC-RNN: a deep learning model for traffic speed prediction[C]//IJCAI. Proceedings of the 27th International Joint Conference on Artificial Intelligence. Freiburg: IJCAI, 2018: 3470-3476.
- [47] LAI Guo-kun, CHANG Wei-cheng, YANG Yi-ming, et al. Modeling long-and short-term temporal patterns with deep neural networks[C]//ACM. Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2018: 95-104.
- [48] ZONOOZI A, KIM J J, LI Xiao-li, et al. Periodic-CRN: a convolutional recurrent model for crowd density prediction with recurring periodic patterns[C]//IJCAI. Proceedings of the 27th International Joint Conference on Artificial Intelligence. Freiburg: IJCAI, 2018: 3732-3738.
- [49] KE Jin-tao, ZHENG Hong-yu, YANG Hai, et al. Short-term forecasting of passenger demand under on-demand ride services: a spatio-temporal deep learning approach[J]. Transportation Research Part C: Emerging Technologies, 2017, 85: 591-608.
- [50] WANG Le-ye, GENG Xu, MA Xiao-juan, et al. Cross-city transfer learning for deep spatio-temporal prediction[C]//IJCAI. Proceedings of the 28th International Joint Conference on Artificial Intelligence. Freiburg: IJCAI, 2019: 1893-1899.
- [51] ZANG Di, LING Jia-wei, WEI Zhi-hua, et al. Long-term traffic speed prediction based on multiscale spatio-temporal feature learning network[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 20(10): 3700-3709.
- [52] YE Jun-chen, SUN Lei-lei, DU Bo-wen, et al. Co-prediction of multiple transportation demands based on deep spatio-temporal neural network[C]//ACM. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2019: 305-313.
- [53] JIANG Ren-he, SONG Xuan, HUANG Dou, et al. Deep urban event: a system for predicting citywide crowd dynamics at big events[C]//ACM. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2019: 2114-2122.
- [54] DEFFERRARD M, BRESSON X, VANDERGHEYNST P. Convolutional neural networks on graphs with fast localized spectral filtering[C]//NIPS. 30th Conference on Neural Information Processing Systems. San Diego: NIPS, 2016:

- 3844-3852.
- [55] KIPF T N, WELING M. Semi-supervised classification with graph convolutional networks[C]//ICLR. The 2017 International Conference on Learning Representations. New York; ICLR, 2017: 1-14.
  - [56] XU Bing-bing, SHEN Hua-wei, CAO Qi, et al. Graph wavelet neural network[C]//ICLR. 7th International Conference on Learning Representations. New York; ICLR, 2019: 1-13.
  - [57] NIEPERT M, AHMED M, KUTZKOV K. Learning convolutional neural networks for graphs[C]//ICML. Proceedings of the 33rd International Conference on Machine Learning. New York; ICML, 2016: 2014-2023.
  - [58] HAMILTON W L, YING R, LESKOVEC J. Inductive representation learning on large graphs[C]//NIPS. 31st Conference on Neural Information Processing Systems. San Diego; NIPS, 2017: 1-11.
  - [59] VELICKOVIC P, CUCURULL G, CASANOVA A, et al. Graph attention networks[C]//ICLR. Proceedings of the 6th International Conference on Learning Representations. New York; ICLR, 2018: 1-12.
  - [60] MONTI F, BOSCAINI D, MASCI J, et al. Geometric deep learning on graphs and manifolds using mixture model CNNs[C]//IEEE. 2017 Conference on Computer Vision and Pattern Recognition (CVPR). New York; IEEE, 2017: 5425-5434.
  - [61] XU Bing-bing, SHEN Hua-wei, CAO Qi, et al. Graph convolutional networks using heat kernel for semi-supervised learning[C]//IJCAI. Proceedings of the 28th International Joint Conference on Artificial Intelligence. Freiburg; IJCAI, 2019: 1928-1934.
  - [62] SEO Y, DEFFERRARD M, VANDERGHEYNST P, et al. Structured sequence modeling with graph convolutional recurrent networks[C]//Springer. Proceedings of the 25th International Conference on Neural Information Processing (ICONIP). Berlin; Springer, 2018: 362-373.
  - [63] LI Ya-guang, YU R, SHAHABI C, et al. Diffusion convolutional recurrent neural network: data-driven traffic forecasting[C]//ICLR. Proceedings of the 6th International Conference on Learning Representations. New York; ICLR, 2018: 1-16.
  - [64] WU Zong-han, PAN Shi-rui, LONG Guo-dong, et al. Graph wavenet for deep spatial-temporal graph modeling[C]//IJCAI. Proceedings of the 28th International Joint Conference on Artificial Intelligence. Freiburg; IJCAI, 2019: 1907-1913.
  - [65] YU Bing, YIN Hao-teng, ZHU Zhan-xing. Spatio-temporal graph convolutional networks: a deep learning framework for traffic forecasting[C]//IJCAI. Proceedings of the 27th International Joint Conference on Artificial Intelligence. Freiburg; IJCAI, 2018: 3634-3640.
  - [66] GUO Sheng-nan, LIN You-fang, FENG Ning, et al. Attention based spatial-temporal graph convolutional networks for traffic flow forecasting[C]//AAAI. Proceedings of the 33rd AAAI Conference on Artificial Intelligence. Palo Alto; AAAI, 2020: 922-929.
  - [67] ZHENG Chuan-pan, FAN Xiao-liang, WANG Cheng, et al. GMAN: a graph multi-attention network for traffic prediction[C]//AAAI. Proceedings of the 34th AAAI Conference on Artificial Intelligence. Palo Alto; AAAI, 2020: 1234-1241.
  - [68] WANG Xiao-yang, MA Yao, WANG Yi-qi, et al. Traffic flow prediction via spatial temporal graph neural network[C]//ACM. Proceedings of the 29th World Wide Web Conference (WWW). New York; ACM, 2020: 1082-1092.
  - [69] CHEN Wei-qi, CHEN Ling, XIE Yu, et al. Multi-Range attentive bicomponent graph convolutional network for traffic forecasting[C]//AAAI. Proceedings of the 34th AAAI Conference on Artificial Intelligence. Palo Alto; AAAI, 2020: 3529-3536.
  - [70] CHEN Cen, LI Ken-li, TEO S G, et al. Gated residual recurrent graph neural networks for traffic prediction[C]//AAAI. Proceedings of the 33rd AAAI Conference on Artificial Intelligence. Palo Alto; AAAI, 2019: 485-492.
  - [71] LI Meng-zhang, ZHU Zhan-xing. Spatial-temporal fusion graph neural networks for traffic flow forecasting[C]//AAAI. Proceedings of the 35th AAAI Conference on Artificial Intelligence. Palo Alto; AAAI, 2021: 4189-4196.
  - [72] LYU Ming-qi, HONG Zhao-xiong, CHEN Ling, et al. Temporal multi-graph convolutional network for traffic flow prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(6): 3337-3348.
  - [73] ZHANG Yang, CHENG Tao, REN Yi-bin, et al. A novel residual graph convolution deep learning model for short-term network-based traffic forecasting[J]. International Journal of Geographical Information Science, 2020, 34(5): 969-995.
  - [74] MALLICK T, BALAPRAKASH P, RASK E, et al. Graph-partitioning-based diffusion convolutional recurrent neural network for large-scale traffic forecasting[J]. Transportation Research Record, 2020, 2674(9): 473-488.
  - [75] LI Zhi-shuai, XIONG Gang, TIAN Yong-lin, et al. A multi-stream feature fusion approach for traffic prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(2): 1456-1466.
  - [76] LIU Jie-lun, ONG P, CHEN Xi-qun. Graph SAGE-based traffic speed forecasting for segment network with sparse data[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(3): 1755-1766.
  - [77] OH S D, KIM Y J, HONG Ji-sun. Urban traffic flow prediction system using a multifactor pattern recognition model[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 16(5): 2744-2755.
  - [78] ZHENG Chuan-pan, FAN Xiao-liang, WEN Cheng-lu, et al. DeepSTD: mining spatio-temporal disturbances of multiple context factors for citywide traffic flow prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(9): 3744-3755.
  - [79] HE Kai-ming, ZHANG Xiang-yu, REN Shao-qing, et al.

- Identity mappings in deep residual networks[C]//Springer. Proceedings of the 14th European Conference on Computer Vision (ECCV). Berlin: Springer, 2016: 630-645.
- [80] LIAO Bin-bing, ZHANG Jing-qing, WU Chao, et al. Deep sequence learning with auxiliary information for traffic prediction[C]//ACM. Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2018: 537-546.
- [81] ZHANG Jun-bo, ZHENG Yu, QI De-kang, et al. Predicting citywide crowd flows using deep spatio-temporal residual networks[J]. Artificial Intelligence, 2018, 259: 147-166.
- [82] WANG Ping, ZHANG Ya-jie, WANG Sai-sai, et al. Forecasting travel speed in the rainfall days to develop suitable variable speed limits control strategy for less driving risk[J]. Journal of Advanced Transportation, 2021, 2021: 1-13.
- [83] ZHANG Jun-bo, ZHENG Yu, QI De-kang. Deep spatio-temporal residual networks for citywide crowd flows prediction[C]//AAAI. Proceedings of the 31st AAAI Conference on Artificial Intelligence. Palo Alto: AAAI, 2017: 1655-1661.
- [84] WANG Ping, XU Wan-rong, JIN Yin-li, et al. Forecasting traffic volume at a designated cross-section location on a freeway from large-regional toll collection data[J]. IEEE Access, 2019, 7: 9057-9070.
- [85] WANG Ping, HAO Wen-bang, JIN Yin-li, et al. Fine-grained traffic flow prediction of various vehicle types via fusion of multisource data and deep learning approaches[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(11): 6921-6930.
- [86] 赵海龙, 张 干, 吕安涛, 等. 基于 EMD-Wavelet 模型的实时交通流噪声数据清洗方法[J]. 交通科技, 2013(2): 150-153.
- ZHAO Hai-long, ZHANG Gan, LYU An-tao, et al. Research on noise reduction of real-time traffic data based on emd-wavelet model[J]. Transportation Science and Technology, 2013(2): 150-153. (in Chinese)
- [87] QU Li, ZHANG Yi, HU Jian-ming, et al. A BPCA based missing value imputing method for traffic flow volume data[C]//IEEE. Proceedings of IEEE Intelligent Vehicles Symposium. New York: IEEE, 2008: 985-990.
- [88] QU Li, LI li, ZHANG Yi, et al. PPCA-based missing data imputation for traffic flow volume: a systematical approach[J]. IEEE Transactions on Intelligent Transportation Systems, 2009, 10(3): 512-522.
- [89] 侯思安, 张 峰, 李向阳. 基于贝叶斯概率矩阵分解的地震数据重建算法[J]. 石油科学通报, 2018, 3(2): 154-166.
- HOU Si-an, ZHANG Feng, LI Xiang-yang. Seismic data reconstruction via a Bayesian probabilistic matrix factorization algorithm[J]. Petroleum Science Bulletin, 2018, 3(2): 154-166. (in Chinese)
- [90] TAN Hua-chun, FENG Guang-dong, FENG Jiar-shuai, et al. A tensor-based method for missing traffic data completion[J]. Transportation Research Part C: Emerging Technologies, 2013, 28: 15-27.
- [91] ACAR E, DUNLAVY D M, KOLDA T G, et al. Scalable tensor factorizations for incomplete data[J]. Chemometrics and Intelligent Laboratory Systems, 2011, 106(1): 41-56.
- [92] CHEN Yi-lei, HSU C T, LIAO H Y M. Simultaneous tensor decomposition and completion using factor priors[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2014, 36(3): 577-591.
- [93] LIU Ji, MUSIALSKI P, WONKA P, et al. Tensor completion for estimating missing values in visual data[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(1): 208-220.
- [94] SU Ya-ru, WU Xiao-hui, LIU Wen-xi. Low-rank tensor completion by sum of tensor nuclear norm minimization[J]. IEEE Access, 2019, 7: 134943-134953.
- [95] 徐 程, 曲昭伟, 陶鹏飞, 等. 动态交通数据异常值的实时筛选与恢复方法[J]. 哈尔滨工程大学学报, 2016, 37(2): 211-217.
- XU Cheng, QU Zhao-wei, TAO Peng-fei, et al. Methods of real-time screening and reconstruction for dynamic traffic abnormal data[J]. Journal of Harbin Engineering University, 2016, 37(2): 211-217. (in Chinese)
- [96] 裴莉莉, 孙朝云, 韩雨希, 等. 基于 SSC 与 XGBoost 的高速公路异常收费数据修复算法[J]. 吉林大学学报(工学版), 2022, 52(10): 2325-2332.
- PEI Li-li, SUN Zhao-yun, HAN Yu-xi, et al. Algorithm for repairing abnormal toll data of expressway based on SSC and XGBoost[J]. Journal of Jilin University (Engineering and Technology Edition), 2022, 52(10): 2325-2332. (in Chinese)
- [97] 阮嘉琨, 蔡延光, 乐 冰. 基于 DBSCAN 密度聚类算法的高速公路交通流异常数据检测[J]. 工业控制计算机, 2019, 32(7): 92-94.
- RUAN Jia-kun, CAI Yan-guang, LE Bing. Highway traffic flow anomaly data detection based on DBSCAN density clustering algorithm[J]. Industrial Control Computer, 2019, 32(7): 92-94. (in Chinese)
- [98] 周 博, 贾树林, 胡江宇, 等. 基于机器学习的交通流参数异常数据处理模型研究[J]. 武汉纺织大学学报, 2021, 34(2): 9-14.
- ZHOU Bo, JIA Shu-lin, HU Jiang-yu, et al. Research on data processing model of traffic flow parameter anomaly based on machine learning[J]. Journal of Wuhan Textile University, 2021, 34(2): 9-14. (in Chinese)
- [99] 秦一菲, 马明辉, 王岩松, 等. 基于改进 KNN 方法的交通流异常数据修复算法[J]. 计算机测量与控制, 2018, 26(12): 180-184.
- QIN Yi-fei, MA Ming-hui, WANG Yan-song, et al. A recovery method for abnormal traffic flow data based on improved knn algorithm [J]. Computer Measurement and Control, 2018, 26(12): 180-184. (in Chinese)
- [100] 秦胜君, 李 婷. 一种基于长短记忆模型的交通轨迹异常挖掘模型[J]. 广西科技大学学报, 2021, 32(2): 58-64.
- QIN Sheng-jun, LI Ting. An anomaly detection algorithm for traffic trajectory data based on long short term memory model[J]. Journal of Guangxi University of Science and Technology, 2021, 32(2): 58-64. (in Chinese)



- [101] ZHU Li, YU F R, WANG Yi-ge, et al. Big data analytics in intelligent transportation systems: a survey[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 20(1): 383-398.
- [102] BUI K H N, CHO J, YI H. Spatial-temporal graph neural network for traffic forecasting: an overview and open research issues[J]. Applied Intelligence, 2022, 52(3): 2763-2774.
- [103] CAO Zhi-guang, JIANG Si-wei, ZHANG Jie, et al. A unified framework for vehicle rerouting and traffic light control to reduce traffic congestion[J]. IEEE Transactions on Intelligent Transportation Systems, 2017, 18(7): 1958-1973.
- [104] QI Liang, ZHOU Meng-chu, LUAN Wen-jing. A two-level traffic light control strategy for preventing incident-based urban traffic congestion[J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 19(1): 13-24.
- [105] LI Hui, WANG Peng, SHEN Chun-hua. Toward end-to-end car license plate detection and recognition with deep neural networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 20(3): 1126-1136.
- [106] YUAN Wu-bei, WANG Ping, YANG Jing-wen, et al. An alternative reliability method to evaluate the regional traffic congestion from GPS data obtained from floating cars[J]. IET Smart Cities, 2021, 3(2): 79-90.
- [107] JIN Yin-li, JIA Zhen, WANG Ping, et al. Quantitative assessment on truck-related road risk for the safety control via truck flow estimation of various types[J]. IEEE Access, 2019, 7: 88799-88810.
- [108] JIN Yin-li, GAO Yi-wen, WANG Ping, et al. Improved manpower planning based on traffic flow forecast using a historical queuing model[J]. IEEE Access, 2019, 7: 125101-125112.