

基于深度 LSTM 与遗传算法融合的短期交通流预测模型

李静宜^{1,2},丁飞^{1,2*},张楠^{1,2},李湘媛^{1,2},顾潮^{1,2}

(1.南京邮电大学 物联网学院,江苏 南京 210003;

2.南京邮电大学 江苏省宽带无线通信和物联网重点实验室,江苏 南京 210003)

摘要:短期交通流预测是交通优化控制和智能服务的基础。由于交通流日内波动性明显,使用单层长短期记忆网络(LSTM)存在泛化能力不足的问题,堆叠多层 LSTM 易导致模型难以快速收敛。通过对 LSTM 神经网络架构的优化设计,提出一种深度 LSTM 与遗传算法融合的交通流预测模型 GA-mLSTM。首先,采用遗传算法(Genetic Algorithm, GA)对 LSTM 层数、Dense 层数、隐藏层神经元个数和 Dense 层神经元个数进行优化,确定 GA-mLSTM 模型的网络结构设计和最优参数;然后,基于 GA-mLSTM 模型的预测结果,使用差分运算对预测误差进行修正;最后,利用公开数据集对交通流预测性能进行评估并验证,实验结果表明:GA-mLSTM 模型采用 3 层 LSTM 神经网络结构,融入遗传算法和差分计算后,能有效捕获路网交通流的波动特性,可以实现更准确的交通流预测。

关键词:交通流预测;长短期记忆网络;遗传算法;差分处理

中图分类号:TN919.23

文献标志码:A

开放科学(资源服务)标识码(OSID):

文章编号:1003-3114(2022)05-0836-08



Short-term Traffic Flow Prediction Model Base on Fusion of Depth LSTM and Genetic Algorithm

LI Jingyi^{1,2}, DING Fei^{1,2*}, ZHANG Nan^{1,2}, LI Xiangyuan^{1,2}, GU Chao^{1,2}

(1.School of Internet of Things, Nanjing University of Posts and Telecommunications, Nanjing 210003, China;

2.Key Laboratory of Broadband Wireless Communication and Internet of Things of Jiangsu Province, Nanjing University of Posts and Telecommunications, Nanjing 210003, China)

Abstract: Short-term traffic flow prediction is the basis for optimizing traffic control and intelligent services. Due to the significant intra-day volatility of traffic flow, the use of a single-layer Long Short-term Memory network (LSTM) suffers from insufficient generalization ability, and stacking too many LSTMs will make the model difficult to converge quickly. Through the optimization design of LSTM neural network architecture, this paper proposes a traffic flow prediction model GA-mLSTM based on the fusion of deep LSTM and genetic algorithm. Firstly, the number of LSTM layers, the number of Dense layers, the number of hidden layer neurons, and the number of Dense layer neurons are optimized by using the Genetic Algorithm (GA), the network structure and optimal parameters of the GA-mLSTM model were determined; then, based on the prediction results of the GA-mLSTM model, the prediction errors were corrected by using differential processing; finally, the traffic flow prediction performance was evaluated and validated by using public data sets. The experimental results show that the GA-mLSTM model adopts a three-layer LSTM neural network structure can effectively capture the fluctuation characteristics of road network traffic flow and achieve more accurate traffic flow prediction after integrating genetic algorithm and differential calculation.

Keywords: traffic flow prediction; long short term memory; genetic algorithm; differential processing

收稿日期:2022-05-17

基金项目:江苏省大学生实践创新训练项目(SYB2020035);江苏省研究生科研与实践创新计划项目(KYCX20_0770);南京邮电大学科研创新资助项目(NY220028)

Foundation Item: Practice Innovation Training Program Project for the Jiangsu College Students (SYB2020035); Postgraduate Research & Practice Innovation Program of Jiangsu Province (KYCX20_0770); NUPTSF (NY220028)

0 引言

“十三五”以来,我国高速公路发展总体适应经济社会发展需要,但与高质量发展和构建新发展格局要求相比,高速公路补短板、强弱项、增质效任务仍然艰巨,转型发展亟待加快。信息化智慧化建设相对滞后,信息资源配置较为分散,运行监控、预测预警等信息管理平台不完善,数字化新技术、新手段运用较薄弱。道路交通状态瞬息万变,交通流预测可以为交通优化控制和智能服务提供决策参考。

目前,国内外研究者在交通流预测方面已有较多有益成果。现有交通流预测模型可分为:基于统计分析的预测模型^[1-2]、非线性理论模型^[3]、仿真预测模型^[4]、智能预测模型^[5-6]、混合模型^[7-8]等。近年来,以 LSTM 为代表的反馈神经网络在时间序列数据的预测方面具有广泛的应用,而且可作为非线性单元用于构造更大型的混合模型。王博文等人^[9]提出一种基于编码器-解码器的卷积神经网络(CNN)门循环单元模型,在单模特征或多模特征输入时均可获得较好的预测性能,且可以缓解预测误差的迅速积累问题。邵春福等人^[10]提出基于皮尔森相关系数法(PCC)与双向长短期记忆(BLSTM)的交通流预测模型,通过 PCC 筛选目标路段空间的路段并重构数据集,然后由 BLSTM 进行交通流预测,短时交通流预测精度获得较好提升。由于长短期记忆网络(LSTM)在长时间序列预测中表现出对历史信息的优秀整合能力,大多数学者也倾向于使用基于 LSTM 模型的交通流预测。Chu 等人^[6]利用 LSTM 进行车道级交通流预测,相较于门控循环单元(GRU)、堆叠自动编码器(SAEs)等模型具有更优的预测性能。王庆荣等人^[11]设计了一种多尺度特征融合的短时交通流预测模型,考虑了时间序列的连续性以及天气、节假日等因素,可以提升预测模型的预测泛化能力。李磊等人^[12]提出基于改进 CNN 与 LSTM 的交通流预测模型,设计了分层网络结构自动提取交通流序列的空间特征,优化 LSTM 网络模块来减少网络对数据的长时间依赖,并引入改进后的自适应矩估计(RAdam)优化算法,从而提高网络输出的准确性和鲁棒性。文献[13-14]分别使用双层

LSTM 构建电网能量消耗预测模型,前者结合了近邻节点拓扑关系,后者融入了注意力机制,二者均认为双层 LSTM 网络结构相较于单层 LSTM 能更好地表征能耗时空的变化,可以更准确地实现电网能量消耗曲线的预测。

考虑到神经网络在训练时易受其超参数影响,从而影响到模型的预测精度。Zhang 等人^[15]提出一种改进遗传神经网络(GA-BP),在遗传算法迭代过程中,选择前 n 个最优个体,自适应优化种群的搜索步长,保证种群的多样性且提高交通流预测模型的收敛速度。何祖杰等人^[16]提出基于改进灰狼算法(IGWO)优化支持向量机(SVM)的短期交通流预测模型,引入帐篷混沌序列初始化灰狼种群,优化收敛因子并对灰狼群体进化差分丰富种群多样化,从而提升预测模型的鲁棒性和泛化能力。温惠英等人^[17]采用遗传算法对数据时间窗步长、LSTM 神经网络的隐藏层数、训练次数、dropout 进行参数优化,相比传统 LSTM 模型具有更好的预测性能,由于选用了不同固定采样周期间隔的数据集,因此在通过固定采样周期的交通流预测场合无法复制应用。

基于以上分析,本文提出一种基于深度 LSTM 与遗传算法融合的交通流预测模型(GA-mLSTM),通过 LSTM 的深度网络设计保证模型泛化能力;引入遗传算法在全局空间获得最优解,加速模型收敛;通过差分运算对预测误差进行优化,提升整体交通流预测模型的准确率。最后,利用公开数据集进行模型测试并性能评估,对比传统两层 LSTM、支持向量回归(SVR)模型和循环神经网络(RNN)模型,验证所提 GA-mLSTM 模型的有效性与预测性能。

1 遗传算法超参数优化

基于深度 LSTM 进行预测时,网络层数和隐藏层神经元个数取值对于预测结果有直接影响。LSTM 网络的层数和隐藏层神经元个数决定了神经网络的复杂程度和拟合程度^[18]。考虑到交通流日内波动性明显,使用单层长短期记忆网络(LSTM)存在泛化能力不足的问题,堆叠多层 LSTM 易导致模型难以快速收敛。隐藏层接收来自输入神经元的输入后,根据输入的重要性分配权重,输入所分配的权重越大,则该输入量越重要。Dense 层的目的是

将提取的特征通过非线性变化提取关联因子并映射到输出中。在实际训练中,Dense 层的增加能够加快收敛速度。

遗传算法 (Genetic Algorithm, GA) 在求解过程中模拟生物进化中染色体基因的选择、交叉、变异等过程,并求取最优解的方法。其核心是通过适应度函数评估个体的优劣,对于结果更好的个体,在下一代种群中占比更高。GA 在求解较为复杂的组合优化问题时,相对于传统优化算法,通常能够较快地获得较好的优化结果,有较强的鲁棒性。因此,本文采用遗传算法对 LSTM 层及 Dense 层的层数、隐藏层及 Dense 层的神经元个数的组合进行寻优,将获得的优化参数用于预测模型,从而达到降低误差,提升收敛性的目的。

GA-mLSTM 模型将深度 LSTM 与 GA 进行融合,将 GA 中的每个染色体基因描述为 LSTM 网络结构层数和每层神经元个数等信息。染色体基因的编码结构示意图如图 1 所示,X1、X2 分别代表 LSTM 的层数与 Dense 层的层数,X3~X8 按顺序代表 LSTM 与 Dense 各层神经元个数。此外,在模型结构设计中,除了染色体中所定义的 Dense 层外,还需要添加一层神经元个数为 1 的 Dense 层用于输出预测结果。




图 1 染色体基因的编码结构

Fig.1 Coding structure of chromosome genes

堆叠 LSTM 的层数会导致预测模型的时间和资源开销的增加,文献[13-14]均采用了两层 LSTM 网络结构,可以获得时序数据预测性能的提升;文献[19]指出当 LSTM 层数超过 3 层时,会产生较明显的层与层之间的梯度消失问题。

本文在深度 LSTM 网络结构设计时,将 LSTM 网络层数限定为 1~3 层,同时将隐藏层的神经元个数约束在[32,256]区间。

基于 GA 优化深度 LSTM 网络超参数的核心操作包括:

(1) 选择

遗传算法通过适应度函数对子代染色体基因进行选择,按照预定策略从父代种群中进行个体选择和淘汰。本文利用轮盘赌选择方法实现遗传算法的

选择操作,采用均方误差 (MSE) 作为适应度函数,若 MSE 越小,则代表该个体适应度越高,其被选择的概率将变大。

(2) 交叉

交叉是对选择操作后存活的父代个体的基因进行组合,具体实现方式为个体生成一个随机数 $r_c \in [0,1)$,若 r_c 小于预设交叉概率 $P_c = 0.5$,则随机选择父代种群中的某个个体进行交叉,生成一个 8 位二进制数并转化为布尔类型决定发生交叉的基因位点。基因位点 X1、X2 代表 LSTM 的层数与 Dense 层的层数,由于层数交叉会影响到神经元参数的数量,因此基因位点 X1、X2 不产生交叉。

(3) 变异

变异是指遗传过程中染色体基因发生的突变。假定变异率 P_m 设为 0.01,则通过遍历所有染色体基因个体,当生成随机数 $r_m \in [0,1) < P_m$ 时,则认为该基因位点发生变异。与交叉同理,基因位点 X1、X2 不发生变异。

每一代种群生成后,将其子代个体所表示的网络结构参数代入深度 LSTM 网络中进行训练,本文通过对连续迭代训练设置最大迭代限定值以结束此次遗传进程。

2 GA-mLSTM 交通流预测模型设计

2.1 模型预测框架

GA-mLSTM 模型的整体框架如图 2 所示,主要包括数据准备模块、参数优化模块和预测训练模块。采用遗传算法对 LSTM 层数、Dense 层数、隐藏层神经元个数和 Dense 层神经元个数进行优化。

基于 GA-mLSTM 模型进行交通流预测的步骤描述如下:

步骤 1:数据预处理,使用 Min-Max-Scaler 函数对初始数据进行归一化处理;

步骤 2:使用遗传算法优化参数,得出 1~3 层 LSTM 网络结构的最优解;

步骤 3:构建模型,使用遗传算法寻优得出的参数训练 LSTM 模型;

步骤 4:使用训练好的模型,对测试集进行交通流预测;

步骤 5:对输出数据进行反归一化;

步骤 6:差分处理并计算误差。

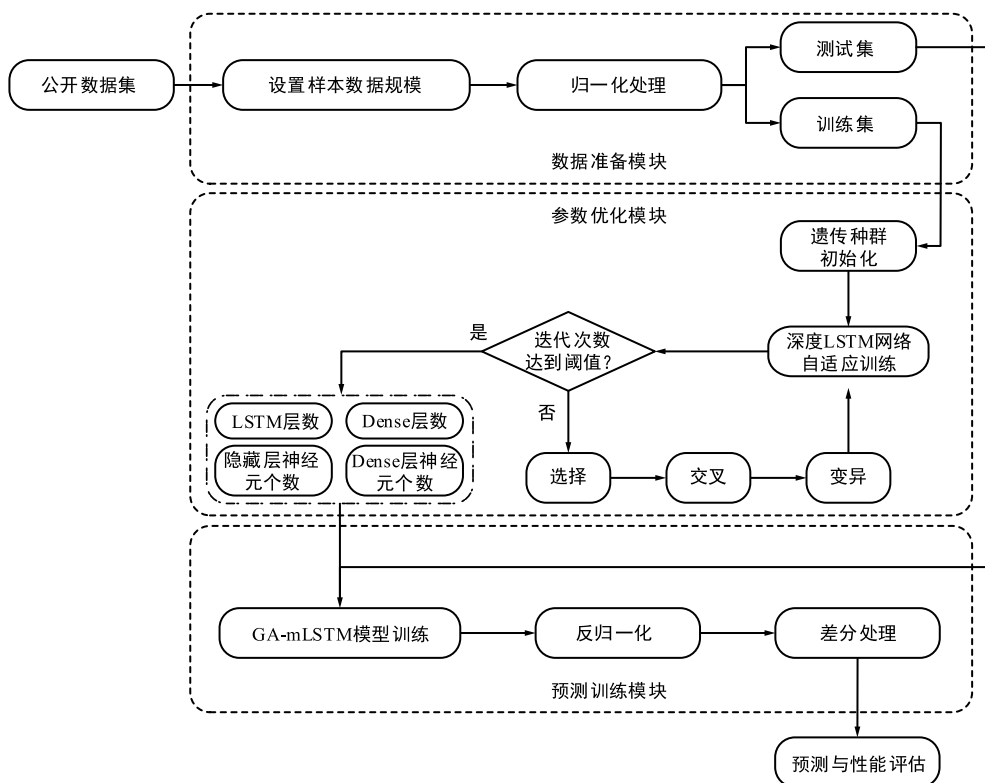


图2 GA-mLSTM 模型框架

Fig.2 Framework of GA-mLSTM model

2.2 数据预处理

本文使用公开的高速公路数据集^[20]检验模型性能,该数据集包含英国 M、A 级高速公路交通流量数据,以 15 min 为采样间隔。图 3 为该数据集中 2018 年 8 月 1—7 日共 7 天的原始交通流序列曲线,每天含 00:14:00—23:59:00 共 96 条交通流量数据。本文实验选取该数据集 2018 年 8 月 1—24 日共 2 304 条样本数据作为训练集,8 月 25—31 日共 672 条样本数据作测试集。




图3 原始交通流序列曲线

Fig.3 Sequence curve of original traffic flow

为提升模型的收敛速度及预测准确度,使用 Min-Max-Scaler 函数对初始数据进行统一规约,通

过式(1)将原始交通流量数据线性转换为 $[0, 1]$ 区间。

$$x^* = \frac{x - x_{\min}}{x_{\max} - x_{\min}}, \quad (1)$$

式中, x_{\max} 为样本数据的最大值, x_{\min} 为样本数据的最小值。处理后的输入输出数据格式如表1所示,输入步长设为20,即输入特征矩阵 X 由前20条数据进行构造,模型预测后输出预测值 Y 。

表1 模型输入输出格式示例

Tab.1 Input and output of the model

X				Y
0.061 389	0.068 389	...	0.189 014	0.212 708
0.068 389	0.716 208	...	0.212 708	0.289 176
⋮	⋮		⋮	⋮
0.465 805	0.455 573	...	0.168 551	0.164 243

2.3 长短期记忆神经网络

LSTM 是循环神经网络 RNN 的变形,其解决了 RNN 在长序列训练过程中出现的梯度消失以及梯度爆炸问题。LSTM 网络通过输入门、遗忘门以及输出门控制信息的传递,输入门决定当前时刻需要保存到单元状态的数据,遗忘门对输入进行选择记忆,将重要信息保留,输出门控制输出内容。

根据 LSTM 神经网络的结构^[21],其内部的计算逻辑如式(2)~(7)所示,其中 f_i 表示遗忘门, i_i 表示输入门, o_i 表示输出门, \tilde{C}_i 表示前一时刻细胞状态, C_i 表示当前细胞状态, h_i 表示当前单元的输出, h_{i-1} 表示前一时刻单元的输出, x_i 表示当前层的输入, W_f 、 W_i 、 W_c 、 W_o 分别为遗忘权重、输入权重、当前状态权重以及输出权重, b_f 、 b_i 、 b_c 、 b_o 分别为遗忘偏置项、输入偏置项、当前状态偏置项以及输出偏置项。

$$f_i = \sigma(W_f \cdot [h_{i-1}, x_i] + b_f), \quad (2)$$

$$i_i = \sigma(W_i \cdot [h_{i-1}, x_i] + b_i), \quad (3)$$

$$o_i = \sigma(W_o \cdot [h_{i-1}, x_i] + b_o), \quad (4)$$

$$\tilde{C}_i = \tanh(W_c \cdot [h_{i-1}, x_i] + b_c), \quad (5)$$

$$C_i = f_i \times C_{i-1} + i_i \times \tilde{C}_i, \quad (6)$$

$$h_i = o_i \times \tanh(C_i). \quad (7)$$

2.4 差分处理设计

交通流作为时间序列数据,由于时间序列预测存在自相关性,即 t 时刻的预测值更贴近 $t-1$ 时刻的真实值。因此,本文将为预测输出值采用差分操作,消除一阶自相关性,并将差分后的结果作为最终交通流预测值。

3 实验与性能分析

3.1 环境配置与评价指标

GA-mLSTM 模型的参数设置如表 2 所示。为防止模型过拟合,于每个 LSTM 层后加入 Dropout 层,丢弃率设置为 0.2。选择 Adam 优化器,该优化器结合了 AdaGrad 和 RMSProp 方法的最佳属性,自动为模型参数使用自定义学习率,能够使训练收敛性能更佳。

表 2 模型参数设置

Tab.2 Model parameter setting	
参数名称	参数值
Dropout	0.2
Batch_size	32
优化器	Adam

实验所使用的计算机配置为: Intel(R) Core(TM) i5-10400F CPU @ 2.90 GHz,内存为 16 GB, Windows10(64 位)操作系统,软件开发环境为 Python 3.7.11。

为对 GA-mLSTM 模型进行性能评价,使用均方误差(MSE)、均方根误差(RMSE)以及平均绝对误差(MAE)作为误差评价指标,对应计算公式如式(8)~(10)所示。

$$MSE = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2, \quad (8)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2}, \quad (9)$$

$$MAE = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|. \quad (10)$$

3.2 GA-mLSTM 交通流预测与分析

基于遗传算法的深度 LSTM 网络的优化训练过程如图 4 所示,可以看出,遗传算法在训练迭代过程中,初始阶段的均方误差存在明显波动性,但在进入 27 次迭代后,其均方误差趋于最优解,且波动性相对较小,即在该区间可以确定遗传算法的近似最优解。因此,在 GA-mLSTM 模型进行交通流预测时,将迭代次数设为 30 次,则认为在 30 次迭代训练中种群子代可获得近似最优适应度,即在遗传搜索空间能找到近似最优解。

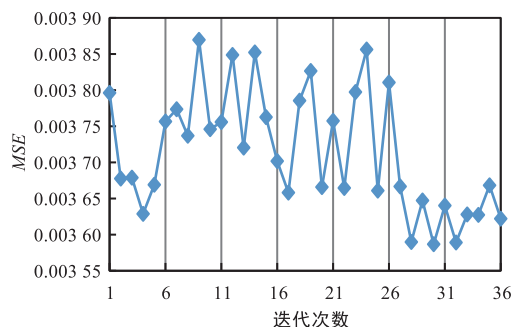


图 4 基于遗传算法的迭代训练结果

Fig.4 Iterative training results with GA algorithm

为评估 GA-mLSTM 的性能,参照文献[22]所用双层 LSTM 神经网络的设置参数,将 LSTM 模型中的 batch size 和步长分别设置为 64 和 8。在 GA-mLSTM 模型中,将 LSTM 层数设为 1~3 层,通过遗传算法探索解空间的最优解。经预测训练,获得 GA-mLSTM 模型的优化参数设置为表 3 所示,即 GA-mLSTM 模型中 LSTM 层数取为 3 层。

表 3 遗传算法寻优结果

Tab.3 Optimization results with GA	
参数名称	最优参数
LSTM 层数	3
隐藏层神经元个数	(41, 96, 53)
Dense 层数	1
Dense 层神经元个数	(149)

从表 4 中可知,相较于已有双层 LSTM 模型方法^[22],使用遗传算法优化深度 LSTM 网络结构参数的模型预测性能更优,其中 MSE、RMSE、MAE 分别提高了 1 870.92、10.23、7.55;加入差分操作后,MSE、RMSE 与 MAE 分别提高了 4 150.47、24.63、20.65。

表 4 不同 LSTM 模型预测性能比较

Tab.4 Comparison of different LSTM models

模型策略	MSE	RMSE	MAE
双层 LSTM ^[22]	9 331.74	96.61	72.82
GA+3 层 LSTM	7 460.82	86.38	65.27
GA+3 层 LSTM+差分	5 181.27	71.98	52.17

图 5 为 GA-mLSTM 模型在差分处理前后的预

测值与真实值的绝对误差对比图,在进行差分处理后,日高峰时间段交通流预测结果得到显著提升,总体误差得到有效减小。不同模型预测结果对比如图 6 所示,可以看出,GA-mLSTM 模型能够较好拟合交通流的变化趋势,且在交通流趋势为下降以及突变的时间区段,GA-mLSTM 模型的预测精度更高,显示其交通流预测的有效性。




图 5 融入差分处理的绝对误差对比

Fig.5 Absolute error comparison with differential processing




图 6 不同模型预测结果对比

Fig.6 Comparison of different model prediction results

3.3 不同模型的交通流预测与分析

图 7 给出了 GA-mLSTM 模型与支持向量回归 (SVR) 模型、循环神经网络 (RNN) 模型的交通流预测对比结果,在 8:00—20:00 时间段,GA-mLSTM、SVR、RNN 模型预测值与真实值之间的绝对误差区间分别为 $[0.042, 177, 276]$ 、 $[0.355, 386.955]$ 、 $[1.026, 399.682]$,因此,GA-mLSTM 模型相较于 SVR 和 RNN 具有更优的交通流预测性能,性能比较如表 5 所示。

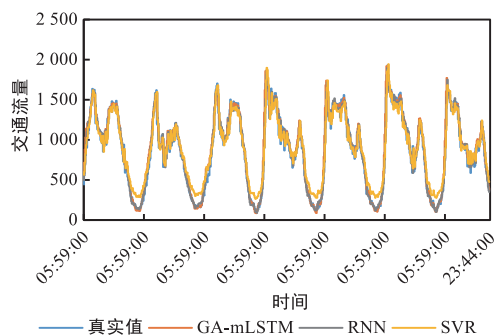


图 7 不同算法模型预测结果

Fig.7 Result of different algorithm models

表 5 不同算法模型预测性能比较

Tab.5 Comparison of different algorithm models

模型	MSE	RMSE	MAE
RNN	8 301.71	91.11	68.45
SVR	13 982.04	118.25	99.87
GA-mLSTM	5 181.27	71.98	52.17

4 结束语

由于交通流复杂程度高,实现对交通流的高精度预测对于城市交通管理具有重要意义。针对 LSTM 网络结构模型依赖传统经验难以确定结构参数的问题,基于遗传算法优化的深度 LSTM 网络结构,融合差分处理,提出一种交通流预测模型 GA-mLSTM。通过公开交通流数据集测试验证,相比传统 LSTM 模型,本模型具有更好的预测精度。本文提出的 GA-mLSTM 模型仅考虑交通流量单指标输入,且对于预测的时效性方面未作深入研究,未来研究可考虑在日内时序划分、长期交通流预测需求下的模型参数自适应调节等方面进一步优化和深入研究。

参考文献

- [1] 韩超,宋苏,王成红.基于 ARIMA 模型的短时交通流实时自适应预测[J].系统仿真学报,2004(7):1530-1532.
- [2] 杨高飞,徐睿,秦鸣,等.基于 ARMA 和卡尔曼滤波的短时交通预测[J].郑州大学学报(工学版),2017,38(2):36-40.
- [3] 杨紫煜,焦朋朋,云旭,等.基于相空间重构的卡尔曼滤波短时交通流预测模型[J].北京建筑大学学报,2021,37(4):43-50.
- [4] 马云龙,王坚,任子晖.基于微观仿真的快速路短时交通流预测研究[J].系统仿真学报,2009,21(14):4501-4503.
- [5] 翁小雄,郝翊.基于 LSTM 引入客车占比特征的短时交通流预测[J].重庆交通大学学报(自然科学版),2020,39(11):20-25.
- [6] CHU Q, LI G, ZHOU R, et al. Traffic Flow Prediction Model Based on LSTM with Finnish Dataset[C]//2021 6th International Conference on Intelligent Computing and Signal Processing (ICSP). Xi'an:IEEE,2021:389-392.
- [7] LI K, ZHAI C, XU J, et al. Short-term Traffic Flow Prediction Using a Methodology Based on ARIMA and RBF-ANN[C]//2017 Chinese Automation Congress (CAC). Jinan:IEEE,2017:2804-2807.
- [8] 叶景,李丽娟,唐臻旭.基于 CNN-XGBoost 的短时交通流预测[J].计算机工程与设计,2020,41(4):1080-1086.
- [9] 王博文,王景升,王统一,等.基于卷积神经网络与门控循环单元的交通流预测模型[J/OL].重庆大学学报:1-11[2022-05-04].http://kns.cnki.net/kcms/detail/50.1044.N.20220413.1704.003.html.
- [10] 邵春福,薛松,董春娇,等.考虑时空相关性的网络交通流短期预测[J].北京交通大学学报,2021,45(4):37-43.
- [11] 王庆荣,田可可,朱昌锋,等.融合多因素的短时交通流预测研究[J/OL].计算机工程与应用:1-12[2022-05-05].http://kns.cnki.net/kcms/detail/11.2127.TP.20210806.0837.006.html.
- [12] 李磊,张青苗,赵军辉,等.基于改进 CNN-LSTM 组合模型的分时段短时交通流预测[J].应用科学学报,2021,39(2):185-198.
- [13] 杨佳宁,黄向生,李宗翰,等.基于双层栈式长短期记忆的电网时空轨迹预测[J].计算机科学,2019,46(S2):23-27.
- [14] 高堰沪,徐圆,朱群雄.基于 A-DLSTM 夹层网络结构的电能消耗预测方法[J].计算机科学,2022,49(3):269-275.
- [15] ZHANG L, LIU W, FENG L. Short-term Traffic Flow Prediction Based on Improved Neural Network with GA[C]//2021 IEEE International Conference on Artificial Intelligence and Computer Applications (ICAICA). Dalian:IEEE,2021:312-315.
- [16] 何祖杰,吴新辉,刘中华.基于改进灰狼算法优化支持向量机的短期交通流预测[J].厦门大学学报(自然科学版),2022,61(2):288-297.
- [17] 温惠英,张东冉,陆思园.GA-LSTM 模型在高速公路交通流预测中的应用[J].哈尔滨工业大学学报,2019,51(9):81-87.
- [18] 周俊,尹悦,夏斌.基于 LSTM 神经网络的声发射信号识别研究[J].计算机科学,2021,48(S2):319-326.
- [19] 付强,王华伟.基于多层 LSTM 的复杂系统剩余寿命智能预测[J].兵器装备工程学报,2022,43(1):161-169.
- [20] 郭佳丽,邢双云,栾昊,等.基于改进的 LSTM 算法的时间序列流量预测[J].南京信息工程大学学报(自然科学版),2021,13(5):571-575.
- [21] 赵刚,王梦灵.基于模糊分析的 LSTM 交通流量预测[J].计算机工程与设计,2021,42(4):1103-1108.
- [22] 曹博,高茂庭.基于 LSTM 的短时交通流预测研究[J].现代计算机(专业版),2018(25):3-7.

作者简介：



李静宜 南京邮电大学物联网学院本科在读。主要研究方向：交通流预测建模与分析。



李湘媛 南京邮电大学物联网学院硕士研究生。主要研究方向：智能系统与大数据技术。



(* 通信作者) **丁 飞** 南京邮电大学物联网学院副教授。主要研究方向：智能网联车辆通信与网络技术、边缘智能与协同计算、智能系统与大数据。



顾 潮 南京邮电大学物联网学院硕士研究生。主要研究方向：物联网与信息系统、车辆目标检测与边缘智能技术。



张 楠 南京邮电大学物联网学院硕士研究生。主要研究方向：车联网技术、交通流预测技术。