



控制与决策

Control and Decision

ISSN 1001-0920, CN 21-1124/TP

## 《控制与决策》网络首发论文

题目: 考虑时空相似性的动态图卷积神经网络交通流预测  
作者: 谷振宇, 陈聪, 郑家佳, 孙棣华  
DOI: 10.13195/j.kzyjc.2022.0937  
收稿日期: 2022-05-26  
网络首发日期: 2022-11-10  
引用格式: 谷振宇, 陈聪, 郑家佳, 孙棣华. 考虑时空相似性的动态图卷积神经网络交通流预测[J/OL]. 控制与决策. <https://doi.org/10.13195/j.kzyjc.2022.0937>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

## 考虑时空相似性的动态图卷积神经网络交通流预测

谷振宇<sup>1†</sup>, 陈 聪<sup>1</sup>, 郑家佳<sup>2</sup>, 孙隽华<sup>1</sup>

(1. 重庆大学自动化学院, 重庆市 400044; 2. 重庆城市管理职业学院商学院, 重庆市 401331)

**摘要:** 高精度的交通流预测, 对于大型城市的交通管理和智慧出行具有重要作用. 而交通流动态时空相关性的挖掘, 则是提高预测精度的关键. 针对现有研究中存在的对交通流在不同时间尺度下呈现出的高度相似性, 以及处于相似功能区的非邻近节点间交通流变化的相似性考虑不足的问题, 构建了考虑时空相似性的动态图卷积神经网络(Dynamic Graph Convolution Neural network considering Spatio-Temporal Similarity, STS-DGCN). 以相邻时段、日和周等多时间尺度下的数据输入张量表达交通流数据的时间相似性, 以路网节点间距离度量、相似性度量、自适应嵌入、动态相关性等多属性特征的邻接矩阵表达交通流数据的时空相似性, 进而基于这些邻接矩阵构建反映路网节点时空动态变化的动态图, 并设计了相应的时空特征挖掘算法. 在公开的数据集上进行了实验, 结果表明: 模型的预测结果优于目前较为先进的对比基线模型, 具有更高的预测精度.

**关键词:** 交通流预测; 图卷积神经网络; 动态图; 时间相似性; 空间相似性; Wasserstein距离

中图分类号: TP273

文献标志码: A

DOI: 10.13195/j.kzyjc.2022.0937

## Traffic Flow Prediction Based on STG-CRNN

GU Zhen-yu<sup>1†</sup>, CHEN Cong<sup>1</sup>, ZHENG Jia-jia<sup>2</sup>, SUN Di-hua<sup>1</sup>

(1. School of Automation, Chongqing University, Chongqing 400044, China; 2. School of Business Administration, Chongqing City Management College, Chongqing 401331, China)

**Abstract:** High precision traffic flow prediction plays an important role in traffic management and intelligent travel in large cities. Mining the temporal and spatial correlation of traffic flow dynamics is the key to improve the prediction accuracy. In view of the insufficient consideration of the high similarity of traffic flow in different time scales and the similarity of traffic flow changes between non adjacent nodes in similar functional areas, a dynamic graph convolution neural network considering spatio-temporal similarity is constructed (Dynamic Graph Convolution Neural network considering Spatio-Temporal Similarity, STS-DGCN). The time similarity of traffic flow data is expressed by the data input tensor under multiple time scales such as adjacent periods, days and weeks, and the time-space similarity of traffic flow data is expressed by the adjacency matrix with multi-attribute characteristics such as distance measurement, similarity measurement, adaptive embedding and dynamic correlation between road network nodes. Then, based on these adjacency matrices, a dynamic graph reflecting the temporal and spatial dynamic changes of road network nodes is constructed. The corresponding spatio-temporal feature mining algorithm is designed. The results show that the prediction result of the model is better than the more advanced baseline model and has higher prediction accuracy.

**Keywords:** traffic flow prediction; graph convolutional neural network; dynamic graph; temporal similarity; spatial similarity; Wasserstein distance

## 0 引言

交通流预测是智能交通与智慧城市研究中最关键的问题之一<sup>[1]</sup>. 高精度的交通流预测有助于提高动态交通管理和交通资源的智能服务分配能力, 对于大型城市的交通管理和智慧出行具有重要作用.

交通流预测是基于历史的交通流数据对未来一段时间内该区域的交通流参数进行预测. 早期研究

主要包括: 历史均值模型(Historical Average, HA)和时间序列预测模型等<sup>[2]</sup>. 由于这些模型对交通流的非线性特征表征能力不足, 所以其预测精度较差. 而具有非线性核函数和激活函数的机器学习预测模型, 如支持向量机回归、K邻近等<sup>[3]</sup>, 能够挖掘数据中的非线性关系, 从而使预测精度获得了较大的提升. 但是机器学习对于挖掘交通数据中的复杂时空关系

收稿日期: 2022-05-26; 修回日期: 2022-10-21.

基金项目: 国家自然科学基金项目(62073049); 重庆市自然科学基金(cstc2021jcyj-msxmX0649); 重庆市教委科学技术研究项目(KJQN202003303).

<sup>†</sup>通讯作者. E-mail: gzy@cqu.edu.cn.

却能力有限.因此,预测效果仍然不太理想.

深度学习可以对多维特征进行建模,能更好地学习数据内的复杂关系,进而提高预测精度<sup>[4]</sup>.因此,研究者们开始将循环神经网络(Recurrent Neural Network,RNN)等深度学习方法引入到交通流预测中. RNN具有良好的时间依赖性建模能力,但却受到短时记忆的制约<sup>[5]</sup>. RNN的变体,门控循环单元(Gated Recurrent Unit, GRU)<sup>[6]</sup>采用门结构来克服短时记忆的影响,解决了交通流数据中的长期时间依赖性建模问题,预测精度也得到了提升.但是,交通流数据不仅在时间上具有依赖性,在空间上也具有较强的依赖性.因此,仅从时间维度进行挖掘具有一定局限性.

由于卷积神经网络(Convolutional Neural Networks,CNN)具有捕获空间关联性的能力,学者们提出了一些融合卷积神经网络的预测方法<sup>[7]</sup>. CNN提供了一个能有效处理欧几里得结构数据的框架,但它还不能很好地处理交通流这种非欧几里得空间的数据,而对节点间临近度进行合理度量能够有助于更充分表征路网结构关系<sup>[8]</sup>.因此,对交通网络的复杂空间关系挖掘依旧不充分.

由于交通路网本质上是一种图结构,所以一些研究人员引入图神经网络(Graph Neural Networks, GNN)<sup>[9]</sup>,旨在解决非欧几里得空间交通数据的复杂空间关系挖掘问题.例如,Li等<sup>[10]</sup>提出了一种扩散卷积循环神经网络模型,该模型分别使用扩散卷积和循环神经网络在有向图上建模交通流的空间和时间特征. Zhao等<sup>[11]</sup>提出了一种基于融合图卷积神经网络和GRU的组合预测方法T-GCN,利用GCN挖掘复杂拓扑结构的时空作用关系.这些研究的结论都验证了基于GNN的架构比基于CNN的架构能获得更好的预测表现,这说明GNN可以更好地提取交通数据的空间依赖性.然而,这些模型使用的是基于启发式规则预定义的图,在较长的预测时间步长下模型误差会叠加,造成预测精度降低.

为了解决这一问题,Wu等<sup>[12]</sup>提出了一种Graph WaveNet模型,构建了能够保留路网拓扑隐含空间关系的自适应邻接矩阵,通过图卷积和时间卷积进行时空作用关系的挖掘. Bai等<sup>[13]</sup>提出了一种自适应图卷积递归网络,图的邻接矩阵可以通过自适应学习模块进行学习,挖掘时空特征.

这些研究,虽然在路网动态特性挖掘方面取得较好的效果,然而这些模型主要还是以预定义的图作为基准,通过节点邻域聚合操作来自适应更新路网的拓

扑表达,对路网节点之间相互影响的动态时空特征挖掘还不够充分.

因此,研究学者们开始着眼于基于动态图的卷积神经网络预测研究. 李荆等<sup>[14]</sup>提出通过图表示学习对动态图中不断变化的节点和边进行嵌入向量学习,使它们具有良好的信息表征能力. Hu等<sup>[15]</sup>提出了通过对当前输入进行注意力运算,得到动态变化的邻接矩阵,再通过GCN对这种动态空间性进行挖掘.

鉴于图卷积神经网络具有较强的不规则图像建模和挖掘能力,而动态图更能适应交通流动态时空变化特性,所以基于动态图卷积神经网络交通流预测是目前研究的主要方向.但是,现有研究不论是基于启发式规则预定义的图,还是以预定义的图作基准根据相似性度量机制自适应生成的图,都不能很好响应节点依赖关系的动态变化.因此,如何构建能表征路网动态时空特性的动态图,则是当前研究的重点.

交通流预测是典型的时空数据挖掘问题.交通流数据具有复杂的动态时空特性.然而,从交通路网的宏观特性上来看,受人们相似的生活作息规律以及路网节点相似的功能属性的影响和作用,使得交通流表现出一定的相似性变化规律.在时间维度方面,不同时间尺度下,路网节点的交通流呈现出高度的相似性;在空间维度方面,不仅临近节点间有较强的相关性,一些非邻近节点间,由于节点所在的功能区(例如学校、医院、商场等)相似,使得这些节点的交通流变化具有相似性.因此,从交通流时空数据的整体来看,其中蕴含着丰富的时空相似性信息.如果能够在交通流时空数据挖掘中充分考虑时空相似性,就必然会促进交通流预测精度的提升.

但是,现有研究主要是基于距离或连通关系进行节点时空依赖性建模,而对交通流数据中存在的这种时空相似性考虑不充分,并没有很好地利用这种相似的变化规律来帮助预测模型更好地挖掘交通数据中的时空特性.

针对上述问题,论文构建了考虑时空相似性的动态图卷积神经网络(STS-DGCN,Dynamic Graph Convolution Neural network considering Spatio-Temporal Similarity).以相邻时段、日和周等多时间尺度下的数据输入张量表达交通流数据的时间相似性,以路网节点间距离度量、相似性度量、自适应嵌入、动态相关性等多属性特征的邻接矩阵表达交通流数据的时空相似性,进而基于这些邻接矩阵构建反映路网节点时空动态变化的动态图,设计了相应的时空特征挖掘算法,实现了能够考虑时空相



似性的交通流预测. 该模型在公开的美国公路交通数据集上进行了实验,选择基于统计学的HA模型、基于机器学习的SVR模型、基于深度学习的GRU-ED模型、TCN模型、DCRNN模型、STGCN模型、ASTGCN模型和STS-DGCN模型作为基线模型进行对比分析,结果表明模型的预测结果在平均绝对误差、均方根误差和平均绝对百分误差等方面,均优于基线模型.

## 1 交通流时空相似性分析

### 1.1 时间相似性分析

交通流是典型的时间序列数据,在人们生活作息规律的影响和作用下,城市交通存在“早高峰”、“晚高峰”等相似的变化规律. 为了进一步明确这种规律,本节以Pearson相关系数来表示节点间的相关性,并从邻近时段、日和周三个尺度对交通流数据的时间相似性进行分析.

#### (1) 邻近时段相关性

以PeMS数据集中编号为317752的检测节点在2018年1月1日一天的车流量数据为例,设定步长 $n = 12$ ,分析当前时刻序列与前12个相邻时刻序列的相关程度. 依据相关系数结果可知,邻近当前时刻的前6个时间戳的相关性大于0.9呈现强相关,并且随着时间步长的增加,相关性在减弱.

#### (2) 日周期时间相似性

以317752节点1日至7日车流量的相关系数为例,工作日的相关系数均大于0.9,说明工作日的交通流量的变化趋势和程度呈现出强相关,与周末的相关系数分布在(0.67-0.73)之间呈现出中度相关. 周末两天相关系数为0.94呈现出强相关,并且相邻天数的车流量相关系数大,呈现出强相关.

#### (3) 周周期时间相似性

以317752节点1月的车流量的相关系数为例,连续四周相关系数均大于0.88,呈现出强相关性,并且同一天相邻两周的相关程度较高.

### 1.2 空间相似性分析

本节从邻近节点空间相关性、非邻近节点间相似性和动态时空作用关系进行分析.

#### (1) 邻近节点空间相关性

图1是以地图选点的方式在PeMS数据集中选择部分节点数据绘制的一段道路结构示意图,以A、B、C、D和E表示编号为410692、401433、424404、401851和401852的检测节点,图中的箭头表示了道路通行方向.




图1 一段道路结构示意图

图2是这5个检测节点一天内的车流量的相关系数. 由图2可知,位于同一车道的相邻路段之间的相关性均高于0.9,属于高度相关;同一车道非相邻路段CD之间的相关系数为0.87,属于高度相关但不及相邻路段的相关性;而不同车道节点间的相关性都不高.




图2 节点间连续一天车流量序列相关系数

#### (2) 非邻近节点间相似性

通过对节点间相关系数进行分析,我们发现,一些非邻近节点间,当其处于相似的功能区时,也有较强的相似性. 以PeMS数据集中编号为773024,1214270,400278,402340,10121810的五个节点为例,它们之间属于非邻近节点,分别用M、N、X、Y和Z来表示. 结合地图分析,节点X、Y和Z都在公园区域,节点M和N在办公区域,它们之间的相关系数如图3所示.从图中可以发现,依据相关系数的大小,这5个节点被分为两组,其中M和N为一组,X、Y和Z为另一组,且各组相关系数都在0.9以上,这说明它们组内高度相关,而组间相关性较小. 为方便观察,选择节点N、Y和Z,对其车流量进行可视化,如图4所示,从图中可以看出节点Y、Z的数据变化趋势相近,而与节点N的数据变化趋势差异较大,这应该是由Y、Z具有相似的功能属性导致的.

对于这种非邻近节点间的相似性,如果采用欧式距离来度量,会因为它们非邻近的缘故,其欧式距离会很大,则会认为非邻近节点间作用关系较弱,所以需要借助新的手段来表征非邻近节点间的关系.




图3 节点M、N、X、Y、Z相关系数




图4 节点N、Y、Z车流量可视化

### (3) 动态时空作用关系

在对路网节点进行相关性分析时,我们注意到存在一种现象,这就是邻近节点间的相关系数在不同时段会发生动态变化。例如,PeMS数据集中编号为314042和314157的两个节点,它们是邻近的检测节点。当我们对其中某天的数据进行相关性分析时,存在较多不同时段的相关系数会发生动态变化的情况。以数据变化比较明显的1月3日为例,在0点到8点的时段,它们的相关性较高,为0.95。可是在8点到18点的时段它们的相关性很低,为负0.066。在18点到24点的时段,相关系数又恢复到0.9,而在其它天的各时段里面,它们间的相关系数总体保持在0.9-0.95之间。图5显示了该日可视化后的数据,从中可以看出在8点到18点的时段,通过314042节点的车流量较高,这说明该点通行比较顺畅,而通过314157节点的车流量较少,这可能是由于某种突发事件导致314157点通行比较拥堵,导致车流量减少。而在18点之后,当交通恢复正常时,它们的交通流变化趋势又比较相近。这说明,节点间的作用关系会受到随机事件的影响而动态变化的,如果忽视了这一影响因素会降低深度学习的效果。




图5 节点314042和314157车流量可视化车流量可视化

## 2 STS-DGCN 模型

### 2.1 总体框架

本文提出的STS-DGCN模型的总体框架如图6所示,由三个功能相同的Block组成,分别用于处理邻近时段、日和周等三个不同时间尺度下的交通流数据。每个Block由动态图构建组件和通过残

差相连的多个时空层构成。时空层由门控扩张因果卷积(GTCN)和双向游走的图卷积(KDGCN)组成,两者共同作用以建模时间依赖性;双向游走的图卷积通过在生成的图上进行随机漫步游走来汇聚节点信息以建模空间依赖性。多个时空层组件通过残差连接,以避免模型的退化和收敛速度的变慢。动态图构建组件的作用是表征路网的动态时空相关性,生成表征路网节点动态图结构的动态邻接矩阵,并输入到KDGCN中参与计算。

每个Block的输入为张量 $X$ ,  $X \in \mathbb{R}^{N \times F \times T}$ ,其中: $N$ 是检测节点数目, $F$ 是数据特征维度(车流量、速度和占有率), $T$ 是输入序列的时间步数。它并行输入到动态图构建组件和时空层组件中,经过动态图构建组件得到表征动态图的邻接矩阵,通过残差连接的时空层运算后输出Block的结果,对这三个Block的输出进行融合计算得到预测值 $\hat{Y}_{t+1:t+S}$ ,  $\hat{Y}_{t+1:t+S} \in \mathbb{R}^{N \times F \times S}$ ,其中 $S$ 表示需要预测时间步数。

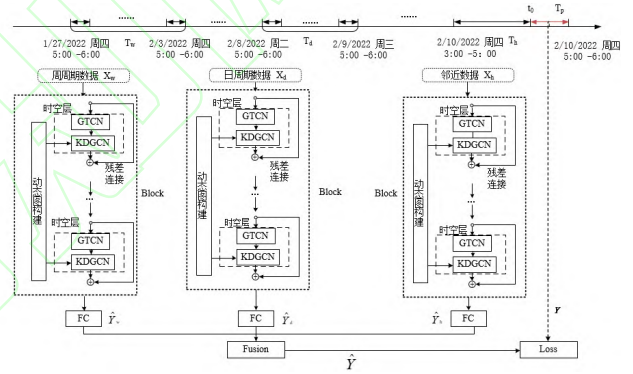


图6 STS-DGCN模型框架

### 2.2 时间相似性的多尺度输入输出表达

根据交通流数据在不同时间尺度上表现出的相似性,本文定义了临近时段、日和周等三种时间尺度,并设计了这三种时间尺度下的周期数据作为模型输入,用以捕获节点间短期和长期的时间作用关系。假设检测节点的采样频率是 $q$ 次/天,则一天的采样时间序列的长度为 $q$ 。设当前时刻为 $t_0$ ,  $T_p$ 表示所要预测的未来时间区间,  $T_h$ 表示过去邻近时段的时间区间,  $T_h = N_h * T_p$ ,  $N_h \in \mathbb{N}^+$ ;  $T_d$ 表示过去几天同一时间的交通流量,  $T_d = N_d * T_p$ ,  $N_d \in \mathbb{N}^+$ ;  $T_w$ 表示过去几周同一时间的交通流量,  $T_w = N_w * T_p$ ,  $N_w \in \mathbb{N}^+$ ; 其中 $N_h, N_d, N_w$ 是大于1的正整数,表示预测步长的倍数。临近时段、日和周输入数据分别用 $X_h$ 、 $X_d$ 和 $X_w$ 表示。预测值 $\hat{Y}$ 是通过通过对 $X_h$ 、 $X_d$ 和 $X_w$ 经过Block时空建模之后的输出 $\hat{Y}_h$ 、 $\hat{Y}_d$ 和 $\hat{Y}_w$ 进行加权后得到,如式(1)所示。

$$\hat{Y} = W(w) \odot \hat{Y}_w + W(d) \odot \hat{Y}_d + W(h) \odot \hat{Y}_h \quad (1)$$

其中:  $W_w, W_d, W_h$ 是可学习参数,表示各个时间尺度对预测值的影响大小,  $\odot$ 表示矩阵对应元素相乘。

### 2.3 时间相似性表达与动态图构建

在图卷积神经网络中,图结构是以邻接矩阵的形式进行表达和参与计算的。因此,论文设计了四种以不同属性形式构建的邻接矩阵用以表达交通流数据不同种类的时空相似性,进而基于这些邻接矩阵构建反映路网节点时空动态变化的动态图。具体包括:

(1) 节点相关性距离度量邻接矩阵  $A_{pre-distance}$

$A_{pre-distance}$ 用以表征邻近节点空间相关性,记为:  $A_{pre-distance} = \{A_{pre-distance_{ij}} | (\nu_i, \nu_j) \in E\} \in \mathbb{R}^{N \times N}$ ,其中  $A_{pre-distance_{ij}}$ 表示节点  $\nu_i$  到节点  $\nu_j$  的权重,  $(\nu_i, \nu_j)$ 表示从节点  $\nu_i$  到节点  $\nu_j$  的交通流向,且  $(\nu_i, \nu_j) \neq (\nu_j, \nu_i)$ 。权重采用带有阈值的高斯核来计算,如式(2)所示。

$$w_{ij} = \begin{cases} \exp(-\frac{dist(\nu_i, \nu_j)^2}{\sigma^2}) & j \in k(i); \\ 0 & otherwise. \end{cases} \quad (2)$$

式中,  $dist(\nu_i, \nu_j)$ 为节点  $\nu_i \rightarrow \nu_j$  的欧式距离,  $k(i)$ 表示当  $dist(\nu_i, \nu_j) \leq \gamma$  时,节点  $\nu_i$  的  $k$  个邻域节点的集合,  $\gamma$ 为设置的阈值,当两个节点的距离超出阈值  $\gamma$  时,则权重系数为0,表示无相互作用关系,  $\sigma^2 = \frac{1}{n \cdot k} \sum_{i=1}^n \sum_{j \in k(i)} dist(\nu_i, \nu_j)^2$ ,表示距离的方差。

(2) 非邻近节点相似性度量邻接矩阵  $A_{pre-similarity}$

如前所述,欧式距离不能很好地度量非邻近节点相似性,而Wasserstein距离是通过时间序列的分布来度量的,可更好度量节点间的相似程度。因此,采用Wasserstein距离进行相似性计算,如式(3):

$$S_{ij} = \exp(-Wasserstein(X_i, X_j)) \quad (3)$$

式中,  $S_{ij}$ 表示节点  $\nu_i$  与节点  $\nu_j$  的相似性得分,  $S_{ij}$ 的值为零,则非邻近节点相似性度量邻接矩阵如式(4)所示。由于相似矩阵非常庞大,其计算量也很大,因此需要稀疏化。Top-k机制是一种相似性选择机制,它可以在一组数据中选择最大的K个数,进而实现稀疏化。所以,我们通过使用top-k机制对  $A_{pre-similarity}$  进行行标准化运算。

$$A_{pre-similarity_{ij}} = \frac{S_{ij}}{\sum_{k=1}^K S_{ik} \cdot L(E_s, \nu_i, \nu_k)} \quad (4)$$

式中,  $EE_s$ 表示通过top-k机制选取的边集合,  $L(E_s, \nu_i, \nu_k)$ 取值为0或者1,表示节点  $\nu_i$  与节点  $\nu_k$  的边是否被选中。

(3) 自适应嵌入邻接矩阵  $A_{adp}$

自适应嵌入邻接矩阵用以学习路网中一些相似的固有属性特性(例如POI分布、道路等级等)。由于以预定义的形式来预先确定这些作用关系难以反映真正的依赖关系,并可能会丢失真正的关系,本文采用文献12中提出的基于自适应嵌入邻接矩阵学习路网固有属性的方法,实现对路网固有属性的表征。构建的基本原理是先随机生成自适应嵌入邻接矩阵,通过计算处理后,作为构建动态图组件的一部分,然后输入到STS-DGCN网络模型中,经过学习和训练,最终得到能表征路网的固有属性的自适应嵌入邻接矩阵。其构建过程是,先随机初始化生成两个可学习的嵌入矩阵  $E_{em1}, E_{em2} \in \mathbb{R}^{N \times d}$ ,其中N是节点的数量,d为每个节点的嵌入维度且远小于N,然后通过式(5)计算得到。

$$A_{adp} = SoftMax(ReLU(E_{em1} \cdot E_{em2}^T)) \in \mathbb{R}^{N \times N} \quad (5)$$

其中:  $SoftMax(\cdot)$ 是激活函数,作用是将输入映射到(0,1)区间内,对自适应邻接矩阵进行归一化;  $ReLU(\cdot)$ 是线性整流激活函数,用于消除弱连接。

(4) 动态相关性邻接矩阵  $A_{dynamic}$

一些外部突发事件会导致节点间的依赖关系发生动态变化。本文设计了动态相关性邻接矩阵来捕获这种动态的空间相关性。假设有一组包含N个节点、F维特征和序列长度为T的输入数据,记为:  $X_{t-T+1:t} = [X_{t-T+1}, \dots, X_{t-1}, X_t] \in \mathbb{R}^{N \times F \times T}$ 。首先,为更好挖掘原始数据的特征,将其输入全连通网络,把特征维度从F维升为D维,计算方式如下式(6):

$$S = FC(X_{t-T+1:t}) \in \mathbb{R}^{N \times D \times T} \quad (6)$$

式(6)中,  $FC(\cdot)$ 表示全连接网络,  $S$ 表示映射后节点属性,为了捕获T长度内节点间的动态相关性,沿时间维度对S进行一维卷积操作,一维卷积膨胀系数是d,卷积核为K,计算方式如式(7):

$$DC_d(S) = \left( \sum_{t=d \times (k-1)}^T \sum_{k=0}^{K-1} w_k \cdot S_{t-d \times k} \right) \quad (7)$$

式(7)中,  $DC_d(\cdot)$ 表示一维膨胀卷积操作,  $DC_d(S) \in \mathbb{R}^{N \times D \times [T-(d \times (k-1))]}$ 。  $S_t$ 表示t时刻的数据,  $S_t \in \mathbb{R}^{N \times D}$ 。我们通过堆叠几个不同膨胀系数的一维膨胀卷积操作把  $N \times D \times T$  的矩阵转化成为  $N \times D$  的矩阵,记为M:

$$M = DC_{d2}(DC_{d1}(S)) \in \mathbb{R}^{N \times D} \quad (8)$$

进而,通过式(9)计算得到  $A_{dynamic}$ 。

$$A_{dynamic} = SoftMax(ReLU(M \cdot M^T)) \in \mathbb{R}^{N \times N} \quad (9)$$

通过对上述定义的邻接矩阵进行融合可以得到



表达动态图的邻接矩阵 $DA_t \in \mathbb{R}^{N \times N}$ ,其计算方式如式(10)所示.

$$DA_t = \text{ReLu}(A_{\text{pre-distance}} + A_{\text{pre-similarity}} + A_{\text{adp}} + A_{\text{dynamic}}) \quad (10)$$

## 2.4 时空特征挖掘算法

### (1) 时间特征挖掘算法

从时间维度上来看,交通流数据本质上是一个时间序列数据. 因此本文使用门控扩张因果卷积来挖掘交通流数据中的时间特征. 拼接扩张因果卷积是通过将每层扩张因果卷积的结果进行拼接,从而能更有效地提取原序列中的短期和长期时间特征. 在拼接扩张因果卷积第 $l$ 层, $t$ 时刻,节点 $\nu_i$ 在 $p_l$ 维度上扩张因果卷积的输出结果可以由式(11)计算得出.

$$y_{i,p_l,t}^l = \sum_{k=0}^{K-1} \sum_{p_{l-1}=1}^{P_{l-1}} w_{k,p_{l-1},p_l}^l \cdot y_{i,p_{l-1},t-d^l \times k'}^{l-1} \quad (11)$$

其中: $d^l$ 是第 $l$ 层的膨胀系数, $w_{k,p_{l-1},p_l}^l$ 是长度为 $K$ 的卷积核 $W \in \mathbb{R}^{K \times P_{l-1} \times P_l}$ 中的元素, $P_{l-1}$ 和 $P_l$ 是输入和输出的维度.  $\mathcal{Y}^l \in \mathbb{R}^{N \times P_{l-1} \times T}$ 表示每一层输出的序列特征, $l = 0, 1, \dots, L$ 表示扩张因果卷积的层数.

我们将扩张因果卷积的每层结果 $\mathcal{Y}^l$ 进行拼接 $\|_{l=0}^L \mathcal{Y}^l$ ,其中, $\mathcal{Y}^l \in \mathbb{R}^{N \times P_0 \times T}$ 表示第0层表示输入数据,在经过特征映射学习函数 $h(\cdot)$ 使得 $\mathcal{Y} \in \mathbb{R}^{N \times D \times T}$ ,计算公式如下式(12):

$$\mathcal{Y} = \theta * \mathcal{X} = h(\|_{l=0}^L \mathcal{Y}^l) \quad (12)$$

其中: $*$ 表示上述的扩张因果卷积和拼接操作, $\theta$ 表示了上述操作的所有可学习参数.

门控机制可以很好地控制隐藏状态与当前状态对未来的影响. 因此,本文在在使用拼接扩张因果卷积的基础上引入门控机制,得到GTCN块的输出结果 $y_{tcn}$ .如下式(13)所示:

$$y_{tcn} = \tanh(\theta_a * \mathcal{X}) \odot \sigma(\theta_b * \mathcal{X}) \in \mathbb{R}^{N \times D \times T} \quad (13)$$

其中,激活函数 $\sigma(\cdot)$ 是将卷积后的值缩放到0与1之间,其中数值越接近1表示留存的信息越详细,越接近0表示留存率越低; $\odot$ 表示哈达玛积; $\tanh(\cdot)$ 表示激活函数.

### (2) 空间特征挖掘算法

本文使用随机双向游走的图卷积来提取交通流数据中的空间特征. 其中随机双向游走的图卷积定义如下: 在图 $G$ 上对 $t$ 时刻输入 $X_t \in \mathbb{R}^{N \times F}$ ,令状态转移方程为 $D_p = (\text{diag}(AI))^{-1}A$ ,其反向的状态转移方程为 $D_r = (\text{diag}(AI))^{-1}A^T$ ,则双向卷积计算如下

式(14):

$$X_t * f(\theta) = \sum_{k=0}^{K-1} (\theta_{k,1} \cdot D_p + \theta_{k,2} \cdot D_r) X_t \quad (14)$$

其中: $\theta \in \mathbb{R}^{K \times 2}$ 为滤波器 $f(\theta)$ 的参数,其输出为预测结果 $Z \in \mathbb{R}^{N \times O}$ ,其中 $O$ 为其输出数据的特征维度. 输入到输出的卷积层可简写为式(15):

$$Z = \sigma(X_t * f(\theta)) \quad (15)$$

基于如上的定义进行随机双向游走的图卷积. 对于第 $h$ 层时空块的KDGCN输入为 $Z^{(h)} \in \mathbb{R}^{N \times D \times T}$ ,在 $t$ 时刻 $Z^{(h)} \in \mathbb{R}^{N \times D}$ ,首先通过动态图构建组件求出动态图表达矩阵,之后通过式(14)和式(15)可以得到随机双向游走卷积的输出 $\tilde{Z}_t^{(h)}$ .

$$\tilde{Z}_t^{(h)} = \sigma(Z_t^{(h)} * f(\theta)) \quad (16)$$

将第 $h$ 层每个时刻的随机双向游走卷积进行拼接可以得到 $\tilde{Z}^{(h)} = \tilde{Z}_{t-T+1}^{(h)}, \dots, \tilde{Z}_{t-1}^{(h)}, \tilde{Z}_t^{(h)}$ . 通过堆叠多个时空层来加深网络深度以捕获高维的时空特征,但在加深深度的同时也带来了模型的退化和收敛速度的变慢. 因此,在堆叠时空层时,使用残差连接的方式来缓解这些问题. 具体地,第 $h$ 层时空层的输出 $Z^{(h)}$ 可以通过第 $l$ 层时空层的输入 $Z^{(h-1)}$ 和经过时空块的运算结果 $\tilde{Z}^{(h)}$ 通过式(17)获得.其中 $Z^{(0)} = FC(X_{t-t+1:t})$ .

$$Z^{(h)} = \tilde{Z}^{(h)} + Z^{(h-1)} \quad (17)$$

## 3 实验设计与验证

### 3.1 数据集描述

选取美国公路交通数据集PeMS04和PeMS08<sup>[16]</sup>进行试验验证. 按照 6 : 2 : 2 的比例将数据集切分成训练集、验证集和测试集.数据集详情如表1所示.

表1 数据集详情

数据集	节点数	边数	数据长度	时间间隔(min)
PeMS04	307	340	16992	5
PeMS08	170	295	17856	5

### 3.2 实验参数设置

本文实验参数主要包括: 训练200个epochs; 批量大小为32; 多尺度时间输入构建表达为 $T_h = 24\Delta T_d = 12\Delta T_w = 24$ ; 预测的步长为 $S=12$ ,即预测未来一小时的交通流量值; 生成器使用Adam优化器对模型进行训练,初始学习率为0.001; 源节点和目标节点嵌入矩阵的维数设置为8; 空间建模中的隐藏维度和融合输出维度均为32,作为扩散步长 $K=2$ ; 门控的扩张因果输出维度为32,每个扩张卷积的卷积核大小是3,三个叠加层的膨胀率分别为1、2和3.

### 3.3 基线模型

为了对比分析预测模型的预测效果,选择在交通流预测中应用较为广泛,比较有代表性的预测模型,包括基于统计学的HA模型、基于机器学习的SVR模型、基于RNN的GRU-ED模型、堆叠多层扩张因果卷积TCN模型、堆叠多层扩张因果卷积DCRNN模型、使用ChebNet图卷积的STGCN模型、结合自适应图与扩展卷积的GWN模型、结合图卷积和注意机制的ASTGCN模型和采用时空同步机制的STS-DGCN模型作为基线模型.这些基线模型是参考对应文献进行构建,其模型参数是在本文选取数据集上进行训练优化后得到.

### 3.4 评价指标

为了验证模型的有效性和对预测结果进行对比分析,选取平均绝对误差(MAE)、均方根误差(RMSE)和平均绝对百分比误差(MAPE)作为试验验证评价指标.这些评价指标的计算公式如下:

#### 1) 平均绝对误差(MAE)

$$MAE(y_i, \hat{y}_i) = \frac{1}{n} \sum_{i=1}^n |(y_i - \hat{y}_i)| \quad (18)$$

#### 2) 均方根误差(RMSE)

$$RMSE(y_i, \hat{y}_i) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (19)$$

#### 3) 平均绝对百分比误差(MAPE)

$$MAPE = \sum_{i=1}^n \left( \frac{y_i - \hat{y}_i}{y_i} \right) \cdot \frac{100}{n} \quad (20)$$

其中,  $y_i$  为观测值,  $\hat{y}_i$  为预测值.

### 3.5 实验结果分析

表2展示了本文模型与基线模型在PeMS04和PeMS08两个数据集上预测未来一小时的平均性能比较.可以看出,本文提出的STS-DGCN模型在三个评价指标上均优于基线模型.基于统计学的HA模型对非线性特征表征能力不足,其预测结果最差,而机器学习方法SVR能够挖掘数据中的非线性关系,从而使预测精度获得了一定的提升.从整体上看,深度学习模型的预测效果总体上好于统计学习模型和机器学习方法,这说明深度学习在交通流预测方面存在优势. TCN的预测效果要好于GRU-ED,这表明在时间依赖性建模方面,TCN比GRU更具有优势.但是,两者仅考虑交通流时间上的特征,没有考虑到空间特征.因此,其预测效果不如基于GCN的模型(DCRNN、STGCN、GWN、ASTGCN、STSGCN和STS-DGCN),这也验证了在交通流预测中引入图结构有助于挖掘交通流数据中的

复杂时空关系和预测精度的提升.在基于GCN的模型中,DCRNN利用GRU提取时间特征,STGCN利用一维卷积提取时间特征,两者都引入了图结构去提取空间特征,但它们使用的图是基于距离预定义的,不能很好的适应交通流的动态时空变化.所以,预测效果还不够好. GWN采用自适应图来挖掘路网的时空依赖性,ASTGCN通过引入注意力机制对空间动态特性进行学习,二者的预测效果均优于使用距离预定义图的DCRNN和STGCN,这也说明了动态图更能适应交通流动态时空变化特性,对提高预测精度具有重要的作用.在所有对比的基线模型中,STSGCN的预测效果不错,这主要得益于该模型能够通过精心设计的时空同步建模机制能有效捕捉复杂的局部时空相关性.同时,在模型中设计的多个不同时间段的模块也有助于有效捕捉局部时空图中的不同特性. STSGCN良好的预测效果也表明复杂路网中存在不同局部的时空相关性.对这种相关性模式的挖掘,会促进交通流预测精度的提升.

与基线模型中表现较好的ASTGCN和STSGCN相比,本文模型在结构设计和算法实现方面都比较简单,没有像ASTGCN那样引入注意力机制,算法也没有STSGCN那样精妙.但是,本文模型在两个数据集上的表现都优于基线模型.这说明,本文提出的充分考虑交通流数据的时空相似性,并把它们以先验的形式表达出来,用于交通流时空数据挖掘,对于提升预测精度具有重要作用.以相邻时段、日和周等多时间尺度下的数据输入张量,来表达交通流数据的时间相似性,有助于有效挖掘不同时间段的时空特性.这是本文模型效果要优于基线的原因之一.以路网节点间距离度量、相似性度量、自适应嵌入、动态相关性等多属性特征的邻接矩阵,来表达交通流数据的时空相似性,进而基于这些邻接矩阵构建反映路网节点时空动态变化的动态图,有助于时空动态特性的挖掘.这是本文模型效果要优于基线模型的原因之二.

表2 不同模型在PeMS04和PeMS08数据集上预测未来一小时得平均性能

Model	PeMS04			PeMS08		
	MAE	RMSE	MAPE	MAE	RMSE	MAPE
HA	36.99	49.57	27.46%	32.39	44.76	21.09%
SVR	28.65	43.86	19.17%	26.44	37.50	17.03%
GRU-ED	24.16	39.07	18.28%	23.45	33.43	15.03%
TCN	23.18	38.76	18.09%	23.24	33.22	14.89%
DCRNN	22.99	35.17	17.02%	20.88	30.84	13.51%
STGCN	22.38	34.62	15.51%	20.72	30.30	13.26%
GWN	22.13	34.23	14.89%	19.25	28.96	13.11%
ASTGCN	21.92	34.38	14.34%	18.34	27.89	12.07%
STSGCN	21.51	34.13	14.13%	17.88	27.36	11.63%
STS-DGCN	19.98	31.85	14.02%	14.74	24.81	10.68%

为了进一步对比本文模型与基线模型之间的



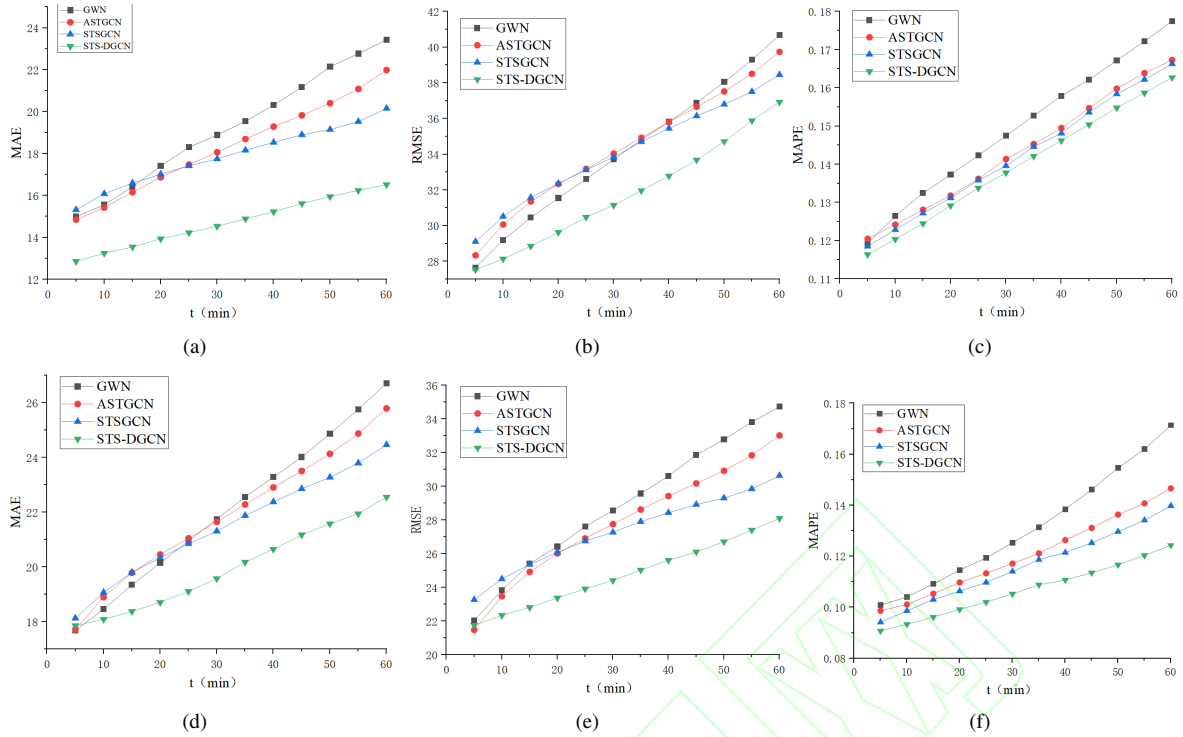


图7 各模型在METR-LA数据集上不同步长的预测结果对比

表3 不同模型在PeMS04和PeMS08数据集上预测未来3,6,12步长的性能

Datasets	Model	Horizon3			Horizon6			Horizon12		
		MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
PEMS04	GWN	19.35	30.45	13.25%	21.75	33.71	14.85%	26.72	40.69	17.35%
	ASTGCN	19.79	31.36	12.8%	21.65	34.04	14.14%	25.80	39.74	16.73%
	STSGCN	19.80	31.58	12.54%	21.31	33.84	13.85%	24.47	38.46	16.63%
	STS-DGCN	18.38	28.86	12.45%	19.58	31.15	13.78%	22.56	36.93	16.27%
PEMS08	GWN	16.42	25.42	10.87%	18.89	28.57	12.54%	26.72	34.74	17.14%
	ASTGCN	16.16	24.93	10.54%	18.07	27.76	11.72%	21.99	33.03	14.67%
	STSGCN	16.60	25.37	10.31%	17.75	27.28	11.41%	20.16	30.64	13.98%
	STS-DGCN	13.55	22.82	9.62%	14.54	24.42	10.53%	16.52	28.11	12.44%

预测性能,选择基线模型中预测效果最好的GWN、ASTGCN、STSGCN和STS-DGCN等四个模型在两个数据集上预测未来15分钟(*Horizon3*)、30分钟(*Horizon6*)和1小时(*Horizon12*)的结果与本文提出的模型进行比较,如图7和表3所示。可以看出,本文模型的预测结果在3个评价指标上都明显好于对比模型。图7展示了每个模型在预测步长上的预测精度,就所有评价指标而言,STS-DGCN在这两个数据集上都表现较好,特别是预测长时性能表现最好。同时,模型在在验证集和测试集上的预测偏差总体小于0.8%,这说明模型预测结果一致性较好,预测精度表现较好。

### 3.6 消融实验分析

为了评估预测模型中各个组件的有效性,以本文模型(STS-DGCN)为基础,移除多时间尺度的输入使用邻近时间段为输入的模型命名为STS-DGCN-H,移除考虑时空相似性的动态图构建组件使用距

离预定义的邻接矩阵的模型命名为STS-DGCN-D,通过在PEMS04数据集上进行各个消融模型的实验分析,如表4所示:

表4 消融模型在PEMS04上性能表现

模型	MAE	RMSE	MAPE
STS-DGCN-H	20.12	32.18	14.18%
STS-DGCN-D	20.56	32.34	14.32%
STS-DGCN	19.98	31.85	14.02%

可以看出,考虑交通流数据中时空相似性的动态图构建组件能提高模型对动态的空间依赖关系的建模表达能力,多时间尺度能为模型提供更长的时间维度信息来辅助模型的预测,各个组件能使模型更好地学习挖掘交通流数据中的时空变化规律。

## 4 结论

交通流预测是典型的时空数据挖掘问题。由于人员流动与城市经济活动具有内在的规律性,使得交通流数据蕴含着丰富的时空相似性信息。针对现有研究对路网时空相似性考虑不足的问题,提出一种考

虑时空相似性的动态图卷积神经网络交通流预测方法.在公开的数据集上进行了实验,结果表明,模型的预测结果优于目前较为先进的对比基线模型,具有更高的预测精度.论文主要研究结论如下:

1) 交通流数据在相邻时段尺度下呈现出高度相关性,在日和周的时间尺度下呈现出相似的变化规律;在邻近空间内,路网节点间相关性高,但相关程度有差异,一些非临近节点间的交通流变化具有相似性.

2) 基于交通流数据时空相似性的先验知识,设计适用于图卷积神经网络的表达形式,有助于挖掘交通流动态时空相关性,提升预测精度.

3) 以相邻时段、日和周等多时间尺度下的数据输入张量表达交通流数据的时间相似性有助于有效挖掘不同时间段的时空特性.以多属性特征邻接矩阵构建的动态图,能反映路网节点时空动态变化,提高了对动态空间依赖关系的建模表达能力.

因为交通流数据存在缺失的情况,这会导致路网图信息不完整,在未来的工作中,将进一步研究引入图注意力机制,同时,围绕动态图构建理论进行深入研究,以优化动态图的表达,提高模型的适应能力.

#### 参考文献(References)

- [1] L Qu, Lv J, Li W, et al. Features Injected Recurrent Neural Networks for Short-term Traffic Speed Prediction[J]. Neurocomputing, 2021, 451(9).
- [2] 刘静,关伟. 交通流预测方法综述[J]. 公路交通科技, 2004, (03): 82-85.  
(Liu J, Guan W. A Summary of Traffic Flow Forecasting Methods[J]. Journal of Highway and Transportation Research and Development, 2004, (03): 82-85.)
- [3] Reshma-Ramchandra Nazirkar, C. Rajabhushanam. Machine learning algorithms performance evaluation in traffic flow prediction[J]. Materials Today: Proceedings, 2022, 51:1046-1050.
- [4] Lv Yisheng, Yanjie Duan, Wenwen Kang, et al. Traffic Flow Prediction With Big Data: A Deep Learning Approach[J]. IEEE Transactions on Intelligent Transportation Systems, 2014,16(2): 865-873.
- [5] 杨丽,吴雨茜,王俊丽,等. 循环神经网络研究综述[J]. 计算机应用, 2018, 38(S2): 1-6.  
(Yang L, Wu Y X, Wang J L, et al. Research on recurrent neural network[J]. Journal of Computer Applications, 2018, 38(S2): 1-6.)
- [6] 王祥雪,许伦辉. 基于深度学习的短时交通流预测研究[J]. 交通运输系统工程与信息, 2018, 18(01): 81-88.  
(Wang X X, Xu L H, Short-term Traffic Flow Prediction Based on Deep Learning[J]. Journal of Transportation Systems Engineering and Information Technology, 2018,18(01):81-88.)
- [7] 罗文慧,董宝田,王泽胜. 基于CNN-SVR混合深度学习模型的短时交通流预测[J]. 交通运输系统工程与信息, 2017, 17(05): 68-74.  
(Luo W H, Dong B T, Wang Z S. Short-term Traffic Flow Prediction Based on CNN-SVR Hybrid Deep Learning Model[J]. Journal of Transportation Systems Engineering and Information Technology, 2017, 17(05): 68-74.)
- [8] 谷振宇, 陈聪, 等. 基于时空图卷积循环神经网络的交通流预测[J]. 控制与决策, 2022, 37(3):9-19.  
(GU Zhenyu, CHEN Cong, et al. Traffic Flow Prediction Based on STGCRNN[J]. Journal of Control and Decision, 2022, 37(3): 9-19.)
- [9] 马帅,刘建伟,左信. 图神经网络综述[J]. 计算机研究与发展, 2022, 59(01): 47-80.  
(Ma S, Liu J W, Zuo X. Survey on Graph Neural Network[J]. Journal of Computer Research and Development, 2022, 59(01): 47-80.)
- [10] Y Li, Yu R, Shahabi C, et al. Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting[C]. International Conference on Learning Representations,2018.
- [11] Zhao Ling, Yujiao Song, Chao Zhang, et al. T-GCN: A Temporal Graph Convolutional Network for Traffic Prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2019,21(9): 3848-3858.
- [12] Zonghan Wu, Pan Shirui, Long Guodong, et al. Graph WaveNet for Deep Spatial-Temporal Graph Modeling[J]. arXiv preprint arXiv:1906.00121, 2019.
- [13] L Bai, Yao L, Li C, et al. Adaptive Graph Convolutional Recurrent Network for Traffic Forecasting[J].2020,33: 17804-17815.
- [14] 李荆,刘钰,邹磊. 基于时空建模的动态图卷积神经网络[J]. 北京大学学报(自然科学版), 2021, 57(04): 605-613.  
(Li J, Liu Y, Zou L. A Dynamic Graph Convolutional Network Based on Spatial-Temporal Modeling[J]. Acta Scientiarum Naturalium Universitatis Pekinensis, 2021, 57(04): 605-613.)
- [15] Hu N, Zhang D, Xie K, et al. Graph learning-based spatial-temporal graph convolutional neural networks for traffic forecasting[J]. Connection Science, 2021: 1-20.
- [16] Caltrans Performance Measurement System[EB/OL]. <http://pems.dot.ca.gov/>.

#### 作者简介

谷振宇(1975—),男,副教授,博士,从事交通态势智能分析与预测等研究,E-mail: gzy@cqu.edu.cn;

陈聪(1996—),男,硕士生,从事交通态势智能分析与预测的研究,E-mail: 812478119@qq.com.

郑家佳(1980—),女,讲师,硕士,从事物流系统工程的研究,E-mail: jjiazjz@cqu.edu.cn

孙棣华(1962—),男,教授,博士生导师,从事交通信息物理系统的研究,E-mail: dsun@cqu.edu.cn.